



UNIVERSIDAD DE CONCEPCIÓN
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA INFORMÁTICA
Y CIENCIAS DE LA COMPUTACIÓN

**DISEÑO DE UN META-CONTROLADOR CON GARANTÍAS DE
ESTABILIDAD MEDIANTE REDES NEURONALES Y CAPAS DE
PROYECCIÓN PARA SISTEMAS LPV POLITÓPICOS**

POR

Pedro Pablo Muñoz Solano

Memoria de Título presentada a la Facultad de Ingeniería de la Universidad de Concepción para
optar al título profesional de Ingeniero Civil Informático

Profesor Guía

Hugo Garcés Hernández

Profesor Co-Guía

Jonathan Palma Olate

Julio 2026

Concepción

©2026 Pedro Pablo Muñoz Solano

Se autoriza la reproducción total o parcial, con fines académicos, por cualquier medio o procedimiento, incluyendo la cita bibliográfica del documento.

Agradecimientos

Quiero agradecer en primer lugar a mi familia, concretamente a mis hermanos José, Juan y en especial a mi madre que influyó en forjar mi carácter, mi hambre por siempre querer superarme y ser una persona independiente, sin ellos y su apoyo incondicional a cualquier adversidad jamás podría llegar a donde he llegado.

También agradecer a todas las personas y amigos con las que me he cruzado a lo largo de mi carrera universitaria. Si bien puede que mi historia con más de alguna de esas personas ya no tenga una continuación o no tengamos un contacto o cercanía como la de antaño en la actualidad, su paso por mi vida, valga la redundancia, vivirá para siempre en mis recuerdos en lo que puedo decir con certeza que son los mejores años que he vivido y siempre los recordaré con cariño. Sobre todo agradecer a la gente que de alguna u otra manera me ayudó ya sea en alguna asignatura haciendo más trabajo que yo ya que siempre pasaba enfocado en cualquier cosa menos la U o ayudándome de cualquier modo en realidad. Gracias a ustedes pude permitirme ser ambicioso y egoísta con mis sueños y metas.

Quiero agradecer en particular a algunas personas: Pelao, Blanchard, Krozz y Adodo que siempre me bancaron a pesar de cualquier cosa y siempre me tuvieron paciencia en las estupideces que podía llegar a decir y pensar por más loco que fuera. Cuando necesitaba que me tiraran para arriba siempre lo hicieron de manera incondicional, el valor de lo que hicieron por mi no tiene precio. Por otro lado a mis queridos amigos Rob, Sanwe, Chano, Óscar y Nico. Gracias a ustedes no puedo pedir una mejor vida universitaria. Con ustedes y las personitas de arriba siento haber vivido lo mejor de esta época. Creo pensar que ustedes estuvieron para mi en todas las maneras en las que se puede comportar y sentir un ser humano (o la gran mayoría al menos).

El departamento de Informática no puede quedar afuera, gracias a todo el personal que fue parte de mi formación. A Mauricio por esas tardes fomes viendo Games Done Quick con pizza y todas las cosas que vivimos y etapas clave de mi vida que si bien no son tantas en comparación a otras personas mencionadas aquí no dejan de ser importantes. Al profesor José Fuentes por dejarme ser su ayudante, gracias a eso desperté mi gusto por la docencia y la academia, aparte de estar para charlar con confianza e influir en quitarme mi síndrome del impostor en algunas ocasiones.

Agradecer a Jonathan por su orientación y exigencia para poder salir de mi zona de confort al hacer investigación, de él aprendí mucho.

Agradezco a Hugo, desde el minuto cero tuvo fé en mi en el momento que me sentía más perdido, cuando más lo necesitaba para encontrarle un sentido a la carrera fuera de lo que me esperaba profesionalmente hablando. A pesar de todos mis altos y bajos, crisis existenciales y mis “no sé que hacer” siempre me apoyó y me tuvo muchísima paciencia a pesar de que muchas veces no sabía lo que estaba haciendo. Sin su ayuda no podría haber disfrutado el proceso de interesarme por un

tema de investigación partiendo desde la mismísima nada para finalmente después de un proceso de constante aprendizaje durante dos años pude elaborar esta memoria de título.

Finalmente, agradecimientos a los Fondecyt Regular Control and Filter Design for Networked Cyber-Physical Systems: Theory and Applications, número 1241305 y Combining Machine Learning and Data Analytics for Advances in Process Control, número 1220903 por financiar esta memoria de título.

Glosario

Este glosario reúne las siglas, los términos técnicos y la notación matemática empleados a lo largo del documento, agrupados por temática. Salvo indicación contraria, las letras minúsculas en cursiva denotan escalares o vectores, las mayúsculas en cursiva denotan matrices, y las letras caligráficas o de pizarra ($\mathcal{C}$, $\mathbb{R}$, $\mathbb{S}$) denotan conjuntos o espacios.

Siglas y acrónimos

Sigla	Significado
CPS	<i>Cyber-Physical System</i> (Sistema Ciberfísico): sistema que integra computación, comunicación y control con un proceso físico.
LTI	<i>Linear Time-Invariant</i> (Lineal Invariante en el Tiempo): sistema lineal cuyas matrices no dependen del tiempo.
LPV	<i>Linear Parameter-Varying</i> (Lineal de Parámetros Variables): sistema lineal cuyas matrices dependen de un parámetro de operación variable en el tiempo.
LMI	<i>Linear Matrix Inequality</i> (Desigualdad Matricial Lineal): restricción de positividad sobre una matriz afín en las variables de decisión; define un conjunto factible convexo.
BMI	<i>Bilinear Matrix Inequality</i> (Desigualdad Matricial Bilineal): desigualdad con productos entre variables de decisión; define un conjunto no convexo y su optimización es NP-difícil.
SDP	<i>Semidefinite Programming</i> (Programación Semidefinida): optimización convexa sobre el cono de matrices semidefinidas positivas.
IPM	<i>Interior-Point Method</i> (Método de Punto Interior): familia de algoritmos que resuelven SDPs iterando estrictamente dentro de la región factible mediante pasos de Newton y barreras logarítmicas.
PSD	<i>Positive Semidefinite</i> (Semidefinida Positiva): propiedad de una matriz simétrica cuyos autovalores son no negativos.
DR	Douglas–Rachford: algoritmo de división de operadores empleado por la capa de proyección.
SOF	<i>Static Output Feedback</i> (Realimentación Estática de Salida): ley de control $u = Fy$ que solo utiliza las salidas medibles.

Sigla	Significado
MLP	<i>Multi-Layer Perceptron</i> (Perceptrón Multicapa): red neuronal densa de capas totalmente conectadas.
ReLU	<i>Rectified Linear Unit</i> : función de activación $\max(0, x)$.
KKT	Karush–Kuhn–Tucker: condiciones de optimalidad de primer orden de un problema de optimización con restricciones.
VJP	<i>Vector-Jacobian Product</i> (producto vector-Jacobiana): operación elemental de la retropropagación.
DEQ	<i>Deep Equilibrium Model</i> : arquitectura cuya salida es el punto fijo de un operador, diferenciada implícitamente.
OOD	<i>Out-of-Distribution</i> (fuera de distribución): régimen de evaluación en que los datos provienen de una distribución distinta a la de entrenamiento.
FDI / DoS	<i>False Data Injection / Denial of Service</i> : clases de ciberataque sobre CPS modelables como variaciones paramétricas.
RS	<i>Robustly Stabilizable</i> (robustamente estabilizable): etiqueta de la base de datos UNICAMP que certifica la existencia de una ganancia estabilizante común.
UNICAMP	Universidad Estatal de Campinas, origen de la base de datos de sistemas politópicos empleada.

Términos de teoría de sistemas y control

Término	Definición
Espacio de estados	Representación de un sistema dinámico mediante un conjunto mínimo de variables de primer orden que determinan su evolución futura.
Estabilidad asintótica	Propiedad de un sistema cuyas trayectorias convergen al punto de equilibrio cuando $t \rightarrow \infty$.
Matriz de Hurwitz	Matriz cuyos autovalores poseen todos parte real estrictamente negativa; equivale a la estabilidad asintótica del sistema $\dot{x} = Ax$.
Abscisa espectral	Mayor parte real de los autovalores de una matriz; su signo decide la estabilidad y su magnitud, la velocidad del modo dominante.

Término	Definición
Función de Lyapunov	Función escalar de energía $V(x)$, definida positiva y de derivada temporal negativa a lo largo de las trayectorias, cuya existencia certifica la estabilidad sin resolver las ecuaciones del sistema.
Certificado (de estabilidad)	Objeto matemático cuya existencia garantiza formalmente una propiedad del sistema; en esta memoria, el par (Q, Y) que satisface las LMIs de síntesis.
Estabilidad cuadrática	Estabilidad de un sistema LPV certificada por una única función de Lyapunov cuadrática común a todo el dominio de operación; garantiza la estabilidad ante variaciones arbitrariamente rápidas del parámetro.
Polítopo	Envolvente convexa de un conjunto finito de vértices; generaliza el polígono y el poliedro a dimensión arbitraria. En el modelado LPV, encierra todas las condiciones de operación admisibles.
Vértice	Condición operativa extrema del polítopo; la LMI verificada en los N vértices se extiende por convexidad a todo el interior.
Combinación convexa	Suma ponderada con coeficientes no negativos que suman uno; todo punto del polítopo es combinación convexa de sus vértices.
Lazo abierto / lazo cerrado	Topologías de control sin y con realimentación del estado o la salida hacia la entrada de control, respectivamente.
Realimentación de estados	Ley de control $u = Kx$ que mide el vector de estados completo.
Asignación de polos	Modificación de los autovalores del lazo cerrado mediante la elección de la ganancia K .
Transformación de congruencia	Pre y post multiplicación de una desigualdad matricial por una matriz invertible y su transpuesta; preserva el signo de la desigualdad y permite linealizar la BMI de síntesis.
Procedimiento S	Técnica que incorpora restricciones cuadráticas (por ejemplo, la cota de una perturbación) dentro de una LMI mediante multiplicadores no negativos.
Elipsoide invariante	Conjunto $\mathcal{E} = \{x : x^\top Px \leq 1\}$ que las trayectorias no abandonan bajo perturbaciones admisibles; su volumen es un criterio de desempeño.
Tasa de decaimiento	Velocidad mínima garantizada de disipación de la energía del lazo cerrado; se prescribe como el escalar α en la LMI de síntesis.

Término	Definición
Esfuerzo de control	Magnitud de la ganancia del controlador ($\ K\ $); su limitación evita la saturación de actuadores y la amplificación de ruido.
Región factible	Conjunto de variables de decisión que satisface todas las restricciones del problema; para las LMIs, un conjunto convexo.
Frontera de factibilidad	Borde de la región factible, donde el margen de la LMI se anula; los certificados sobre ella degeneran y la ganancia recuperada se dispara.
Condicionamiento	Razón $\kappa = \lambda_{max}/\lambda_{min}$ entre los autovalores extremos de una matriz; mide la excentricidad del elipsoide asociado y la sensibilidad numérica.
Barrera logarítmica	Término de penalización $-\mu \log \det(\cdot)$ que los IPM emplean para mantenerse en el interior estricto de la región factible.

Términos de optimización y aprendizaje profundo

Término	Definición
Proyección ortogonal	Punto de un conjunto convexo más cercano (en norma euclidiana) a un punto dado; operación central de la capa de proyección.
División de operadores (<i>splitting</i>)	Familia de métodos que resuelven un problema sobre la intersección de conjuntos alternando operaciones simples sobre cada conjunto por separado.
Douglas–Rachford	Algoritmo de división que alterna proyecciones y reflexiones sobre dos conjuntos convexos; converge a un punto de la intersección si esta es no vacía.
Levantamiento (<i>lifting</i>)	Introducción de una variable auxiliar que eleva el problema a un espacio de mayor dimensión donde la restricción se descompone en conjuntos con proyecciones cerradas.
Restricciones duras (<i>hard constraints</i>)	Restricciones que la salida de la red satisface por construcción, en oposición a las penalizaciones suaves de la función de pérdida.
<i>Backbone</i>	Red neuronal densa que transforma la descripción del sistema en la predicción cruda de la variable de decisión.
Capa de proyección	Módulo diferenciable que desplaza la predicción cruda de la red hasta el conjunto factible de la LMI.

Término	Definición
Pase hacia adelante (<i>forward pass</i>)	Evaluación de la red y del solucionador de proyección sobre una entrada.
Pase hacia atrás (<i>backward pass</i>)	Cálculo de los gradientes de la pérdida respecto de los pesos mediante retropropagación (<i>backpropagation</i>).
Desenrollado algorítmico (<i>unrolling</i>)	Estrategia de retropropagación que trata cada iteración del solucionador como una capa diferenciable del grafo computacional; su memoria crece con el número de iteraciones.
Diferenciación implícita	Estrategia que calcula el gradiente exacto en el punto fijo del solucionador mediante el Teorema de la Función Implícita, con memoria constante.
Punto fijo	Estado s^* que el operador de iteración deja invariante, $s^* = T(s^*)$; caracteriza la convergencia del solucionador.
Aprendizaje auto-supervisado	Régimen en que la señal de entrenamiento proviene de evaluar la propia restricción y el criterio de desempeño sobre las predicciones, sin etiquetas externas.
Arranque en caliente (<i>warm-start</i>)	Inicialización de un solucionador numérico con una predicción cercana al óptimo para reducir sus iteraciones.
Deep Sets	Familia de arquitecturas invariantes a permutación que procesan conjuntos mediante un codificador por elemento y una agregación simétrica.
Invarianza / equivariancia	Una función es invariante si su salida no cambia ante una transformación de la entrada, y equivariante si su salida se transforma de manera correspondiente.
Sesgo inductivo	Supuesto estructural incorporado en la arquitectura que restringe el espacio de hipótesis y facilita la generalización.
Ficha (<i>token</i>)	Unidad de entrada del codificador; en esta memoria, la representación vectorizada de un vértice o de un par (vértice, actuador).
Función de bisagra (<i>hinge</i>)	Penalización $\text{relu}(\tau - z)$ que se activa solo cuando la cantidad protegida z cae bajo el umbral τ .
Regularización implícita	Efecto regularizador que emerge del procedimiento de optimización (por ejemplo, del truncamiento del desenrollado) sin ser un término explícito de la pérdida.
Normalización de capa (<i>layer normalization</i>)	Estandarización de las activaciones dentro de cada capa que homogeneiza las magnitudes internas de la red.

Término	Definición
Mish	Función de activación suave y no monótona, $x \tanh(\ln(1+e^x))$, empleada en los codificadores propuestos.
Adam	Optimizador de gradiente estocástico con momentos adaptativos, empleado en todos los entrenamientos.
Época	Pasada completa del conjunto de entrenamiento durante el aprendizaje.
Lote (<i>batch</i>)	Subconjunto de sistemas procesado en un mismo paso de entrenamiento.
CVXPY	Lenguaje de modelado de optimización convexa empleado como solucionador exacto de referencia.

Notación: conjuntos, espacios y operadores generales

Símbolo	Descripción
$\mathbb{R}^n, \mathbb{R}^{m \times n}$	Espacio euclidiano real de dimensión n ; espacio de matrices reales de $m \times n$.
$\mathbb{S}^n$	Conjunto de matrices simétricas de $n \times n$.
$\mathbb{C}$	Plano complejo.
I	Matriz identidad (dimensión inferida por contexto).
$(\cdot)^\top$	Transposición de una matriz o vector.
$\text{diag}(\cdot)$	Matriz (bloque-)diagonal construida a partir de sus argumentos.
$\det(\cdot), \text{tr}(\cdot)$	Determinante y traza de una matriz.
$\text{Re}(\cdot), \text{Im}(\cdot)$	Parte real e imaginaria de un número complejo.
$\kappa(\cdot)$	Número de condición de una matriz.
$\lambda_{\min}(\cdot), \lambda_{\max}(\cdot)$	Menor y mayor autovalor de una matriz simétrica.
$\ \cdot\ _2, \ \cdot\ _F$	Norma espectral (matricial) o euclidiana (vectorial); norma de Frobenius.
$\succ 0, \succeq 0$	Matriz definida / semidefinida positiva (análogamente $\prec, \preceq$ para negativa).
$\text{vec}(\cdot), \text{vech}(\cdot)$	Vectorización de una matriz; vectorización de la parte triangular de una matriz simétrica.
$\text{relu}(\cdot)$	Función $\max(0, \cdot)$.
Δ_N	Símplex unitario de dimensión N : $\{\eta \in \mathbb{R}^N : \eta_i \geq 0, \sum_i \eta_i = 1\}$.

Símbolo	Descripción
$\Pi_{\mathcal{C}}(\cdot)$	Operador de proyección ortogonal sobre el conjunto $\mathcal{C}$.

Notación: sistemas dinámicos y modelos politópicos

Símbolo	Descripción
t	Variable temporal continua.
$x(t) \in \mathbb{R}^{n_x}$	Vector de estados; $x_0 = x(0)$ es la condición inicial y $\dot{x}(t)$ su derivada temporal.
$u(t) \in \mathbb{R}^{n_u}$	Vector de entradas de control.
$w(t) \in \mathbb{R}^{n_w}$	Vector de perturbaciones exógenas.
$y(t) \in \mathbb{R}^{n_y}$	Vector de salidas medibles del sistema.
n_x, n_u, n_w, n_y	Orden del sistema; número de actuadores; dimensión de la perturbación; dimensión de la salida.
$f(\cdot), g(\cdot)$	Funciones (posiblemente no lineales) de transición de estado y de salida.
A, B, B_w	Matrices de dinámica interna, de entrada de control y de perturbación exógena (caso LTI).
C, D, D_w	Matriz de salida y matrices de transmisión directa. <i>Nota:</i> la matriz de salida C es distinta de los conjuntos $\mathcal{C}, \mathcal{C}_1, \mathcal{C}_2$ de la capa de proyección.
e^{At}	Matriz exponencial que gobierna la solución libre $x(t) = e^{At}x_0$.
$\lambda_i = \sigma_i + j\omega_i$	Autovalores de una matriz; σ_i y ω_i son sus partes real e imaginaria.
V, Λ, v_i	Matriz de autovectores, matriz diagonal de autovalores y i -ésimo autovector.
$\xi(t) \in \Xi \subset \mathbb{R}^p$	Vector de parámetros de operación del sistema LPV y su conjunto compacto admisible. En la formulación de LMI-Net, ξ denota también el vector que codifica los datos de la instancia (entrada de la red).
N	Número de vértices del polítopo de incertidumbre.
A_i, B_i	Matrices del sistema evaluadas en el vértice i del polítopo, $i \in \{1, \dots, N\}$.
$\eta_i, \eta \in \Delta_N$	Coefficientes de la combinación convexa de vértices, $(A(\eta), B(\eta)) = \sum_i \eta_i (A_i, B_i)$.

Símbolo	Descripción
$\bar{A}$	Matriz promedio de los vértices, usada para medir la dispersión del polítopo.
$K \in \mathbb{R}^{n_u \times n_x}$	Matriz de ganancia del controlador por realimentación de estados, $u = Kx$.
$A_{cl}, A_{cl,i}$	Matriz de lazo cerrado, $A_{cl} = A + BK$; su evaluación en el vértice i , $A_{cl,i} = A_i + B_i K$.
K_{ref}	Ganancia de referencia almacenada en la base de datos UNICAMP.
α	Tasa de decaimiento exponencial prescrita o lograda del lazo cerrado. <i>Nota:</i> reutilizada como tamaño de paso de la búsqueda de línea en el método de punto interior.
γ	Cota de la ganancia H_∞ ; también factor de reescalamiento aplicado en la ingesta de datos, $\gamma = \max(\max A , \max B)$.

Notación: LMIs, síntesis y capa de proyección

Símbolo	Descripción
$P \in \mathbb{S}^n$	Matriz de Lyapunov, $P \succ 0$; define la función $V(x) = x^\top P x$ y su derivada $\dot{V}(x)$.
$Q = P^{-1}$	Inversa de la matriz de Lyapunov; variable de decisión tras la transformación de congruencia.
$Y = KQ$	Variable de decisión lineal que elimina el término bilineal de la síntesis; la ganancia se recupera como $K = YQ^{-1}$.
$F(y), F_0, \dots, F_m$	Matriz afín de una LMI, $F(y) = F_0 + \sum_i y_i F_i$, y sus matrices simétricas constantes.
$F^{(i)}(y)$	Bloque de la LMI asociado al vértice i en la construcción bloque-diagonal politópica.
y, m	Vector de variables de decisión de la LMI y su dimensión. <i>Nota:</i> distinto de la salida del sistema $y(t)$.
$\mathcal{E}(P), \mathcal{E}(Q)$	Elipsoide invariante, $\{x : x^\top P x \leq 1\}$, expresado en la variable original o en $Q = P^{-1}$.
α_s	Multiplicador del procedimiento S en la formulación original de LMI-Net (distinto de la tasa de decaimiento α).

Símbolo	Descripción
$\theta, \hat{y}_\theta$	Pesos entrenables de la red y su predicción cruda (no restringida).
$y^* = \Pi_{\mathcal{C}}(\hat{y}_\theta)$	Salida proyectada sobre el conjunto factible.
$\mathcal{C}, \mathcal{C}_1, \mathcal{C}_2$	Conjunto factible de la LMI y su descomposición: subespacio afín ($\mathcal{C}_1$) y cono semidefinido positivo ($\mathcal{C}_2$).
X, z	Variable matricial auxiliar del levantamiento; variable auxiliar de las iteraciones de Douglas–Rachford.
L, c, M^{-1}	Operador y término constante de la forma vectorizada $\text{vec}(F(y)) = Ly + c$; matriz precomputada $(I + L^\top L)^{-1}$ de la proyección afín.
ϵ	Margen de positividad estricta del certificado ($Q \succeq \epsilon I$). <i>Nota:</i> reutilizado como tolerancia de convergencia en el método de punto interior.
σ	Peso de anclaje (fidelidad) de la iteración de Douglas–Rachford hacia la predicción de la red. <i>Nota:</i> reutilizado como parte real de un autovalor (σ_i) y como factor de reducción de barrera en el método de punto interior.
K_{it}	Número de iteraciones de la capa de proyección (distinto de la ganancia K); en los experimentos, K_{tr} denota el presupuesto de entrenamiento.
T, s^*	Operador de una iteración de Douglas–Rachford y su punto fijo.
J	Jacobiana de la proyección, $\partial y^* / \partial \hat{y}_\theta$. <i>Nota:</i> reutilizada como función de costo del problema de optimización en el método de punto interior.
$\mathcal{L}(\theta)$	Función de pérdida auto-supervisada de entrenamiento.
β_{soft}, μ, τ	Hiperparámetros de las funciones de pérdida: peso del margen espectral (formulación original), pesos de traza y esfuerzo, y piso del menor autovalor de Q .
$c(\cdot), N_{train}$	Criterio de desempeño por sistema y tamaño del conjunto de entrenamiento.
$\phi, \rho, \rho_Q, \rho_Y$	Redes del esquema Deep Sets: codificador por ficha y decodificadores (global, de la cabeza Q y de la cabeza Y). <i>Nota:</i> ρ_{Spearman} denota el coeficiente de correlación de Spearman.
t_{ij}, u_j, z	Ficha del par (vértice i , actuador j); resumen por actuador; resumen global del codificador de actuadores.
b_{ij}	j -ésima columna de la matriz de entrada B_i .

Símbolo	Descripción
Π	Matriz de permutación de actuadores (en la simetría equivariante). <i>Nota:</i> distinta del operador de proyección $\Pi_{\mathcal{C}}$.

Nota sobre símbolos con significado dependiente del contexto

Por economía notacional y en seguimiento de las fuentes citadas, algunos símbolos se reutilizan con significados distintos en secciones diferentes. Los casos se listan a continuación para evitar ambigüedades:

- α : tasa de decaimiento exponencial del lazo cerrado (uso predominante) *versus* tamaño de paso de la búsqueda de línea en el algoritmo de punto interior. El multiplicador del procedimiento S de la formulación original se denota siempre α_s para evitar esta colisión.
- ξ : parámetro de operación del sistema LPV, $\xi(t) \in \Xi$ (Marco Teórico), *versus* vector de datos de la instancia que alimenta a la red en la formulación de LMI-Net. Ambos usos comparten el rol de “parámetro que indexa la familia de problemas”.
- ϵ : margen de positividad estricta del certificado en la capa de proyección *versus* tolerancia de convergencia (brecha de dualidad) en el algoritmo de punto interior.
- σ : peso de anclaje de Douglas–Rachford *versus* parte real de un autovalor (σ_i) *versus* factor de reducción de la barrera en el punto interior.
- ρ : decodificador del esquema Deep Sets *versus* coeficiente de correlación de Spearman (ρ_{Spearman}).
- J : Jacobiana de la proyección *versus* función de costo del problema de optimización LMI en el punto interior.
- y : salida del sistema $y(t)$ *versus* vector de variables de decisión de la LMI ($\hat{y}_\theta, y^*$). El contexto de cada capítulo determina el uso correcto.
- γ : cota de atenuación H_∞ *versus* factor de reescalamiento de la ingesta de datos.
- N : número de vértices del polítopo *versus* tamaño de un conjunto de evaluación cuando se indica explícitamente.

Resumen

La síntesis de controladores robustos para sistemas lineales de parámetros variables (LPV) politópicos se formula clásicamente como un problema de optimización sujeto a Desigualdades Matriciales Lineales (LMIs). Esta formulación ofrece garantías formales de estabilidad, pero resolverla mediante métodos de punto interior resulta costoso cuando debe repetirse sobre familias completas de plantas o bajo restricciones de tiempo real. Esta memoria extiende la arquitectura LMI-Net —una red neuronal con una capa de proyección diferenciable basada en la división de Douglas–Rachford, validada originalmente sobre sistemas invariantes en el tiempo individuales— a la estabilización robusta politópica con tasa de decaimiento prescrita, apilando las N condiciones LMI de vértice y la positividad del certificado en una única restricción bloque-diagonal que la capa de proyección impone por construcción. Se estudian además una escalera de codificadores que incorpora progresivamente las simetrías del problema, dos estrategias de retropropagación a través de la capa de proyección y una familia de seis criterios auto-supervisados.

Un barrido de 443 entrenamientos sobre una base de datos estándar de sistemas robustamente estabilizables muestra que la mejor configuración estabiliza el 97.4% de los sistemas de topologías jamás vistas, con una mediana de cien iteraciones de proyección, y que la proyección por lotes supera entre 5.1 y 16.2 veces la velocidad de un solucionador convexo exacto. El resultado metodológico principal es que el desenrollado truncado supera a la diferenciación implícita en 43.4 puntos porcentuales bajo idéntica función de pérdida y a un costo once veces menor: el truncamiento opera como regularización implícita que aleja los certificados de la frontera del conjunto factible, donde la solución degenera.

Palabras clave: control robusto; sistemas LPV politópicos; desigualdades matriciales lineales; aprendizaje profundo con restricciones duras; capas de proyección diferenciables; división de Douglas–Rachford.

Índice general

Glosario	III
Resumen	XIII
1. Introducción	1
1.1. Contexto y Motivación	1
1.2. Enfoque Propuesto	2
1.3. Estructura del Documento	3
2. Marco Teórico	4
2.1. Teoría de Sistemas Dinámicos y Control	4
2.1.1. Concepto de Sistema, Entradas, Estados y Salidas	4
2.1.2. Preámbulo: Sistemas Lineales Invariantes en el Tiempo (LTI)	5
2.2. Sistemas Lineales de Parámetros Variables (LPV) y Modelos Parametrizados	7
2.2.1. Estabilidad de Sistemas LPV mediante Modelos Politópicos	8
2.3. Desigualdades Matriciales Lineales y Teoría de Lyapunov	9
2.3.1. Fundamentos de las Desigualdades Matriciales Lineales (LMI)	9
2.3.2. El Método Directo de Lyapunov	11
2.3.3. De Lyapunov a LMI	11
2.4. Realimentación	12
2.4.1. El Principio de Realimentación y el Lazo Cerrado	12
2.4.2. Realimentación de Estados y Asignación de Polos	13
2.4.3. Realimentación Estática de Salida	14
2.4.4. El Problema de Síntesis LMI y la No Convexidad	15
2.4.5. Transformación de Congruencia y Linealización de la LMI	16
2.4.6. Control Robusto y Criterios de Desempeño	17
2.5. El Desafío Computacional y Nuevos Paradigmas en Tiempo Real	18
2.5.1. Algoritmos de Punto Interior	18
2.5.2. Nuevos Paradigmas en Tiempo Real	19
2.5.3. Redes Neuronales con Restricciones Duras y Capas de Proyección	19
3. Desarrollo Metodológico	22
3.1. Caracterización de la base de datos	22
3.1.1. Cómo se mide un sistema y su estabilidad	22
3.1.2. Propósito y estructura	22
3.1.3. Sistema en lazo abierto	23
3.1.4. Geometría del politopo	23

3.1.5.	La ley de control y el lazo cerrado	24
3.1.6.	Implicaciones para el aprendizaje	24
3.2.	Formulación Original de LMI-Net	25
3.2.1.	El Problema de Optimización Parametrizada	25
3.2.2.	Visión General de la Arquitectura	26
3.2.3.	Problema de Referencia: Diseño Conjunto de Controlador y Elipsoide Invariante	26
3.2.4.	Levantamiento del Espacio de Restricciones	27
3.2.5.	Pase hacia Adelante: Algoritmo de Douglas-Rachford	27
3.2.6.	Pase hacia Atrás: Diferenciación Implícita	28
3.2.7.	Configuración de Entrenamiento de la Formulación Original	29
3.2.8.	Limitaciones de la Formulación Original	30
3.3.	Extensión a la Estabilización Robusta de Sistemas Politépicos	31
3.3.1.	Estabilidad Cuadrática con Tasa de Decaimiento	31
3.3.2.	Construcción Bloque-Diagonal	31
3.3.3.	Adaptación del Problema de Referencia	32
3.4.	Arquitecturas de Codificación del Polítopo	32
3.4.1.	El Polítopo como Conjunto: Asimetría entre Entrada y Salida	32
3.4.2.	Codificador Aplanado	33
3.4.3.	Invarianza de Conjunto sobre los Vértices	33
3.4.4.	Arquitectura Propuesta: Codificador de Actuadores en Dos Ejes	33
3.4.5.	Elementos Comunes de Implementación	35
3.5.	Desenrollado frente a Diferenciación Implícita	35
3.6.	Funciones de Pérdida	36
3.6.1.	Criterio de Referencia: Volumen con Margen Lineal (paper)	36
3.6.2.	Criterio de Volumen y Esfuerzo Sustituto (control)	36
3.6.3.	Criterio de Volumen con Piso Espectral (control_margen)	37
3.6.4.	Criterio de Esfuerzo de Control Efectivo (esfuerzo)	37
3.6.5.	Criterio de Condicionamiento del Certificado (condicionamiento)	37
3.6.6.	Criterio de Margen Normalizado (margen_norm)	38
3.6.7.	Síntesis de la Familia de Criterios	38
4.	Experimentos y Resultados	39
4.1.	Diseño Experimental	40
4.1.1.	Protocolo General y Configuración Base	40
4.1.2.	Etapas del Barrido y Preguntas Asociadas	40
4.1.3.	Escenarios de Evaluación	41
4.1.4.	Métricas	42
4.2.	Resultados del Barrido Principal	43
4.2.1.	Efecto de la Función de Pérdida	43
4.2.2.	Truncamiento como Regularización	44
4.2.3.	Efecto de la Tasa de Decaimiento Prescrita	44

4.2.4.	Mejor Configuración Global	45
4.2.5.	Hiperparámetros de la Capa de Proyección	45
4.2.6.	La Geometría de la Frontera como Hilo Conductor	46
4.3.	Escalamiento en Orden y Eficiencia de Datos	46
4.3.1.	Efecto del Orden del Sistema (E2)	46
4.3.2.	Curva de Eficiencia de Datos (E3)	47
4.4.	Arquitecturas e Invarianza Estructural	47
4.5.	Unrolling frente a Diferenciación Implícita	48
4.5.1.	Puesta a Prueba del Mecanismo Propuesto	48
4.6.	Douglas–Rachford frente al Solver Convexo	49
4.6.1.	Velocidad y Escalamiento	49
4.6.2.	El Valor del Codificador	50
4.6.3.	Caracterización de los Fallos del solver	50
4.7.	Evaluación <i>Out-of-Distribution</i>	50
4.7.1.	Protocolo	51
4.7.2.	Resultados Agregados	51
4.7.3.	Anatomía de un Colapso: <code>margen_norm</code> sobre el Polítopo de Vértice Marginal	52
4.7.4.	Firma del Encoder	52
4.7.5.	Costo Temporal en la Instancia Adversarial	53
4.8.	Costos Computacionales	53
4.9.	Limitaciones y consideraciones	54
4.10.	Configuración del <i>Benchmark</i>	55
4.10.1.	Plataforma de Cómputo	55
4.10.2.	Costo Total del Barrido	55
5.	Conclusiones y Trabajo Futuro	56
5.1.	Conclusiones	56
5.2.	Trabajo Futuro	57
5.2.1.	Meta-Controlador Agnóstico al Orden del Sistema	58
5.2.2.	Clases de Sistemas Más Amplias	58
5.2.3.	Anclaje Adaptativo y Frontera del Óptimo	60
5.2.4.	Visualización de la Geometría del Polítopo y del Conjunto Factible	60
A.	Figuras, Tablas y Algoritmos	64
A.1.	Capítulo 2: Marco Teórico	64
A.2.	Capítulo 3: Desarrollo Metodológico	68
A.3.	Capítulo 4: Estudio Experimental	77

Índice de tablas

A.1. Glosario de indicadores usados en el análisis.	68
A.2. Esquema de la base de datos. Cada sistema es un politopo de N vértices con una ganancia robusta K	68
A.3. Resumen de descriptores sobre los 14 000 sistemas (datos crudos, sin normalizar). . .	72
A.4. Configuración de entrenamiento de la formulación original de LMI-Net [28].	73
A.5. Correspondencia entre la instancia original de LMI-Net y la extensión politópica de esta memoria	74
A.6. Síntesis de la escalera arquitectónica. La columna final indica cuántas redes independientes exige cubrir las 28 celdas topológicas (n_x, n_u, N) de la base de datos.	75
A.7. Comparación entre las dos estrategias de retropropagación	75
A.8. Registro de las seis funciones de pérdida estudiadas. Todas se evalúan sobre el certificado proyectado (Q, Y) y se minimizan.	76
A.9. Estructura del barrido experimental. Las etapas E1–E4 son entrenamientos; E5 y la comparación de solvers evalúan modelos ya entrenados. Todas las celdas no mencionadas permanecen en la configuración base (codificador de actuadores, $n_x = 3$, <i>unrolling</i> con $K_{tr} = 30$, $\alpha = 0.01$, 150 sistemas, 2 semillas).	77
A.10.Efecto marginal de la función de pérdida sobre el escenario estructural (S2), promediando sobre los restantes ejes del barrido principal. Época 400, presupuesto de inferencia 8000.	78
A.11.Efecto del presupuesto de <i>unrolling</i> en entrenamiento sobre el escenario estructural (S2). La última fila corresponde a la rama de diferenciación implícita, que itera hasta convergencia y constituye el caso límite del <i>unrolling</i> profundo.	78
A.12.Efecto de la tasa de decaimiento prescrita α sobre el escenario estructural (S2). . . .	79
A.13.Mejor configuración global frente a la receta de la formulación original, ambas con codificador de actuadores. La columna intermedia aísla el efecto del gradiente, pues conserva la pérdida original y solo cambia la estrategia de <i>backpropagation</i> . Métrica de referencia correspondiente al % estabilizado en el escenario estructural (S2), época 400, presupuesto 8000, promedio sobre semillas.	80
A.14.Descomposición por celda topológica (n_u, N) del desempeño de la mejor configuración, época 400, presupuesto 8000, promedio sobre semillas. El factor que ordena las celdas es el número de actuadores, no la cardinalidad del polítopo ni la pertenencia al escenario.	80
A.15.Curva de eficiencia de datos sobre el escenario estructural (S2), bajo configuración base (codificador de actuadores, $n_x = 3$, $K_{tr} = 30$, $\alpha = 0.01$), promedio sobre las seis pérdidas y dos semillas. La celda de 150 sistemas proviene de la misma configuración controlada del contraste de arquitecturas (E4).	83

A.16.	Contraste de arquitecturas sobre el escenario estructural S2, % estabilizado promedio sobre las seis pérdidas y dos semillas, configuración base controlada. Los dos codificadores no evalúan el mismo conjunto: el de actuadores cubre las cinco celdas de S2 (2500 sistemas), mientras que el de vértices, invariante a N pero no a n_u , solo admite como entrada la celda ($n_u=1, N=5$) (500 sistemas), que es además la más difícil del escenario. Las dos últimas columnas restringen la comparación a esa celda común. En $n_x = 2$ ambas lecturas coinciden porque la base no contiene celdas de dos actuadores en ese orden. La línea base aplanada no aparece porque su entrada de dimensión fija no puede procesar ninguna topología retenida.	83
A.17.	Contraste de arquitecturas sobre el escenario en distribución S1 (topologías vistas), % estabilizado promedio sobre las seis pérdidas y dos semillas, configuración base controlada. Cada arquitectura se evalúa sobre la partición de prueba de las celdas en que fue entrenada, de modo que los codificadores invariantes cubren tres celdas (300 sistemas) y la línea base aplanada una sola, ($n_u=1, N=2$) (100 sistemas); la comparación mide por tanto el desempeño de cada arquitectura en su propio régimen y no un contraste sobre sistemas idénticos.	83
A.18.	Comparación entre estrategias de <i>backpropagation</i> sobre el escenario estructural (S2), marginando sobre el resto del barrido principal, junto a su costo de entrenamiento. El <i>unrolling</i> reporta su mejor presupuesto ($K_{tr} = 30$) y su marginal completo.	84
A.19.	Douglas–Rachford por lotes frente a CVXPY, por cardinalidad del polítopo ($n_x = 3$, 200 sistemas por celda, partida aleatoria para DR). Tiempos por sistema; la aceleración se calcula respecto del presupuesto de 4000 iteraciones.	84
A.20.	Techo de factibilidad del banco de desplazamiento de polos según el solver convexo ($\alpha = 0.01$). La LMI admite certificado en toda la rampa; lo que se degrada es el condicionamiento de ese certificado, y el peor autovalor de lazo cerrado se ancla en la tasa prescrita.	85
A.21.	Evaluación <i>out-of-distribution</i> de los modelos de la rama de <i>unrolling</i> , con presupuesto de inferencia de 8000 iteraciones. Para cada banco se reporta el promedio del % estabilizado a lo largo de la rampa completa y la fracción de puntos de la rampa resueltos al 100 %. En ambos bancos el solver convexo certifica factibilidad en toda la rampa, de modo que el techo alcanzable es 100 en las cuatro columnas y toda diferencia es atribuible al método. El banco del vértice marginal promedia 4 réplicas de modelo por punto y el de desplazamiento, 44.	86
A.22.	Anatomía del colapso sobre el polítopo de vértice marginal. Para cada nivel de deriva se reporta la fracción de réplicas (modelos $\times$ semillas) que estabiliza, el peor condicionamiento del certificado final y el peor autovalor de lazo cerrado entre las réplicas, junto al comportamiento de <code>control_margen</code> bajo el mismo protocolo. La factibilidad según el solver convexo se mantiene en toda la rampa.	87
A.23.	Plataforma de cómputo empleada en la totalidad de los experimentos.	90

A.24.Costo computacional agregado del barrido, en horas de procesador. Las corridas de diferenciación implícita concentran dos tercios del cómputo pese a representar el 13 % del total.	91
A.25.Distribución del espectro de J_s en el punto fijo y proyección de la señal de entrenamiento por banda, promediada sobre los sistemas evaluados. El operador de Douglas–Rachford es firmemente no expansivo, de modo que $\rho(J_s) \leq 1$ por construcción. . . .	91
A.26.Barrido cruzado del peso de anclaje y el margen de positividad sobre el escenario estructural (S2), época 400, presupuesto 8000, promedio sobre las seis pérdidas y dos semillas. La celda sombreada es la configuración heredada de la formulación original para los codificadores invariantes.	92
A.27.Contraste de arquitecturas a margen de positividad igualado ($\sigma_{anc} = 0.01$, resto en configuración base), % estabilizado promedio sobre las seis pérdidas y dos semillas. La formulación original fija $\epsilon_{pos} = 10^{-3}$ para la línea base aplanada y 10^{-5} para los codificadores invariantes, de modo que el contraste heredado enfrenta las celdas en <i>diagonal</i> : 95.00 contra 91.25, esto es, los 3.75 puntos que la Sección 4.4 atribuía a la arquitectura. Léida por columnas, a ϵ_{pos} igualado, la ventaja de la línea base se reduce a 0.67 y 0.83 puntos. La línea base no admite evaluación en S2 por imposibilidad estructural.	92

Índice de figuras

3.1. Flujo de la arquitectura LMI-Net en su formulación original [28]: el <i>backbone</i> propone una estimación cruda $\hat{y}_\theta$ que la capa de proyección corrige hasta satisfacer la LMI por construcción.	26
A.1. Representación espectral de la estabilidad en el plano complejo $\mathbb{C}$. El semiplano izquierdo representa el espacio geométrico donde los autovalores de una matriz de Hurwitz inducen trayectorias dinámicas asintóticamente convergentes a cero.	64
A.2. Representación geométrica de un polítopo paramétrico en 2D. Las líneas punteadas representan los límites físicos o restricciones operativas del sistema. La intersección de estos límites define los vértices (A_i) , correspondientes a las condiciones operativas extremas. Cualquier variación en el tiempo del sistema físico $(\xi(t))$ queda contenida de forma segura dentro de la región azul, expresable como combinación convexa de sus vértices.	65
A.3. Interpretación geométrica de la matriz de Lyapunov P mediante sus vectores propios (v_1, v_2) y la influencia de los signos de sus autovalores en el confinamiento del espacio de estados $\mathbb{R}^2$	65
A.4. Esquema de realimentación de estados aplicado al sistema politópico. El controlador estático K mide el vector de estado $x(t)$ y genera la señal de control $u(t) = Kx(t)$, que se reinyecta a la planta para conformar la dinámica en lazo cerrado $\dot{x} = (A(\xi) + B(\xi)K)x$. Nótese que la misma ganancia K debe estabilizar la planta para toda variación admisible de $\xi(t)$	66
A.5. Abscisa espectral del peor vértice. La planta es inestable (rojo, $\text{Re } \lambda > 0$) en el 98.8 % de los casos; bajo la ganancia K el lazo cerrado es estable en el 100 % (inset azul, todos < 0).	69
A.6. Distribución de $\ K\ _2$, $\max_i \ A_i\ _2$ y $\max_i \ B_i\ _2$ por orden n_x . El esfuerzo de control y la norma de la planta crecen con el orden.	69
A.7. Tamaño del politopo $\max_i \ A_i - \bar{A}\ _2$ frente al número de vértices N . La incertidumbre crece con N	70
A.8. Tasa de decaimiento lograda α (escala log). El 84.9 % de los sistemas queda casi marginal ($\alpha < 10^{-2}$); una minoría exhibe márgenes grandes. La distribución es bimodal.	70
A.9. Autovalores de los vértices en el plano complejo (escala symlog en el eje real). La planta en lazo abierto (rojo) se extiende al semiplano derecho; el lazo cerrado (azul) queda íntegramente a la izquierda, con el polo dominante junto al eje.	71
A.10. Correlaciones de Spearman entre descriptores. $\ K\ $ sigue a $\ A\ $ y a la dispersión del politopo; la tasa de decaimiento α no correlaciona con ningún descriptor.	71

A.11. Ilustración esquemática (no a escala) de la convergencia del algoritmo de Douglas–Rachford: partiendo de una predicción $\hat{y}_\theta$ fuera de la región factible, las proyecciones alternadas sobre el subespacio afín $\mathcal{C}_1$ y el cono $\mathcal{C}_2$ generan una trayectoria en zigzag de amplitud decreciente que converge al punto factible $y^* \in \mathcal{C}_1 \cap \mathcal{C}_2$	73
A.12. Interpretación geométrica (esquema no a escala) del criterio de volumen $\log \det(Q)$. El elipsoide invariante $\mathcal{E}(Q)$ es la región que el certificado garantiza que las trayectorias no abandonan. Con un certificado holgado (a), la garantía admite excursiones amplias del estado; al minimizar el volumen (b), la misma garantía confina las trayectorias en la vecindad más compacta posible del equilibrio, lo que se traduce en un rechazo más estricto de las perturbaciones.	74
A.13. Flujo del codificador de actuadores para un ejemplo con $N = 2$ vértices y $n_u = 2$ actuadores. Cada ficha t_{ij} empareja la dinámica de un vértice con una columna de su matriz de entrada; la red compartida ϕ y los dos promedios sucesivos producen un resumen por actuador (u_j) y uno global (z); la cabeza partida genera la mitad invariante del certificado desde z y cada fila de Y desde su actuador correspondiente.	75
A.14. Escenarios de evaluación. El escenario S1 mide generalización estadística sobre topologías vistas; el escenario S2 mide generalización estructural a topologías jamás observadas, para lo cual el codificador debe capturar la estructura de conjunto del polítopo y no memorizar topologías particulares; el escenario S3 somete los modelos ya entrenados a deriva paramétrica <i>out-of-distribution</i> , con el solver convexo como <i>ground truth</i> de factibilidad y con Douglas–Rachford desde una inicialización aleatoria como control que aísla al codificador.	77
A.15. Porcentaje de sistemas estabilizados en función del presupuesto de inferencia de Douglas–Rachford, por función de pérdida (época 400, promedio sobre configuraciones de E1). El ordenamiento entre pérdidas es estable en todo el rango de presupuestos y consistente entre ambos escenarios, lo que indica que la ventaja de los criterios sensibles a la frontera no depende del punto de operación elegido.	78
A.16. Esquema conceptual (no a escala) del truncamiento como regularización implícita: con <i>unrolling</i> truncado (a), el gradiente refleja un punto interior y la red es recompensada por proponer $\hat{y}$ cuya proyección superficial ya es un certificado interior; con <i>unrolling</i> profundo o diferenciación implícita (b), el gradiente refleja el punto de convergencia sobre la frontera y el codificador deriva hacia certificados de margen nulo.	79
A.17. Esquema conceptual (no a escala) de la geometría del conjunto factible $\mathcal{C}$ de la LMI politópica y de las fuerzas que cada familia de criterios ejerce sobre el certificado. Los criterios de volumen puro atraen la solución hacia la frontera, cuyo extremo degenerado corresponde a Q casi singular con $\kappa(Q)$ y $\ K\ $ divergentes; los términos de margen la repelen hacia el interior; y los criterios de calidad del certificado penalizan las esquinas sin fijar la distancia a la frontera. La posición del óptimo de cada pérdida dentro de esta geometría explica los ordenamientos de las Tablas A.10 y A.11.	81

A.18.	Contraparte <i>computada</i> de la Figura A.17, sobre una instancia real del pol�topo de v�rtice marginal en su valor nominal ($\delta = 0$), con el codificador de actuadores entrenado con margen_norm . Para $n_x = 2$ el espacio de decisi�n tiene dimensi�n cinco, de modo que se representa el corte de $\mathcal{C}$ por el plano de las dos componentes principales de la nube formada por $\hat{y}$, la trayectoria completa del solucionador, y^* y y_{cvx} ; dicho plano recoge el 98.2 % de la varianza de esa nube. La regi�n coloreada es $\{y : \lambda_{\min}(F(y)) \geq 0\}$ evaluada exactamente sobre una malla de 460×460 puntos, y su color indica el condicionamiento $\kappa(Q)$ del certificado en cada punto. Tres hechos cuantitativos sustituyen aqu� a la intuici�n del esquema. Primero, y^* se sit�a exactamente en el v�rtice de la cu�a factible, que es la esquina que el argumento geom�trico postula. Segundo, la salida del solucionador y el certificado convexo de referencia distan 2.1×10^{-5} , por lo que ambos marcadores se superponen y Douglas–Rachford alcanza en la pr�ctica el mismo punto que el solucionador exacto. Tercero, los criterios de desempe�o ejercen fuerzas de direcciones distintas sobre el certificado, con control y condicionamiento apuntando fuera del conjunto factible. Los gradientes se dibujan normalizados, de modo que la figura informa su direcci�n y no su magnitud, y tanto ellos como la trayectoria son proyecciones sobre el plano de corte; la componente de $\hat{y}$ fuera de dicho plano es 1.5×10^{-2} . La trayectoria mostrada corresponde a la proyecci�n final $\Pi_{\mathcal{C}_1}$ en cada iteraci�n, que es la salida que el codificador efectivamente recibe.	82
A.19.	Comparaci�n de solvers. A la izquierda, el costo por sistema de Douglas–Rachford por lotes crece suavemente con el presupuesto y con N , mientras que el solver de punto interior (l�neas punteadas) parte m�s de un orden de magnitud por encima y escala peor con la cardinalidad. A la derecha, CVXPY certifica el 100 % de los sistemas y define el techo de factibilidad que Douglas–Rachford aproxima al aumentar el presupuesto.	84
A.20.	Descriptores de los sistemas que Douglas–Rachford no estabiliza desde partida aleatoria, contrastados con los estabilizados. Los fallos se concentran en sistemas con matrices peor condicionadas, pol�topos m�s dispersos y mayor abscisa espectral de lazo abierto.	85
A.21.	Presupuesto m�nimo de estabilizaci�n en funci�n de la deriva δ sobre el pol�topo de v�rtice marginal, por funci�n de p�rdida, junto al control de Douglas–Rachford desde propuesta aleatoria. El costo crece con δ para todas las p�rdidas conforme la regi�n factible se estrecha, con la excepci�n del colapso intermitente de margen_norm , cuyos puntos faltantes o extremos corresponden a instancias no estabilizadas dentro del presupuesto m�ximo.	86

A.22.	Evolución del certificado final sobre la rampa del polítopo de vértice marginal. El condicionamiento $\kappa(Q^*)$ de <code>margen_norm</code> salta órdenes de magnitud a partir de $\delta \approx 1$ y su peor autovalor de lazo cerrado cruza al semiplano derecho, mientras que las pérdidas restantes degradan su condicionamiento de forma suave y mantienen el espectro estable. La pérdida <code>esfuerzo</code> exhibe una degeneración intermedia, con $\kappa(Q^*)$ creciendo silenciosamente hasta el orden de 10^5 sin fallo inmediato.	87
A.23.	Firma del mecanismo de fallo. Para tres niveles de deriva se muestra el peor autovalor de lazo cerrado (arriba) y el residual del solver (abajo) en función de la iteración, partiendo de la propuesta de la red y de una propuesta aleatoria. La meseta del residual aparece solo con la propuesta de la red, lo que atribuye el fallo al codificador y no al solver.	88
A.24.	Esquema conceptual (no a escala) del mecanismo de colapso de <code>margen_norm</code> . En el nominal (a), el codificador apunta al punto de margen máximo y la proyección converge en pocas iteraciones; bajo deriva (b), el conjunto factible se adelgaza precisamente en la dirección del sesgo aprendido, la proyección se arrastra por la zona angosta —la meseta del residual de la Figura A.23— y el certificado degenera, mientras que una propuesta aleatoria, sin sesgo direccional, proyecta sobre la parte ancha y estabiliza.	88
A.25.	Tiempo hasta estabilizar la instancia del vértice marginal en función de la deriva, para la red (mejor réplica que estabiliza) y para el solver convexo. En instancias individuales pequeñas el solver exacto es más rápido; la ventaja del método propuesto aparece en el régimen por lotes de la Figura A.19.	89
A.26.	Tiempo de inferencia por sistema en función del presupuesto de Douglas–Rachford. El crecimiento esencialmente lineal permite tratar el presupuesto como una perilla de compromiso entre latencia y tasa de éxito, calibrable con las curvas de la Figura A.15.	89
A.27.	Costo de entrenamiento por función de pérdida, promediado sobre las configuraciones (E1: cuatro tasas α y dos semillas por celda). El eje logarítmico del panel izquierdo hace visibles los dos regímenes a la vez: el presupuesto de <i>unrolling</i> hace variar el tiempo por corrida en un factor de cincuenta, y la diferenciación implícita lo multiplica otras cuatro veces sobre el <i>unrolling</i> más profundo, mientras que la elección del criterio apenas mueve el costo dentro de cada régimen, un 4.1 % de dispersión en tiempo y un 12 % en memoria. La memoria pico es indiferente tanto al criterio como a la estrategia de gradiente, y se mantiene por debajo de los 700 MB en todos los casos.	90

1. Introducción

1.1. Contexto y Motivación

Los Sistemas Ciberfísicos (CPS, por sus siglas en inglés) integran estrechamente las capacidades de computación, comunicación y control para interactuar con procesos físicos en el mundo real. Asegurar la estabilidad de estos sistemas ante perturbaciones externas o incertidumbres en los parámetros es uno de los desafíos más críticos de la ingeniería. Las consecuencias de una estabilización deficiente están ampliamente documentadas: el apagón del noreste de Norteamérica de 2003, donde una combinación de fallas locales y lazos de control mal coordinados derivó en una inestabilidad de tensión en cascada que dejó sin suministro a unos 50 millones de personas [30]; o los escenarios de control en red sometidos a ataques de inyección de datos falsos y secuestro de actuadores, capaces de desestabilizar la planta física aunque cada componente parezca operar dentro de sus márgenes nominales [10, 25].

En el ámbito de los sistemas dinámicos, la estabilidad se define como la propiedad de un sistema de retornar a un estado de equilibrio, o de permanecer confinado dentro de una región segura, tras ser sometido a una perturbación. El diseño de controladores con garantías formales de estabilidad se aborda tradicionalmente postulando funciones candidatas de Lyapunov sobre un modelo matemático del proceso, las cuales actúan como certificados de que la energía del sistema se disipa continuamente hacia el equilibrio. Cuando el proceso opera bajo condiciones cambiantes, por ejemplo desgaste, variaciones de carga, cambios de punto de operación o anomalías, el modelo adecuado deja de ser una única planta lineal y pasa a ser un *Sistema Lineal de Parámetros Variables* (LPV), cuya representación politópica encierra todas las condiciones de operación admisibles dentro de la envolvente convexa de un conjunto finito de vértices.

Mediante herramientas clásicas de la teoría de control robusto, las condiciones de estabilidad de Lyapunov para estas familias de sistemas se reestructuran algebraicamente hasta adoptar la forma de *Desigualdades Matriciales Lineales* (LMIs, por sus siglas en inglés): restricciones convexas sobre una matriz de certificado y una ganancia de control que, de satisfacerse simultáneamente en todos los vértices del polítopo, garantizan la estabilidad para *toda* trayectoria admisible de los parámetros. Esta formulación posee sólidas garantías teóricas a costa de un alto costo computacional. Resolver cada instancia mediante los solucionadores numéricos convencionales como los métodos de punto interior que exigen factorizar matrices densas en cada iteración lo que conlleva una complejidad que escala pobremente con la dimensión del problema y el número de vértices. Esto resulta especialmente limitante en los CPS modernos, donde las condiciones de operación varían dinámicamente y las decisiones de control deben tomarse en cuestión de milisegundos.

La tensión entre ambos extremos define el problema central de esta memoria: los métodos exactos

ofrecen garantías pero no velocidad, mientras que los modelos de aprendizaje profundo ofrecen inferencia casi instantánea pero, por sí solos, ninguna garantía.

1.2. Enfoque Propuesto

Los avances recientes en aprendizaje automático aplicado a optimización han comenzado a cerrar esta brecha. Existen propuestas orientadas al aprendizaje de extremo a extremo para generar arranques en caliente (*warm-start*) que aceleran la optimización en tiempo real [26], así como métodos basados en capas de proyección y parametrizaciones convexas que imponen restricciones duras directamente sobre la salida de la red [16, 29, 22]. Dentro de esta línea, la arquitectura *LMI-Net*, propuesta por Tang, Goertzen y Azizan [28], incorpora una capa de proyección diferenciable basada en la división de Douglas–Rachford que fuerza, de manera estricta y por construcción, el cumplimiento de restricciones LMI sobre las salidas de la red. El enfoque sigue una descomposición *offline-online*, lo que significa que el grueso del cómputo se traslada a una fase de entrenamiento previa, de modo que resolver un sistema nuevo se reduce a una inferencia de la red seguida de la proyección, sin violar bajo ninguna circunstancia las restricciones de estabilidad.

La formulación original de *LMI-Net*, sin embargo, fue propuesta y validada únicamente sobre sistemas lineales invariantes en el tiempo (LTI) individuales y de baja dimensión. El aporte de esta memoria de título consiste en extender dicha arquitectura al problema de la estabilización robusta de sistemas LPV politópicos: sintetizar, para cada familia de plantas descrita por sus vértices, una única ganancia y un único certificado de Lyapunov válidos para todo el polítopo, apilando las condiciones de vértice en una restricción bloque-diagonal que la misma capa de proyección impone por construcción.

Las contribuciones principales de este trabajo son las siguientes:

1. **Extensión politópica de *LMI-Net*.** Se formula e implementa la generalización de la arquitectura al caso de estabilización robusta con tasa de decaimiento prescrita, mediante la construcción bloque-diagonal de las N LMIs de vértice más la condición de positividad del certificado, preservando íntegra la capa de proyección original.
2. **Codificadores con las simetrías del problema.** Se diseñan y comparan tres arquitecturas de codificación del polítopo —la línea base aplanada del trabajo original, un codificador de conjunto invariante a la permutación y cardinalidad de los vértices, y un codificador que añade la equivariancia respecto de los actuadores—, y se cuantifica el valor de cada simetría para la generalización a topologías no vistas.
3. **Estudio de la estrategia de retropropagación.** Se implementa el desenrollado algorítmico truncado como alternativa a la diferenciación implícita de la formulación original, y se caracteriza empíricamente una interacción no evidente entre la exactitud del gradiente, la función de pérdida y la geometría de la frontera del conjunto factible.
4. **Familia de criterios de desempeño.** Se estudia una familia de seis funciones de pér-

dida auto-supervisadas, fundamentadas en criterios clásicos de la síntesis LMI —volumen del elipsoide invariante, esfuerzo de control, condicionamiento del certificado y margen de factibilidad—, y se evalúa su efecto sobre la calidad del certificado dentro y fuera de la distribución de entrenamiento.

5. **Evaluación empírica exhaustiva.** Se valida la propuesta sobre una base de datos estándar de sistemas politópicos robustamente estabilizables, mediante un barrido experimental que separa la generalización estadística, la generalización estructural a topologías no vistas y la robustez ante deriva paramétrica, contrastando siempre contra un solucionador convexo exacto como referencia de factibilidad.

1.3. Estructura del Documento

El resto del documento se organiza de la siguiente manera. El Capítulo 2 desarrolla el marco teórico desde sus fundamentos: la representación de sistemas dinámicos en el espacio de estados, los sistemas LPV y su modelación politópica, la teoría de Lyapunov y su traducción a LMIs, la síntesis de control por realimentación y el desafío computacional que motiva los nuevos paradigmas de tiempo real. El Capítulo 3 presenta el desarrollo metodológico: la caracterización de la base de datos, la formulación original de LMI-Net, su extensión politópica, las arquitecturas de codificación, las estrategias de retropropagación y la familia de funciones de pérdida. El Capítulo 4 reporta el diseño y los resultados del estudio experimental, y el Capítulo 5 sintetiza las conclusiones y las líneas de trabajo futuro.

2. Marco Teórico

2.1. Teoría de Sistemas Dinámicos y Control

El análisis y diseño de Sistemas Ciberfísicos (CPS) requiere una modelación matemática rigurosa de los procesos físicos involucrados. En esta sección, se establecen las definiciones fundamentales de la teoría de sistemas orientada al control continuo, estructurando las nociones de variables dinámicas, clasificaciones de sistemas y sus representaciones matemáticas.

2.1.1. Concepto de Sistema, Entradas, Estados y Salidas

Desde la perspectiva de la teoría de control, un *sistema* es una entidad abstracta o física que procesa señales de entrada para producir señales de salida a lo largo del tiempo. Matemáticamente, este comportamiento se describe mediante una representación en el **espacio de estados**, la cual modela la dinámica interna del proceso a través de un conjunto de variables de primer orden de la siguiente forma:

$$\dot{x}(t) = f(x(t), u(t), w(t), t) \quad (2.1)$$

$$y(t) = g(x(t), u(t), w(t), t) \quad (2.2)$$

Donde las variables e interacciones principales se definen formalmente como:

- **Vector de Estados** ($x(t) \in \mathbb{R}^{n_x}$): Representa la memoria interna del sistema, con n_x el orden o dimensión del sistema. Contiene el conjunto mínimo de variables independientes cuyo conocimiento en un instante inicial t_0 , junto con las entradas aplicadas para $t \geq t_0$, determina unívocamente el comportamiento futuro del sistema.
- **Vector de Entradas de Control** ($u(t) \in \mathbb{R}^{n_u}$): Representa las señales de actuación que el diseñador o controlador puede manipular directamente para modificar la trayectoria de los estados del sistema, con n_u el número de actuadores disponibles.
- **Vector de Perturbaciones** ($w(t) \in \mathbb{R}^{n_w}$): Representa señales exógenas no controlables que afectan la dinámica del proceso físico. Estas señales modelan ruidos ambientales, errores de modelado o fuerzas externas imprevistas.
- **Vector de Salidas** ($y(t) \in \mathbb{R}^{n_y}$): Representa las variables medibles o de interés operativo del sistema. Comúnmente corresponde a combinaciones de los estados que son capturadas por sensores.

Las Ecuaciones (2.1)-(2.2) son completamente generales y admiten dinámicas no lineales arbitrarias a través de las funciones $f(\cdot)$ y $g(\cdot)$. La siguiente subsección presenta, a modo de preámbulo, el caso particular en que estas funciones son lineales y no dependen del tiempo; este caso clásico permite introducir con la menor complejidad posible las nociones de estabilidad y de función de Lyapunov que, más adelante, se generalizarán al caso de interés de esta memoria: los sistemas con parámetros variables en el tiempo.

2.1.2. Preámbulo: Sistemas Lineales Invariantes en el Tiempo (LTI)

Un sistema dinámico se clasifica como *Lineal Invariante en el Tiempo* (LTI, por sus siglas en inglés) si satisface los principios de superposición (homogeneidad y aditividad) y sus parámetros internos no varían de manera explícita con respecto al tiempo. En el espacio de estados continuo, un sistema lineal acoplado con entradas de control y señales de perturbación adopta la siguiente estructura matricial compacta:

$$\dot{x}(t) = Ax(t) + Bu(t) + B_w w(t) \quad (2.3)$$

$$y(t) = Cx(t) + Du(t) + D_w w(t) \quad (2.4)$$

Donde las componentes deterministas del sistema están representadas por matrices de dimensiones apropiadas:

- $A \in \mathbb{R}^{n_x \times n_x}$ es la matriz del sistema o matriz de dinámica interna.
- $B \in \mathbb{R}^{n_x \times n_u}$ es la matriz de entrada de control.
- $B_w \in \mathbb{R}^{n_x \times n_w}$ es la matriz de perturbación exógena.
- $C \in \mathbb{R}^{n_y \times n_x}$ es la matriz de salida o de observación.
- $D \in \mathbb{R}^{n_y \times n_u}$ y $D_w \in \mathbb{R}^{n_y \times n_w}$ son las matrices de transmisión directa.

Un concepto central para los sistemas LTI es la *estabilidad asintótica*. En ausencia de entradas ($u(t) = 0, w(t) = 0$), la dinámica autónoma del sistema queda definida exclusivamente por la ecuación diferencial lineal homogénea $\dot{x}(t) = Ax(t)$. La solución analítica de este sistema, dada una condición inicial $x(0) = x_0$, viene determinada por la matriz exponencial:

$$x(t) = e^{At} x_0 \quad (2.5)$$

Para comprender el comportamiento cualitativo de esta solución, se recurre al análisis espectral de la matriz del sistema A . Los valores propios (o autovalores) λ_i de A son las raíces del polinomio característico definido por $\det(\lambda I - A) = 0$. En el caso general, estos valores propios pueden ser reales o complejos conjugados, adoptando la forma:

$$\lambda_i = \sigma_i + j\omega_i \quad (2.6)$$

donde $\sigma_i = \text{Re}(\lambda_i)$ representa la parte real y $\omega_i = \text{Im}(\lambda_i)$ la parte imaginaria. Si la matriz A es diagonalizable, existe una matriz de transformación de similitud V compuesta por los vectores propios de A tal que $A = V\Lambda V^{-1}$, donde $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{n_x})$. Bajo este cambio de coordenadas, la respuesta temporal del sistema se puede descomponer como una combinación lineal de los modos dinámicos individuales:

$$x(t) = \sum_{i=1}^{n_x} v_i c_i e^{\lambda_i t} = \sum_{i=1}^{n_x} v_i c_i e^{\sigma_i t} (\cos(\omega_i t) + j \sin(\omega_i t)) \quad (2.7)$$

donde v_i representan los vectores propios y c_i son constantes que dependen de las condiciones iniciales. A partir de esta descomposición, se puede observar que el comportamiento asintótico del sistema cuando $t \rightarrow \infty$ está gobernado estrictamente por el término exponencial real $e^{\sigma_i t}$.

Por lo tanto, el sistema es de tipo *Hurwitz* (o internamente estable de manera asintótica) si y solo si todos los valores propios de la matriz de dinámica A poseen partes reales estrictamente negativas, siendo esta la expresión:

$$\text{Re}(\lambda_i(A)) < 0, \quad \forall i \in \{1, \dots, n_x\} \quad (2.8)$$

Si esta condición se cumple, el término $e^{\sigma_i t}$ decae exponencialmente hacia cero, garantizando que $\lim_{t \rightarrow \infty} x(t) = 0$ ante cualquier condición inicial x_0 . Por el contrario, si existe al menos un valor propio con $\text{Re}(\lambda_i) > 0$, el modo dinámico asociado crecerá de forma ilimitada, resultando en un sistema inestable. En el caso de que existan autovalores sobre el eje imaginario ($\text{Re}(\lambda_i) = 0$), el sistema presentará oscilaciones sostenidas o respuestas marginalmente estables. Esta relación geométrica entre la ubicación de los autovalores en el plano complejo y la naturaleza de las trayectorias del estado se ilustra en la Figura A.1.

Este preámbulo LTI establece dos herramientas conceptuales que reutilizaremos a lo largo de todo el marco teórico: (i) la estabilidad se certifica mediante el signo de los autovalores de la matriz de dinámica, y (ii) esta condición espectral admite una formulación algebraica equivalente en términos de una matriz definida positiva P , que desarrollaremos formalmente en la Sección 2.3. A partir de este punto, el marco teórico abandona la matriz constante A propia del caso LTI y trabaja exclusivamente con la estructura de parámetros variables que sí corresponde al sistema de interés de este estudio.

2.2. Sistemas Lineales de Parámetros Variables (LPV) y Modelos Parametrizados

Los procesos reales en los CPS a menudo operan bajo condiciones cambiantes, variaciones estructurales o dependencias operativas no lineales. Para capturar este comportamiento sin perder las ventajas de las herramientas lineales, se recurre a la formulación de *Sistemas Lineales de Parámetros Variables* (LPV) o sistemas parametrizados.

En este marco de modelación, la dinámica del sistema depende explícitamente de un vector de parámetros externos o variables de operación variables en el tiempo, denotado por $\xi(t) \in \mathbb{R}^p$. La representación en espacio de estados de la Ecuación (2.1) se particulariza entonces a la forma *lineal de parámetros variables*, en la cual las funciones $f(\cdot)$ y $g(\cdot)$ dejan de ser arbitrarias y adoptan una estructura afín en $(x(t), u(t), w(t))$, pero cuyos coeficientes (las matrices del sistema) ya no son constantes, sino que se transforman en funciones del parámetro operativo $\xi(t)$:

$$\dot{x}(t) = f(x(t), u(t), w(t), \xi(t)) = A(\xi(t))x(t) + B(\xi(t))u(t) + B_w(\xi(t))w(t) \quad (2.9)$$

$$y(t) = g(x(t), u(t), w(t), \xi(t)) = C(\xi(t))x(t) + D(\xi(t))u(t) + D_w(\xi(t))w(t) \quad (2.10)$$

Las Ecuaciones (2.9)-(2.10) constituyen la representación general del sistema LPV que se utilizará a lo largo del estudio.

El vector de parámetros $\xi(t)$ suele variar dentro de un conjunto compacto admisible $\Xi \subset \mathbb{R}^p$. Esta formulación permite modelar situaciones críticas en CPS como:

1. **Variaciones estructurales:** Cambios físicos intrínsecos en el sistema, tales como variaciones de masa, fluctuaciones térmicas o cambios en la resistencia de componentes debidos al desgaste.
2. **Linealización alrededor de trayectorias (Ganancia Programada):** Aproximaciones locales de sistemas altamente no lineales a lo largo de diferentes puntos de operación indexados por la variable ξ .
3. **Ciberataques y anomalías en la red:** En el contexto de los CPS, ataques maliciosos como la inyección de datos falsos (FDI), ataques de denegación de servicio (DoS) o el secuestro de actuadores pueden alterar la topología de comunicación o modificar los parámetros efectivos del sistema físico, lo cual se modela mediante cambios abruptos y arbitrarios en el vector $\xi(t)$ [25, 10].

El principal desafío operativo bajo el enfoque LPV es que las condiciones de estabilidad deben garantizarse de forma unívoca para *cualquier* trayectoria posible que el parámetro $\xi(t)$ adopte dentro del espacio admisible Ξ . En este contexto, una **trayectoria paramétrica** se define como una función dependiente del tiempo $\xi : [0, \infty) \rightarrow \Xi$, la cual describe el historial de la evolución del punto de operación o el perfil temporal de una anomalía. Garantizar la estabilidad robusta implica asegurar que el estado del sistema converja o permanezca acotado sin importar qué camino

específico tome $\xi(t)$, ni cuán rápido varíe dentro de los límites de Ξ . La trayectoria paramétrica $\xi(t)$ se ilustra en la Figura A.2, donde se muestra su recorrido dentro del espacio admisible.

A diferencia de los sistemas LTI, donde la estabilidad se certifica evaluando el espectro fijo de la matriz A , los sistemas LPV presentan un desafío mayor. Un teorema fundamental en sistemas variables en el tiempo establece que el hecho de que los autovalores de $A(\xi)$ posean partes reales negativas para cada parámetro “congelado” en Ξ , **no garantiza** la estabilidad del sistema dinámico; fluctuaciones paramétricas suficientemente rápidas pueden inducir inestabilidad.

Por lo tanto, para el caso de un sistema LPV se exige generalizar una función de Lyapunov. Se dice que un sistema es *cuadráticamente estabilizable* si admite una función de Lyapunov cuadrática común $V(x) = x^\top P x$ que disipe energía bajo cualquier condición. Hallarla implica encontrar una única matriz $P \in \mathbb{S}^n$ que satisfaga la restricción para todo el dominio de operación simultáneamente:

$$P \succ 0 \quad (2.11)$$

$$A(\xi)^\top P + P A(\xi) \prec 0, \quad \forall \xi \in \Xi \quad (2.12)$$

Dado que el conjunto Ξ es continuo y contiene infinitos puntos, la Ecuación (2.12) representa un problema de optimización semidefinida de dimensión infinita, lo cual es computacionalmente intratable de resolver directamente.

2.2.1. Estabilidad de Sistemas LPV mediante Modelos Politépicos

Para sortear este obstáculo de dimensionalidad infinita, una de las maneras que propone la literatura de control robusto para lograr la estabilidad en sistemas LPV es la representación mediante polítopos [9, 2]. Geométricamente, un polítopo es la generalización de un polígono (en 2D) o un poliedro (en 3D) a p dimensiones. En el modelado de sistemas, el polítopo define los límites máximos y mínimos que pueden tomar los parámetros físicos.

Los **vértices del polítopo** (N) corresponden a las combinaciones de las condiciones operativas extremas (o “peores casos”). Por ejemplo, si un sistema depende de una masa $m \in [m_{min}, m_{max}]$ y una fricción $f \in [f_{min}, f_{max}]$, el espacio admisible Ξ es un rectángulo cuyos $N = 4$ vértices son las combinaciones de dichos valores extremos.

Si se asume que la matriz del sistema $A(\xi)$ depende de forma afín de los parámetros ξ , entonces cualquier matriz del sistema evaluada en un punto de operación intermedio puede expresarse como una *combinación convexa* de las matrices evaluadas en los vértices extremos, denotadas como A_i :

$$A(\xi) = \sum_{i=1}^N \eta_i A_i, \quad \text{con} \quad \sum_{i=1}^N \eta_i = 1, \quad \eta_i \geq 0 \quad (2.13)$$

Bajo esta transformación, y gracias a la linealidad geométrica de las LMIs, se demuestra que si una desigualdad matricial estricta se cumple en todos los vértices de un polítopo, automáticamente se cumple para cualquier punto en su interior. Así, el problema de infinitas restricciones de la Ecuación (2.12) se reduce de forma exacta a un conjunto finito de N LMIs acopladas:

$$A_i^\top P + PA_i \prec 0, \quad \forall i \in \{1, 2, \dots, N\} \quad (2.14)$$

Encontrar una matriz P que resuelva este conjunto finito de LMIs garantiza que el sistema LPV se mantenga asintóticamente estable para toda posible variación temporal de $\xi(t)$. Sin embargo, a medida que la dimensión del sistema (n_x) o la cantidad de parámetros inciertos crecen, el número de vértices N aumenta exponencialmente. El costo computacional de resolver este conjunto acoplado de restricciones mediante solucionadores de punto interior en tiempo real se vuelve prohibitivo para las dinámicas rápidas de los CPS.

2.3. Desigualdades Matriciales Lineales y Teoría de Lyapunov

Introduciremos desde sus bases el concepto de Desigualdad Matricial Lineal (LMI) y el Método Directo de Lyapunov, cuya intersección constituye la base del control robusto moderno. Para desarrollar estas herramientas con la menor carga notacional posible, esta sección introduce primero los conceptos de positividad matricial y de función de Lyapunov sobre la matriz constante A del caso LTI; la generalización de estos resultados a la matriz dependiente de parámetros $A(\xi)$ y a su versión politópica A_i se retoma en la Sección 2.4, donde se formula el problema de síntesis de control propiamente LPV.

2.3.1. Fundamentos de las Desigualdades Matriciales Lineales (LMI)

En el ámbito del álgebra lineal y la optimización, una Desigualdad Matricial Lineal (LMI, por sus siglas en inglés) es una condición que restringe el espacio de soluciones de un problema. Su propósito es garantizar que una matriz paramétrica, cuyos elementos dependen de un conjunto de variables desconocidas (variables de decisión), resulte ser definida positiva (o negativa).

Se dice que la matriz está construida **paramétricamente** porque no está compuesta por valores numéricos estáticos, sino que se formula como una función afín de ciertos parámetros de diseño. En el contexto de la teoría de control, esta parametrización es fundamental: los parámetros desconocidos representan precisamente las incógnitas que un ingeniero o un algoritmo deben encontrar (por ejemplo, los coeficientes de un controlador o los elementos de una función de Lyapunov). Al estructurar estas incógnitas de forma lineal dentro de la matriz, el problema de buscar un diseño estable se transforma en un problema de búsqueda geométrica. La principal ventaja de formular el problema de esta manera es que el conjunto de parámetros que satisface la LMI forma un espacio de soluciones estrictamente convexo, lo que garantiza la tratabilidad computacional y la inexistencia de mínimos locales al optimizar.

Positividad

Sea $P \in \mathbb{S}^n$ una matriz cuadrada y simétrica (es decir, $P = P^\top$). Se dice que P es **definida positiva**, denotado como $P \succ 0$, si para cualquier vector no nulo $x \in \mathbb{R}^n$, la forma cuadrática asociada es estrictamente mayor que cero:

$$x^\top P x > 0, \quad \forall x \neq 0 \quad (2.15)$$

Para comprender el impacto geométrico de la matriz P , es imperativo analizar su estructura a través del teorema espectral. Toda matriz simétrica $P \in \mathbb{S}^n$ puede descomponerse en la forma $P = V \Lambda V^\top$, donde Λ es una matriz diagonal que contiene los valores propios (o autovalores) λ_i , y V es una matriz ortogonal cuyas columnas son los vectores propios (o autovectores) de P .

En el contexto de la función de energía $V(x) = x^\top P x = c$, estos elementos dictan completamente la topología del espacio de estados:

- **Los vectores propios ortogonales (v_i):** Representan los ejes principales o “direcciones naturales” de la figura geométrica. Al ser ortogonales (forman ángulos de 90° entre sí en el espacio de dimensión n), garantizan que la matriz define un sistema de coordenadas no distorsionado. Físicamente, indican las direcciones en las que la dinámica del sistema está puramente desacoplada.
- **Los valores propios (λ_i):** Representan el factor de concavidad o “escala” a lo largo de cada vector propio. La longitud del semieje de la figura geométrica en la dirección del vector propio v_i está dada por $\frac{\sqrt{c}}{\sqrt{\lambda_i}}$.

Si la matriz P es definida positiva, todos sus valores propios son estrictamente mayores que cero ($\lambda_i > 0$). Esto asegura que todas las longitudes de los semiejes sean números reales finitos. En consecuencia, la ecuación $x^\top P x = c$ forma un elipsoide cerrado centrado en el origen. Desde la perspectiva del control, esto significa que la “energía” del sistema está confinada, lo que se traduce en que el estado $x(t)$ no puede escapar hacia el infinito sin aumentar el nivel de energía c como se aprecia en la figura A.3a.

Por el contrario, si P pierde su positividad y presenta al menos un autovalor negativo, la longitud de ese semieje se vuelve imaginaria. Geométricamente, el elipsoide se “rompe” y se abre transformándose en un hiperboloide (ver figura A.3b). Esto es catastrófico para la estabilidad ya que implica que el sistema posee trayectorias a lo largo de las cuales los estados pueden crecer de forma ilimitada (hacia el infinito) mientras la “energía” medida c se mantiene constante o incluso disminuye, violando el principio de confinamiento de Lyapunov.

Linear Matrix Inequality (LMI)

Una LMI general se formula estableciendo que una matriz afín, que depende de un vector de variables de decisión $y \in \mathbb{R}^m$, debe ser semidefinida o definida positiva. Su forma canónica es:

$$F(y) = F_0 + y_1 F_1 + y_2 F_2 + \cdots + y_m F_m \succ 0 \quad (2.16)$$

donde $F_0, F_1, \dots, F_m \in \mathbb{S}^n$ son matrices simétricas conocidas e y_i son las incógnitas del problema. La propiedad más valiosa de una LMI es la convexidad: el conjunto de soluciones y que satisfacen $F(y) \succ 0$ forma un conjunto estrictamente convexo. Esto implica que cualquier problema de optimización sujeto a restricciones LMI posee un único óptimo global, el cual puede ser hallado mediante algoritmos de punto interior.

2.3.2. El Método Directo de Lyapunov

El matemático ruso Aleksandr Lyapunov formuló un método para determinar la estabilidad de un sistema dinámico sin necesidad de resolver analíticamente sus ecuaciones diferenciales. Este enfoque, conocido como el *Método Directo de Lyapunov*, se basa en un principio físico fundamental: si la energía total de un sistema mecánico o eléctrico disipa (disminuye) continuamente a lo largo del tiempo, el sistema eventualmente se detendrá y alcanzará un punto de equilibrio estable.

Lyapunov propuso reemplazar el concepto físico de “energía” por una función matemática escalar abstracta $V(x)$, denominada *función candidata de Lyapunov*, que depende del estado del sistema $x(t)$. Para que $V(x)$ sea válida, debe cumplir dos condiciones elementales:

1. **Debe ser localmente definida positiva:** $V(x) > 0$ para todo $x \neq 0$, y $V(0) = 0$. Esto imita a la energía de un sistema, la cual es nula en el reposo y positiva en cualquier otro estado.
2. **Su derivada temporal debe ser definida negativa:** A lo largo de las trayectorias del sistema, la variación de esta “energía” debe ser decreciente, es decir, $\dot{V}(x) < 0$ para todo $x \neq 0$.

Si se logra encontrar al menos una función $V(x)$ que cumpla simultáneamente ambas condiciones para un sistema dado, el Teorema de Lyapunov garantiza matemática y rigurosamente que el origen del sistema es asintóticamente estable.

2.3.3. De Lyapunov a LMI

El nexo fundamental entre las abstracciones de Lyapunov, el álgebra matricial de las LMIs y, posteriormente, la teoría de control, surge al elegir una estructura matemática específica para la función de energía. La elección más clásica para la función candidata de Lyapunov es la forma cuadrática:

$$V(x) = x^\top P x \quad (2.17)$$

Para satisfacer la primera condición de Lyapunov, basta con exigir directamente que la matriz P sea definida positiva, lo que constituye nuestra primera desigualdad matricial. Ahora, supongamos

un sistema dinámico lineal y autónomo descrito por la ecuación diferencial $\dot{x} = Ax$. Para evaluar la segunda condición de Lyapunov, se debe derivar $V(x)$ con respecto al tiempo aplicando la regla de la cadena:

$$\dot{V}(x) = \dot{x}^\top Px + x^\top P\dot{x} \quad (2.18)$$

Sustituyendo la dinámica del sistema ($\dot{x} = Ax$) en la derivada, se obtiene:

$$\dot{V}(x) = (Ax)^\top Px + x^\top P(Ax) = x^\top A^\top Px + x^\top PAx \quad (2.19)$$

$$\dot{V}(x) = x^\top (A^\top P + PA)x \quad (2.20)$$

Para que la energía disipe, se requiere que $\dot{V}(x) < 0$ para cualquier estado $x \neq 0$. Observando la Ecuación (2.20), es evidente que esta condición se cumple si y solo si la matriz encerrada entre los vectores de estado es definida negativa. Esto genera nuestra segunda desigualdad matricial:

$$A^\top P + PA \prec 0 \quad (2.21)$$

De esta manera, el problema abstracto y complejo de analizar ecuaciones diferenciales para demostrar la estabilidad de un sistema físico, ha sido transformado en un problema puramente algebraico. Si existe una matriz P que satisfaga simultáneamente las LMIs $P \succ 0$ y $A^\top P + PA \prec 0$, el sistema es estable. Esta traducción de dinámicas temporales a restricciones geométricas convexas es la base sobre la cual se diseñan los controladores robustos en la ingeniería de Sistemas Ciberfísicos.

La Ecuación (2.21) corresponde al caso LTI, con la matriz constante A ; su generalización directa al caso politópico corresponde a la Ecuación (2.14), reemplazando A por cada vértice A_i del politopo y exigiendo una matriz P común para todos ellos. De aquí en adelante, todas las LMIs se formulan directamente sobre la estructura politópica A_i, B_i ($i = 1, \dots, N$), pues es esta la que corresponde al sistema LPV objeto de este estudio.

2.4. Realimentación

2.4.1. El Principio de Realimentación y el Lazo Cerrado

En la teoría de sistemas, una topología de control puede clasificarse fundamentalmente en dos paradigmas: lazo abierto (*open-loop*) y lazo cerrado (*closed-loop*).

En una configuración de lazo abierto, la señal de control $u(t)$ inyectada al sistema físico (la planta) se calcula exclusivamente en función de una referencia deseada y un modelo matemático previo, sin tomar en cuenta el estado actual del sistema. Si bien es computacionalmente económica, esta arquitectura tiene la falencia de que si el modelo matemático posee imprecisiones o si perturbaciones

externas, las cuales normalmente se pueden presentar en la realidad como fricción no modelada, ráfagas de viento, sobrecalentamiento natural del sistema, etc, actúan sobre la planta, el error entre el estado real y el deseado crecerá sin que el controlador pueda detectarlo ni compensarlo.

Para dotar a los CPS de inteligencia y robustez, se emplea la arquitectura de lazo cerrado. En este esquema, el sistema de control mide continuamente a través de sensores el estado actual de la planta o sus salidas, y utiliza esta información para ajustar dinámicamente la señal de control $u(t)$. Este flujo continuo de información desde la salida hacia la entrada del controlador se denomina realimentación. La realimentación permite que el sistema se auto-corrija, compare su estado actual con un punto de equilibrio deseado, y genere la energía necesaria para anular cualquier desviación, mitigando eficazmente los efectos de las incertidumbres y perturbaciones exógenas. La Figura A.4 ilustra el esquema de realimentación de estados.

2.4.2. Realimentación de Estados y Asignación de Polos

La forma más directa de implementar un lazo cerrado es a través de la *realimentación completa de estados* (*full state feedback*). El calificativo completa se refiere a la **información** disponible para el controlador, y no a la estructura de la ganancia. Se asume que las n_x componentes del vector de estados $x(t) \in \mathbb{R}^{n_x}$ están disponibles en todo instante —medidas directamente o reconstruidas por un observador—, lo que equivale a decir que la salida realimentada es el estado mismo, es decir, $y(t) = Cx(t)$ con $C = I_{n_x}$. Bajo este supuesto la matriz de ganancia K es densa: cada entrada de control puede depender de cualquier componente del estado, sin ceros impuestos por la topología de sensores. La contraparte, en que solo se dispone de un subconjunto o de combinaciones lineales del estado ($C \neq I$), se discute en la Sección 2.4.3.

Para el sistema LPV politópico descrito por la Ecuación (2.9), se propone una ley de control proporcional de la forma:

$$u(t) = Kx(t) \quad (2.22)$$

donde $K \in \mathbb{R}^{n_u \times n_x}$ es denominada la **matriz de ganancia del controlador**. A diferencia del caso LTI, donde bastaría con encontrar una ganancia que establezca la única matriz A del sistema, en el caso LPV se exige que *una misma* matriz K establezca simultáneamente la planta para toda trayectoria admisible de $\xi(t)$. Al sustituir la ley de control (2.22) dentro de la ecuación diferencial (2.9) (sin pérdida de generalidad, ignorando temporalmente la perturbación $w(t)$), se acopla la dinámica del controlador con la de la planta, obteniendo la dinámica del sistema en lazo cerrado:

$$\dot{x}(t) = A(\xi(t))x(t) + B(\xi(t))(Kx(t)) = (A(\xi(t)) + B(\xi(t))K)x(t) \quad (2.23)$$

Definiendo la **matriz de lazo cerrado** como $A_{cl}(\xi) = A(\xi) + B(\xi)K$, la dinámica queda gobernada por el sistema autónomo equivalente $\dot{x}(t) = A_{cl}(\xi(t))x(t)$. Aprovechando la estructura politópica

introducida en la Ecuación (2.13), esta condición se traslada de forma exacta a los N vértices del polítopo, definiendo las matrices de lazo cerrado por vértice:

$$A_{cl,i} = A_i + B_i K, \quad \forall i \in \{1, \dots, N\} \quad (2.24)$$

El impacto analítico de la Ecuación (2.24) es profundo: la matriz de ganancia K actúa como un único grado de libertad de diseño compartido por todos los vértices que permite modificar directamente los valores propios (o polos) de cada matriz de planta A_i . El objetivo de la síntesis de control robusto es encontrar una matriz K tal que todos los valores propios de $A_{cl,i}$ posean partes reales estrictamente negativas para cada vértice i ($\text{Re}(\lambda_j(A_i + B_i K)) < 0, \forall j, \forall i$), transformando un polítopo originalmente inestable en uno robustamente Hurwitz. En el contexto geométrico de las trayectorias de estado, la matriz K esculpe simultáneamente los N campos vectoriales de los vértices para asegurar que cualquier condición inicial converja asintóticamente hacia el origen, sin importar qué combinación convexa $\xi(t)$ esté activa.

2.4.3. Realimentación Estática de Salida

Es importante notar que, en la práctica industrial, rara vez se tiene acceso a la medición directa de todas las variables internas del estado $x(t)$ debido a limitaciones físicas o al costo de los sensores. En su lugar, el controlador solo tiene acceso al vector de salidas medibles $y(t) = C(\xi)x(t)$.

En estos escenarios, la ley de control se formula como una *realimentación estática de salida* (*Static Output Feedback* o SOF), dada por $u(t) = Fy(t)$, lo que resulta en $u(t) = FC(\xi)x(t)$. La dinámica en lazo cerrado adopta la forma $\dot{x}(t) = (A(\xi) + B(\xi)FC(\xi))x(t)$. Aunque estructuralmente similar a la realimentación de estados (donde la ganancia efectiva es $K = FC(\xi)$), el diseño por realimentación de salida impone severas restricciones algebraicas adicionales.

Conviene precisar por qué esta memoria se restringe al caso de realimentación completa de estados de la Ecuación (2.22), y en qué sentido dicho supuesto efectivamente se aplica al problema abordado. Hay dos razones, una algebraica y una empírica.

La razón algebraica es que el supuesto de estado completo es precisamente lo que hace convexo al problema de síntesis. Como se desarrolla en la Sección 2, la transformación de congruencia con $Q = P^{-1}$ convierte el término bilineal PBK en BKQ , y el cambio de variable $Y = KQ$ lo linealiza porque K multiplica a Q por la derecha y sin factores intercalados. Con SOF el término homólogo es $PBFC$, y la misma congruencia produce $BFCQ$: el producto FCQ no admite el cambio de variable $Y = FCQ$, pues F no podría recuperarse sin conocer CQ , que a su vez depende de la incógnita Q . La condición permanece, por tanto, como una BMI y el problema es NP-difícil en general [8, 27]; recuperar convexidad exige supuestos estructurales adicionales (por ejemplo, C de rango fila completo y una restricción de acoplamiento del tipo $PB = BG$) o esquemas iterativos sin garantía de optimalidad global. En consecuencia, SOF no es una variante menor del problema aquí resuelto, sino una clase de problema distinta: la capa de proyección de esta memoria opera sobre

conjuntos convexos y no admitiría la restricción bilineal sin reformularse por completo.

La razón empírica es que el supuesto es consistente con los datos utilizados. La base de sistemas politópicos empleada (Sección 3.1) caracteriza cada instancia por la terna $(\{A_i\}, \{B_i\}, K)$, sin matriz de salida C ni canal de perturbación B_w : no existe en ella información de sensores sobre la cual formular una ley $u = Fy$. El supuesto de estado completo no es entonces una idealización añadida sobre los datos, sino la única hipótesis compatible con ellos, y la ganancia de referencia almacenada K_{ref} —densa, de dimensión $n_u \times n_x$ — confirma que la base fue construida bajo ese mismo supuesto.

Cabe señalar, no obstante, que el supuesto no es gratuito desde el punto de vista operativo. En los CPS que motivan esta memoria, el estado completo rara vez se mide directamente, y en la práctica se reconstruye mediante un observador. Ello traslada el problema a la síntesis conjunta de controlador y observador, cuya validez para plantas LPV descansa en supuestos de separación que no son automáticos bajo variación paramétrica. La extensión al caso de salida queda, por lo tanto, explícitamente fuera del alcance de este trabajo y se recoge como línea de trabajo futuro en la Sección 5.2.2.

2.4.4. El Problema de Síntesis LMI y la No Convexidad

Para garantizar formalmente la estabilidad robusta del sistema en lazo cerrado, cada matriz de vértice $A_{cl,i} = A_i + B_i K$ definida en la Ecuación (2.24) debe satisfacer la desigualdad matricial de Lyapunov de la Ecuación (2.14), con una *misma* matriz P para todos los vértices. Sustituyendo $A_{cl,i}$ en dicha LMI ($A_{cl,i}^\top P + P A_{cl,i} \prec 0$), se obtiene, para cada $i \in \{1, \dots, N\}$:

$$(A_i + B_i K)^\top P + P(A_i + B_i K) \prec 0 \quad (2.25)$$

$$A_i^\top P + K^\top B_i^\top P + P A_i + P B_i K \prec 0 \quad (2.26)$$

Al formular este problema como uno de diseño u optimización, surgen dos variables de decisión simultáneas:

1. La matriz de Lyapunov $P \succ 0$, que certifica la estabilidad y define el elipsoide de confinamiento, común a los N vértices.
2. La matriz de ganancia del controlador K , común a los N vértices, que modifica la dinámica de la planta en cada uno de ellos.

La presencia de los términos $P B_i K$ y $K^\top B_i^\top P$ en la Ecuación (2.26) introduce un producto directo entre dos variables desconocidas (P y K). Matemáticamente, esto destruye la propiedad de linealidad afín requerida por las LMIs, transformando la expresión en una Desigualdad Matricial Bilineal (BMI, por sus siglas en inglés) para cada vértice i .

A diferencia de las LMIs, las BMIs definen espacios de búsqueda que *no son convexos*. Optimizar sobre una BMI es un problema de complejidad computacional NP-difícil, propenso a atrapar a los

algoritmos en mínimos locales y hacer que la solución analítica en tiempo real sea intratable. Nótese que este obstáculo de no convexidad se presenta de forma idéntica en cada uno de los N vértices; la transformación que se desarrolla a continuación se aplica, por lo tanto, simultáneamente a todos ellos.

2.4.5. Transformación de Congruencia y Linealización de la LMI

Para recuperar la convexidad y hacer posible la síntesis del controlador, la teoría de control robusto recurre a un cambio de variables. Este proceso transforma la BMI intratable en una LMI exacta sin pérdida de generalidad.

Se parte de la premisa de definir una matriz $Q \in \mathbb{S}^n$ como la inversa de la matriz de Lyapunov, es decir, $Q = P^{-1}$. Dado que $P \succ 0$, se garantiza que su inversa existe y que también es definida positiva ($Q \succ 0$).

A continuación, se aplica una transformación de congruencia sobre la Ecuación (2.26), la cual consiste en pre-multiplicar y post-multiplicar toda la desigualdad por la matriz Q . Dado que Q es definida positiva y simétrica ($Q = Q^\top$), esta transformación preserva estrictamente el signo de la desigualdad (es decir, una matriz definida negativa seguirá siendo definida negativa tras la transformación de congruencia). Como la matriz P es común a todos los vértices por construcción, también lo será su inversa Q ; el procedimiento se desarrolla de la siguiente forma, para cada vértice $i \in \{1, \dots, N\}$:

$$Q \left[A_i^\top P + K^\top B_i^\top P + P A_i + P B_i K \right] Q \prec Q[0]Q \quad (2.27)$$

Distribuyendo el producto matricial y recordando que $PQ = PP^{-1} = I$ (la matriz identidad):

$$Q A_i^\top P Q + Q K^\top B_i^\top P Q + Q P A_i Q + Q P B_i K Q \prec 0 \quad (2.28)$$

$$Q A_i^\top + Q K^\top B_i^\top + A_i Q + B_i K Q \prec 0 \quad (2.29)$$

En esta nueva ecuación, el término bilineal conflictivo es KQ (el producto de las dos matrices incógnitas), presente de forma idéntica en los N vértices. Para linealizar definitivamente la expresión, se introduce un cambio de variable lineal definiendo una nueva matriz de decisión $Y \in \mathbb{R}^{n_u \times n_x}$, también común a todo el polítopo:

$$Y = KQ \quad \implies \quad Y^\top = QK^\top \quad (2.30)$$

Sustituyendo Y en la Ecuación (2.29) y reordenando, se obtiene la formulación final de la desigualdad para la síntesis de control robusto, replicada para cada vértice del polítopo:

$$A_i Q + Q A_i^\top + B_i Y + Y^\top B_i^\top \prec 0, \quad \forall i \in \{1, \dots, N\} \quad (2.31)$$

La Ecuación (2.31) es un conjunto de N Desigualdades Matriciales Lineales (LMI) estrictas acopladas por compartir las mismas variables de decisión. Las incógnitas ahora son Q (que debe ser $Q \succ 0$) e Y , y ambas son *comunes* a los N vértices: es esta condición de simultaneidad la que certifica la estabilización robusta de todo el polítopo con un único controlador. Dado que cada una de las N desigualdades es una combinación lineal afín de Q e Y , el espacio conjunto de soluciones ha recuperado su estricta convexidad, y la Ecuación (2.31) puede reescribirse de forma equivalente como la restricción bloque-diagonal única $\text{diag}(F^{(1)}(Q, Y), \dots, F^{(N)}(Q, Y)) \succeq 0$, con $F^{(i)}(Q, Y) \triangleq -(A_i Q + Q A_i^\top + B_i Y + Y^\top B_i^\top)$.

Una vez que un algoritmo de optimización resuelve este problema y entrega los valores numéricos óptimos para las variables Q y Y , la ganancia estabilizante real del controlador en lazo cerrado que será implementada físicamente en la planta —y que por construcción estabiliza simultáneamente los N vértices— se recupera invirtiendo la transformación:

$$K = Y Q^{-1} \quad (2.32)$$

2.4.6. Control Robusto y Criterios de Desempeño

En condiciones operativas reales, los Sistemas Ciberfísicos interactúan con entornos inciertos, ruidosos o sometidos a variaciones paramétricas. Por ende, es imperante transicionar desde el control clásico hacia el *control robusto*. El objetivo del control robusto no es solo garantizar que el sistema no se desestabilice, sino asegurar que se comporte de la mejor manera posible a pesar de estar sujeto al peor escenario de perturbaciones.

Una suposición fundamental es que las perturbaciones exógenas $w(t)$ (ruido de sensores, ráfagas de viento, variaciones de carga) están limitadas en magnitud. Formalmente, se asume que su energía está acotada según su norma euclidiana, $w(t)^\top w(t) \leq 1$. Bajo estas interferencias, el sistema no puede quedarse estático en el origen (cero absoluto); en su lugar, se busca diseñar un controlador que confine las trayectorias del estado dentro de una región segura. Esta región se formaliza como un elipsoide invariante, definido por una matriz $P \succ 0$:

$$\mathcal{E}(P) = \{x \in \mathbb{R}^{n_x} : x^\top P x \leq 1\} \quad (2.33)$$

Si el sistema logra atrapar los estados dentro de $\mathcal{E}(P)$ para cualquier perturbación admisible, se dice que es robustamente estable. Sin embargo, garantizar la estabilidad es apenas el requisito mínimo de viabilidad. En la ingeniería moderna, se busca que el sistema opere cumpliendo un **criterio de desempeño** específico. Un criterio de desempeño es una métrica que cuantifica la “calidad” de la respuesta del sistema.

Dependiendo de la aplicación del CPS, se formulan distintos criterios de desempeño que pueden optimizarse manipulando la matriz P . Algunos de ellos son:

- **Tasa de decaimiento:** Se busca maximizar la velocidad con la que el sistema regresa a su equilibrio tras una perturbación temporal. Matemáticamente, se optimiza un escalar que representa la convergencia exponencial.
- **Volumen del elipsoide de contención:** Si el elipsoide $\mathcal{E}(P)$ representa la zona donde el sistema “vibra” ante perturbaciones, un excelente criterio de desempeño es hacer que esta zona sea lo más pequeña posible. Esto se logra minimizando el volumen geométrico del elipsoide, lo cual es equivalente a maximizar el determinante de P (planteado comúnmente en optimización como minimizar $-\log \det P$ o minimizar la traza de su inversa).
- **Desempeño $\mathcal{H}_\infty$ (H-infinito):** Es una métrica de ganancia de energía. Mide la peor ampliación posible desde la señal de perturbación $w(t)$ hacia una señal de error o salida de interés $y(t)$. Optimizar este criterio significa encontrar el controlador que minimice un factor $\gamma > 0$ tal que la energía del error siempre sea menor que γ veces la energía del ruido.

2.5. El Desafío Computacional y Nuevos Paradigmas en Tiempo Real

El diseño de controladores se suele plantear como un problema de optimización bajo restricciones. El objetivo es minimizar una función de costo J_{obj} (el criterio de desempeño elegido, como el volumen del elipsoide o la ganancia γ), sujeta a que la matriz P satisfaga el conjunto de restricciones LMI de estabilidad.

2.5.1. Algoritmos de Punto Interior

El desafío operativo radica en que, para los sistemas LPV y los CPS sujetos a dinámicas cambiantes, este problema de optimización paramétrica debe resolverse continuamente en línea (*online*) cada vez que el vector de estado o los parámetros $\xi(t)$ se actualizan.

Tradicionalmente, la resolución de Programación Semidefinida (SDP) y restricciones LMI se lleva a cabo utilizando **métodos de punto interior (IPM)**. A diferencia del método Simplex, los IPM operan estrictamente dentro de la región segura y convexa de soluciones, convergiendo al óptimo en tiempo polinomial. Su estructura central se basa en relajar las condiciones de complementariedad y aplicar el método de Newton junto con una “barrera logarítmica” que penaliza acercarse a las fronteras inestables. El Algoritmo 1 resume la estructura computacional de un método de punto interior primal-dual estándar.

Aunque este algoritmo ofrece garantías irrefutables de convergencia, la línea 6 del Algoritmo 1 representa el origen del cuello de botella en tiempo real. Construir y resolver el sistema de ecuaciones para el paso de Newton requiere calcular la inversa o la factorización de Cholesky de matrices densas

de gran escala en cada iteración del ciclo While.

Herramientas de software clásicas en la literatura de control robusto, tales como **SeDuMi** (que utiliza un enfoque de incrustación auto-dual), **SDPT3** o solucionadores comerciales de alto rendimiento como **MOSEK**, ejecutan estos algoritmos con extremada precisión. Sin embargo, su complejidad computacional típicamente escala en un orden de $\mathcal{O}(m^3 + m^2n^2)$ por iteración (donde m representa el número de variables de decisión y n la dimensión de la LMI). Esto vuelve a los IPM excesivamente lentos y de alto consumo de CPU, haciéndolos incompatibles con aplicaciones de CPS que requieren estimar el control y estabilizar el sistema en fracciones de milisegundo.

2.5.2. Nuevos Paradigmas en Tiempo Real

Para superar este obstáculo de cómputo, las investigaciones recientes en la teoría de control y optimización se han volcado hacia la descomposición offline-online y la integración de técnicas de aprendizaje automático [26, 16, 29, 22]. La premisa fundamental es trasladar la pesada carga de búsqueda iterativa de los IPM a una fase de entrenamiento o cálculo fuera de línea (*offline*). Entre las estrategias contemporáneas para operar en tiempo real destacan:

- **Optimización explícita y partición del espacio:** Intentan precalcular todas las posibles soluciones algebraicas para cada región del espacio paramétrico de operación (por ejemplo, el Control Predictivo Explícito). Aunque son matemáticamente exactas, en sistemas de alto orden se vuelven inmanejables en cuanto al almacenamiento de las regiones en memoria [7].
- **Aprendizaje de arranque en caliente (*warm-start*):** Utilizan modelos de datos para inferir un punto inicial extremadamente cercano al óptimo del problema. Esta predicción se inyecta en un solucionador numérico clásico en tiempo real, reduciendo drásticamente la cantidad de iteraciones necesarias para converger [26].
- **Modelos de aprendizaje profundo con restricciones duras:** Consisten en entrenar arquitecturas neuronales para aprender el mapeo directo desde las condiciones de operación actuales hacia la variable de decisión óptima. Para sortear el problema de las predicciones inseguras o inestables, estas investigaciones se centran en el desarrollo de capas algorítmicas de proyección diferenciable, las cuales fuerzan y garantizan matemáticamente que la salida de la red satisfaga de manera estricta las desigualdades matriciales [16, 29, 22].

2.5.3. Redes Neuronales con Restricciones Duras y Capas de Proyección

Las arquitecturas de aprendizaje profundo tradicionales (como los Perceptrones Multicapa o MLP) son aproximadores de funciones universales que transforman un espacio de entrada en un espacio de salida no restringido. Sin embargo, en el contexto del control robusto de Sistemas Ciberfísicos, las variables de decisión (como la matriz de Lyapunov P) no pueden adoptar valores arbitrarios; deben obedecer estrictamente a las restricciones geométricas del cono semidefinido positivo para garantizar la estabilidad [33]. Si una red neuronal estándar predice una matriz que viola ligeramente estas restricciones, el controlador resultante será matemáticamente inválido, pudiendo inducir

inestabilidad catastrófica en el sistema físico.

Para cerrar esta brecha, la comunidad de aprendizaje automático ha explorado la imposición de restricciones duras (hard constraints) por diseño. Investigaciones recientes demuestran que es posible garantizar una factibilidad estricta mediante el diseño de capas diferenciables que imponen restricciones directamente sobre la salida de la red neuronal, sin perder la capacidad de aproximación universal del modelo [22].

Evolución de las Proyecciones y el Vacío en las LMIs

El concepto de una capa de proyección consiste en tomar la salida “cruda” o no restringida de la red, denotada como $\hat{y}_\theta$ (parametrizada por los pesos θ), y mapearla hacia el punto más cercano que resida dentro de un conjunto factible $\mathcal{C}$. Matemáticamente, esto equivale a resolver un problema de proyección ortogonal en cada inferencia:

$$y^* = \Pi_{\mathcal{C}}(\hat{y}_\theta) = \arg \min_z \frac{1}{2} \|\hat{y}_\theta - z\|_2^2 \quad (2.34)$$

sujeto a $z \in \mathcal{C}$

En la literatura reciente, restricciones afines simples han sido abordadas diseñando capas de proyección con soluciones en forma cerrada, mientras que restricciones convexas más generales se han logrado imponer mediante parametrizaciones ortogonales y basadas en rayos [16]. Sin embargo, esto deja abierto un desafío mayor: el diseño de una capa de proyección diferenciable y eficiente para problemas de aprendizaje limitados por Desigualdades Matriciales Lineales (LMI) que dependen explícitamente de las condiciones de operación cambiantes del sistema físico. Proyectar directamente sobre el conjunto descrito por una LMI compleja ($F(y) \succeq 0$) es analíticamente intratable, pues no posee una solución en forma cerrada.

División de Operadores (Splitting) y Diferenciación Implícita

Para superar la intratabilidad de proyectar directamente sobre una LMI, se recurre a observar la estructura geométrica subyacente del problema. El conjunto factible de una LMI parametrizada admite una representación levantada (Lifting Scheme) que permite tratar la LMI como la intersección exacta de dos conjuntos más simples: una restricción de igualdad afín y el cono semidefinido positivo [28].

Al descomponer la restricción, no existe una única proyección y^* , sino que se requiere un método iterativo que alterne entre ambos conjuntos geométricos hasta encontrar un punto de consenso. Para ello, se emplean algoritmos de división de operadores (Splitting Methods), siendo el algoritmo de Douglas-Rachford [21] uno de los más robustos para garantizar la convergencia hacia un punto factible en contextos de optimización de redes neuronales restringidas [28, 6].

Incrustar este proceso iterativo como una capa de red neuronal introduce el desafío final: el cálculo del pase hacia atrás (*Backward Pass*). Para que la red neuronal pueda ser entrenada mediante retropropagación (*backpropagation*), la capa debe ser diferenciable; es decir, se debe poder calcular la Jacobiana $\frac{\partial y^*}{\partial \hat{y}_\theta}$. Dado que el algoritmo iterativo de Douglas-Rachford reemplazaría una función explícita simple, evaluar gradientes a través de cientos de iteraciones (desenrollado algorítmico o *unrolling*) agotaría la memoria computacional. Para solventarlo, el estado del arte utiliza técnicas de *diferenciación implícita* basadas en el Teorema de la Función Implícita, calculando el gradiente analíticamente en el punto fijo de la proyección sin necesidad de almacenar el historial iterativo [16, 28].

La estructura computacional general de este paradigma se formaliza en el Algoritmo 2.

Al encapsular esta optimización geométrica dentro de la arquitectura neuronal, el modelo transiciona desde una simple heurística paramétrica a un estabilizador matemático formal garantizado por construcción.

3. Desarrollo Metodológico

3.1. Caracterización de la base de datos

3.1.1. Cómo se mide un sistema y su estabilidad

Abscisa espectral. La abscisa espectral es el máximo entre las partes reales, $\max \operatorname{Re} \lambda(A)$. Es el modo que crece más rápido (o decae más lento) y, por sí solo, decide la estabilidad: si la abscisa es negativa, todos los modos decaen; si es positiva, al menos uno explota. Un valor de, por ejemplo, 832 significa que el modo dominante crece como e^{832t} : una inestabilidad extremadamente violenta. Lo usamos como *medida relativa de qué tan inestable* es un sistema (no tiene unidades físicas porque los sistemas son sintéticos).

Norma de una matriz: su “tamaño”. La norma espectral $\|A\|_2$ mide cuánto puede *amplificar* esa matriz a un vector (formalmente, su mayor valor singular). Es una medida del “tamaño” o la fuerza de la dinámica: una $\|A\|_2$ grande indica acoplamientos internos intensos. Reportamos $\max_i \|A_i\|_2$, el tamaño del vértice más grande del politopo.

Tasa de decaimiento α . Una vez cerrado el lazo con el controlador, la matriz que gobierna la dinámica pasa a ser $A_i + B_i K$. Su abscisa espectral, cambiada de signo, es la **tasa de decaimiento** $\alpha = -\max_i \max \operatorname{Re} \lambda(A_i + B_i K)$. Mide *qué tan rápido* se extingue la peor respuesta: $\alpha > 0$ garantiza estabilidad, y cuanto mayor sea α , más rápido y con más margen vuelve el sistema al equilibrio. Un $\alpha \approx 0$ significa “estable, pero al borde”: el sistema apenas se sostiene sobre la frontera de la inestabilidad.

Otros indicadores. La *dispersión del politopo* $\max_i \|A_i - \bar{A}\|_2$ (con $\bar{A}$ el promedio de los vértices) mide qué tan distintos son los vértices entre sí, es decir, cuánta incertidumbre hay. El *número de condición* $\kappa(A_i)$ mide la sensibilidad numérica de la matriz (valores altos anticipan problemas de precisión). El *esfuerzo de control* $\|K\|_2$ mide qué tan “agresivo” es el controlador. La Tabla A.1 del Anexo A resume estos indicadores y su lectura.

3.1.2. Propósito y estructura

El conjunto de datos utilizado reúne sistemas lineales *politópicos* de tiempo continuo junto con una ley de realimentación de estado estática (*static state feedback*) que los estabiliza de forma robusta. Cada muestra es una terna $(\mathcal{A}, \mathcal{B}, K)$ donde el sistema incierto se describe como la envolvente

convexa de N vértices,

$$\dot{x}(t) = A(\eta)x(t) + B(\eta)u(t), \quad (A(\eta), B(\eta)) = \sum_{i=1}^N \eta_i (A_i, B_i), \quad \eta_i \geq 0, \sum_i \eta_i = 1, \quad (3.1)$$

con $A_i \in \mathbb{R}^{n_x \times n_x}$, $B_i \in \mathbb{R}^{n_x \times n_u}$, y $K \in \mathbb{R}^{n_u \times n_x}$ la ganancia común a todo el polígono, de modo que $u = Kx$.

La base de datos, originalmente contenida en un archivo MATLAB, organiza las muestras en un arreglo de celdas de cuatro índices, **BASE**[n_x, n_u, N, caso], de forma nominal $5 \times 2 \times 5 \times 500$. Cada celda poblada contiene los campos **A** (celda de N matrices A_i), **B** (celda de N matrices B_i) y **K**. La malla está poblada parcialmente: el orden mínimo depende del número de actuadores ($n_u=1 \Rightarrow n_x \in \{2, \dots, 5\}$; $n_u=2 \Rightarrow n_x \in \{3, 4, 5\}$) y siempre $N \geq 2$, de modo que de las 25 000 posiciones nominales sólo 28 celdas están ocupadas, con exactamente 500 casos cada una: en total **14 000** sistemas (8 000 con $n_u=1$ y 6 000 con $n_u=2$). El conjunto de datos descrito corresponde a sistemas cuadráticamente estabilizables, lo que se traduce en que cumplen la propiedad de que existe una matriz P para aplicar el método de Lyapunov. La base de datos incluye también otro conjunto de sistemas que son no cuadráticamente estabilizables. Este tipo de sistemas deben cumplir otras propiedades para certificar estabilidad por lo que el alcance para esta memoria solo considerará el subconjunto de sistemas cuadráticamente estabilizables. La Tabla A.2 detalla el esquema de campos y dimensiones.

3.1.3. Sistema en lazo abierto

Los sistemas son *difíciles*: el **98.8** % de estos es inestable en lazo abierto (al menos un vértice con autovalores en el semiplano derecho), y sólo un 1.2 % es estable sin control. La abscisa espectral del peor vértice tiene mediana 30.9 y alcanza valores de hasta ~ 832 (Fig. A.5), es decir, la base no contiene sistemas triviales.

En cuanto a las magnitudes (Fig. A.6), los descriptores presentan un rango dinámico amplio: $\max_i \|A_i\|_2$ va de 12 a 1012 (mediana 131) y crece de forma marcada con el orden n_x , mientras que $\max_i \|B_i\|_2$ se mantiene acotado en $[0.74, 16.8]$. Esta disparidad de escalas justifica la normalización aplicada en la ingesta: cada polígono se reescala por $\gamma_{esc} = \max(\max |A|, \max |B|)$ antes de entrar a la red, llevando todas las entradas a $[-1, 1]$ y homogeneizando las escalas entre sistemas (la normalización preserva el signo de los autovalores, luego no altera la propiedad de estabilizabilidad, aunque escala la tasa de decaimiento por $1/\gamma_{esc}$).

3.1.4. Geometría del politopo

La “extensión” de la incertidumbre se mide con la dispersión de los vértices respecto a su centroide, $\text{dispA} = \max_i \|A_i - \bar{A}\|_2$. Su mediana es 97.5 y crece de manera sistemática con el número de vértices N (Fig. A.7): más vértices implican polígonos más grandes y, por tanto, una incertidumbre más severa que el mismo certificado K debe cubrir simultáneamente. Esto vuelve a N un eje de

dificultad natural y motiva evaluar el modelo estratificado por N .

3.1.5. La ley de control y el lazo cerrado

Verificamos numéricamente la etiqueta de la base recomputando, para cada sistema, los autovalores de lazo cerrado de todos los vértices $A_i + B_i K$. El resultado demuestra que efectivamente el 100 % de los 14 000 sistemas queda con todos sus vértices en el semiplano izquierdo, es decir, la ganancia almacenada estabiliza efectivamente cada polígono. No se hallaron sistemas mal etiquetados ni ganancias inconsistentes.

Estabilización al borde. El cómo se estabiliza es el hallazgo más informativo. La tasa de decaimiento efectivamente lograda se concentra masivamente junto a cero, la mediana es $\alpha \approx 6.3 \times 10^{-4}$ y el **84.9%** de los sistemas es estable con el controlador propuesto pero de manera ineficiente o cercana a la inestabilidad ($\alpha < 10^{-2}$). La distribución es claramente bimodal (Fig. A.8). En otras palabras, la ganancia de referencia estabiliza de modo que coloca el polo dominante prácticamente sobre el eje imaginario lo cual si bien estabiliza, lo hace al límite. La Fig. A.9 muestra este desplazamiento en el plano complejo: los vértices de lazo abierto se extienden al semiplano derecho y el lazo cerrado queda íntegramente a la izquierda, pero pegado al eje imaginario.

Esfuerzo de control. El esfuerzo $\|K\|_2$ tiene mediana 17.4 y máximo 98.1. Éste se correlaciona fuertemente con la norma de los sistemas ($\rho_{\text{Spearman}} = 0.90$ con $\|A\|$), con el tamaño del polígono (0.85 con dispA) y con la inestabilidad de lazo abierto (0.63); sistemas más grandes e inestables exigen ganancias mayores (Fig. A.10). En contraste, α es estadísticamente independiente de todos los descriptores del sistema ($|\rho| \leq 0.04$ en todos los casos), lo que confirma que el margen no responde a la dificultad del problema sino a la propia construcción de la ganancia. La Tabla A.3 consolida los rangos de todos los descriptores sobre los 14 000 sistemas.

3.1.6. Implicaciones para el aprendizaje

El análisis sugiere varias decisiones de modelado:

1. **Normalización.** El rango dinámico de $\|A\|$ (tres décadas) hace inviable alimentar las matrices crudas por lo que es necesario aplicar un reescalamiento por γ_{esc} para condicionar el aprendizaje.
2. **Invarianzas a explotar.** El sistema es un *conjunto* de vértices $\{(A_i, B_i)\}$ (invariante a permutación y a cardinalidad N) cuyo certificado K es común; esto motiva un codificador invariante a N y, análogamente, equivariante al número de actuadores n_u .
3. **Estratificar por N .** Como la dificultad (tamaño del polígono) crece con N , conviene reportar el desempeño separado por número de vértices.

4. **Sobre la se1al de entrenamiento.** La ganancia de referencia es casi marginal y su α no informa sobre el sistema; esto avala usar un objetivo *auto-supervisado* de factibilidad/volumen (estabilizaci3n con margen α prescrito) en lugar de regresar directamente la K almacenada.

3.2. Formulaci3n Original de LMI-Net

La arquitectura empleada como punto de partida de este estudio es *LMI-Net*, propuesta por Tang, Goertzen y Azizan [28]. Esta secci3n describe la formulaci3n original de manera fiel al art3culo, en el contexto en que fue propuesta y validada: sistemas lineales invariantes en el tiempo (LTI) individuales.

3.2.1. El Problema de Optimizaci3n Parametrizada

LMI-Net aborda la siguiente familia de problemas de optimizaci3n, parametrizada por un vector $\xi_{net} \in \mathbb{R}^p$ que codifica los datos de cada instancia y que constituye la entrada de la red¹:

$$\min_y c(y) \quad \text{sujeto a} \quad F(y; \xi_{net}) \triangleq F_0(\xi_{net}) + \sum_{i=1}^m y_i F_i(\xi_{net}) \succeq 0, \quad (3.2)$$

donde las matrices sim3tricas $F_i(\xi_{net})$ son conocidas, $c(\cdot)$ es una funci3n de costo e $y \in \mathbb{R}^m$ es la variable de decisi3n. La soluci3n 3ptima es, por tanto, una funci3n del par3metro: $y^*(\xi_{net})$. Esta estructura captura numerosos problemas de la teor3a de control en los que la plantilla del problema (objetivo y forma de las restricciones) permanece fija mientras ξ_{net} recorre una familia de sistemas: en tales escenarios, invocar un solucionador num3rico para cada instancia resulta computacionalmente costoso, y aprender el mapa $\xi_{net} \mapsto y^*(\xi_{net})$ permite desplazar dicho costo hacia una etapa *offline* de entrenamiento, reduciendo la resoluci3n de cada instancia nueva a una evaluaci3n de funci3n.

El aprendizaje de este mapa se plantea de forma auto-supervisada, lo que se traduce en que en lugar de generar etiquetas $y^*(\xi_{net})$ con un solucionador, la funci3n de p3rdida se define como el costo promedio evaluado sobre las predicciones de la red,

$$\mathcal{L}(\theta) = \frac{1}{N_{train}} \sum_{i=1}^{N_{train}} c(\hat{y}(\xi_{net}^{(i)}; \theta)), \quad (3.3)$$

con la exigencia cr3tica de que la restricci3n $F(\hat{y}; \xi_{net}) \succeq 0$ se satisfaga para *todo* par3metro admisible, no solo para los vistos en entrenamiento. Es precisamente esta exigencia la que motiva el mecanismo central de la arquitectura: una proyecci3n diferenciable que impone la factibilidad por construcci3n.

¹Se emplea el sub3ndice $(\cdot)_{net}$ para distinguir este vector de datos de instancia del par3metro de operaci3n $\xi(t) \in \Xi$ del modelo LPV del Cap3tulo 2. Ambos comparten el rol de “par3metro que indexa una familia de problemas”, pero el primero es una codificaci3n num3rica fija por sistema y el segundo, una se1al variante en el tiempo.

3.2.2. Visión General de la Arquitectura

La arquitectura se compone de dos módulos secuencialmente acoplados. El primero, el *backbone*, es una red neuronal densa convencional que transforma el parámetro del sistema ξ_{net} en una estimación cruda y no restringida $\hat{y}_\theta$ de la variable de decisión. Esta predicción no ofrece garantía alguna de factibilidad: nada en su cálculo impide que viole la LMI. El segundo módulo, la capa de proyección, recibe esta estimación y la desplaza hasta el conjunto factible mediante un procedimiento iterativo determinista basado en el algoritmo de Douglas–Rachford, entregando una salida y^* que satisface la restricción con independencia de la calidad de la predicción inicial. La Figura 3.1 resume este flujo.




Figura 3.1: Flujo de la arquitectura LMI-Net en su formulación original [28]: el *backbone* propone una estimación cruda $\hat{y}_\theta$ que la capa de proyección corrige hasta satisfacer la LMI por construcción.

3.2.3. Problema de Referencia: Diseño Conjunto de Controlador y Elipsoide Invariante

El artículo original valida la arquitectura sobre el problema de sintetizar, de forma conjunta, una ganancia de realimentación K y un elipsoide invariante (Ec. (2.33)), expresado en la variable $Q = P^{-1}$ para un sistema LTI sujeto a una perturbación de energía acotada:

$$\dot{x} = Ax + Bu + B_w w, \quad w^\top w \leq 1, \quad (3.4)$$

bajo la ley de control $u = Kx$. Aplicando el cambio de variables $Q = P^{-1}$, $Y = KQ$ presentado en la Sección 2 y el procedimiento S (*S-procedure*) [32, 9] para incorporar la cota de la perturbación, el problema se reduce a la desigualdad matricial:

$$\begin{bmatrix} QA^\top + AQ + Y^\top B^\top + BY + \alpha_s Q & B_w \\ B_w^\top & -\alpha_s I \end{bmatrix} \preceq 0, \quad Q \succeq \epsilon_{pos} I, \quad (3.5)$$

donde $\alpha_s > 0$ es el multiplicador del procedimiento S, fijado a priori ($\alpha_s = 0.1$ en los experimentos del artículo), y $\epsilon_{pos} = 10^{-3}$ garantiza la positividad estricta de Q . Resuelto el problema, el controlador se recupera como $K = YQ^{-1}$.

En la instancia experimental del artículo, con $n_x = 2$, $n_u = 1$ y $n_w = 1$, el parámetro de entrada es $\xi_{net} = (\text{vech}(A), \text{vec}(B), \text{vec}(B_w)) \in \mathbb{R}^7$ y la variable de decisión $y = (\text{vech}(Q), \text{vec}(Y)) \in \mathbb{R}^5$ codifica los $\frac{n_x(n_x+1)}{2} = 3$ grados de libertad de la matriz simétrica Q y los $n_u \cdot n_x = 2$ de la ganancia

Y .

3.2.4. Levantamiento del Espacio de Restricciones

Proyectar la salida no restringida de la red directamente sobre el conjunto definido por la Ec. (3.5) no admite una solución analítica cerrada. La arquitectura sortea esta dificultad mediante un esquema de levantamiento: se introduce una variable matricial auxiliar X que eleva el problema a un espacio de mayor dimensión, descomponiendo la restricción en la intersección de dos conjuntos convexos con proyecciones individuales calculables en forma cerrada:

$$\mathcal{C}_1 = \{(y, X) : F(y) = X\}, \quad \mathcal{C}_2 = \{(y, X) : y \in \mathbb{R}^m, X \succeq 0\}, \quad (3.6)$$

donde $\mathcal{C}_1$ es un subespacio afín y $\mathcal{C}_2$ es el cono semidefinido positivo estándar. Para el problema de referencia, el mapa afín $F(y)$ agrupa ambas condiciones de la Ec. (3.5) en una única matriz bloque-diagonal:

$$F(y) = \text{diag} \left(-M(y), Q - \epsilon_{pos} I \right) \succeq 0, \quad (3.7)$$

donde $M(y)$ denota el bloque izquierdo de la Ec. (3.5). Nótese que tanto el multiplicador α_s como el margen ϵ_{pos} quedan absorbidos dentro de la estructura afín de F y no en el cono, de modo que la proyección sobre $\mathcal{C}_2$ es la proyección clásica sobre el cono PSD, con recorte espectral en cero. La equivalencia $F(y) \succeq 0 \iff$ Ec. (3.5) se cumple ya que una matriz bloque-diagonal es semidefinida positiva si y solo si cada uno de sus bloques lo es.

3.2.5. Pase hacia Adelante: Algoritmo de Douglas-Rachford

Una vez que el problema se ha separado en los conjuntos $\mathcal{C}_1$ y $\mathcal{C}_2$, se requiere un método capaz de encontrar un punto en su intersección $\mathcal{C}_1 \cap \mathcal{C}_2$. Esta etapa de propagación hacia adelante (*forward pass*) instancia, de manera concreta, la Fase 1 del esquema general presentado en el Algoritmo 2, mediante el algoritmo de división de Douglas–Rachford (DR).

Operaciones de Proyección

Cada iteración requiere resolver dos subproblemas de proyección independientes, ambos con solución analítica cerrada.

Proyección sobre el subespacio afín $\mathcal{C}_1$. Dado que $F(y)$ es una función afín de y , la restricción $F_0 + \sum y_i F_i = X$ puede reescribirse en forma vectorizada como

$$\text{vec}(F(y)) = Ly + c, \quad (3.8)$$

donde L es una matriz constante (pues F es afín en (Q, Y)) y $c = \text{vec}(F_0)$. La proyección euclidiana sobre $\mathcal{C}_1$ se reduce a un problema de mínimos cuadrados cuya solución cerrada involucra la matriz

$M^{-1} = (I + L^\top L)^{-1}$. Como M^{-1} depende únicamente de la topología fija del sistema y no cambia entre iteraciones, se precomputa una única vez antes del bucle iterativo, reduciendo el costo de esta proyección, en cada paso, al de una simple multiplicación matricial.

Proyección sobre el cono semidefinido positivo $\mathcal{C}_2$. Dada una matriz simétrica X , su proyección sobre el cono PSD se calcula por bloques: para cada bloque de la Ec. (3.7) se obtiene la descomposición espectral $X = V\Lambda V^\top$, se recortan los autovalores negativos ($\lambda_i \mapsto \max(\lambda_i, 0)$) y se reconstruye la matriz. La positividad estricta de Q no requiere desplazar el cono: está garantizada por el bloque $Q - \epsilon_{pos}I$ dentro de F .

Iteración de Douglas–Rachford

El algoritmo mantiene un estado conjunto (y_k, x_k) , donde y_k evoluciona en el espacio de parámetros y x_k en el espacio matricial levantado, y combina en cada paso tres operaciones: un anclaje hacia la predicción de la red, una proyección sobre el subespacio afín $\mathcal{C}_1$ y una proyección espectral sobre el cono $\mathcal{C}_2$, articuladas mediante un paso de reflexión. El escalar $\sigma_{anc} > 0$ actúa como peso de fidelidad o *anclaje*: pondera cuánto se atrae el iterado hacia la predicción cruda $\hat{y}_\theta$, de modo que la capa no entregue un punto factible arbitrario sino uno próximo a la propuesta del *backbone*. El procedimiento completo se formaliza en el Algoritmo 3.

Cabe destacar una propiedad más fuerte que la mera factibilidad. Dado que el término de anclaje ponderado por σ_{anc} incorpora la distancia $\|y - \hat{y}_\theta\|^2$ al objetivo que el algoritmo minimiza, el punto fijo del procedimiento no es un punto factible arbitrario: es la **proyección euclidiana** de la predicción cruda sobre el conjunto factible, es decir, el punto factible más cercano a la propuesta de la red. En consecuencia, la capa preserva tanta información de la predicción del *backbone* como la restricción lo permite, y la calidad de dicha predicción se traduce directamente en la velocidad de convergencia del solucionador.

La Figura A.11 ilustra esquemáticamente este proceso: partiendo de una predicción $\hat{y}_\theta$ que puede encontrarse fuera de ambos conjuntos, cada iteración alterna una proyección sobre el subespacio afín $\mathcal{C}_1$ y una proyección sobre el cono $\mathcal{C}_2$, generando una trayectoria en zigzag de amplitud decreciente. Bajo las hipótesis estándar de convergencia del método —conjuntos cerrados, convexos y de intersección no vacía—, la sucesión converge a un punto factible $y^* \in \mathcal{C}_1 \cap \mathcal{C}_2$, con independencia del punto de partida [21, 6].

3.2.6. Pase hacia Atrás: Diferenciación Implícita

Para que la red neuronal actualice sus pesos mediante retropropagación, es necesario calcular el gradiente de la función de pérdida con respecto a los parámetros del *backbone*, lo cual exige propagar el gradiente a través de la capa de proyección iterativa. Al no ser esta una función explícita sino el resultado de un proceso de optimización de punto fijo, existen dos estrategias fundamentalmente distintas para calcular esta propagación, formalizadas de manera general en la Fase 2 del Algoritmo 2

(Sección 2). La formulación original adopta la primera de ellas —la diferenciación implícita—, que se describe a continuación; la segunda —el desenrollado algorítmico— constituye una de las contribuciones de esta memoria y se desarrolla en la Sección 3.5.

Para entrenar la red es necesario propagar el gradiente de la pérdida a través de la capa de proyección. Dado que esta no es una función explícita sino el resultado de un proceso iterativo, la formulación original resuelve el problema mediante diferenciación implícita, siguiendo el esquema introducido en [16] y común a las arquitecturas de punto fijo diferenciables [4, 15]. La observación central es que el estado de convergencia $s^* = (y^*, x^*)$ es, por definición, un punto fijo del operador T de una iteración de Douglas–Rachford:

$$s^* = T(s^*, \hat{y}_\theta). \quad (3.9)$$

Diferenciando ambos lados mediante el Teorema de la Función Implícita, el gradiente de la salida respecto de la predicción cruda satisface el sistema lineal

$$\left(I - \frac{\partial T}{\partial s} \Big|_{s^*} \right) \frac{\partial s^*}{\partial \hat{y}_\theta} = \frac{\partial T}{\partial \hat{y}_\theta} \Big|_{s^*}, \quad (3.10)$$

evaluado únicamente en el punto de convergencia, sin almacenar iteración intermedia alguna. En la práctica no se resuelve el sistema completo: durante la retropropagación solo se requiere el producto vector-Jacobiana (VJP) del gradiente entrante contra esta Jacobiana, lo que se obtiene resolviendo un único sistema lineal adjunto por muestra y aplicando diferenciación automática a una sola iteración del operador T .

Las consecuencias prácticas de este diseño son dos. Primero, el costo de memoria del pase hacia atrás es constante respecto del número de iteraciones del solucionador, lo que permite entrenar con un número elevado de iteraciones (500 en los experimentos del artículo) sin tener problemas de memoria. Segundo, el gradiente obtenido es el gradiente exacto en el punto fijo, y no una aproximación dependiente de la profundidad del desenrollado. Como se discutirá en la Sección 3.3, esta exactitud interactúa de manera no trivial con la elección de la función de pérdida, hallazgo que motiva una de las contribuciones experimentales de esta memoria.

3.2.7. Configuración de Entrenamiento de la Formulación Original

La Tabla A.4 resume la configuración de entrenamiento de la formulación original. El *backbone* consiste en un Perceptrón Multicapa de dos capas ocultas de 64 neuronas con activación ReLU, entrenado con el optimizador Adam [18]. Durante el entrenamiento, la capa de proyección ejecuta 500 iteraciones de Douglas–Rachford con peso de anclaje $\sigma_{anc} = 0.01$; en inferencia, el número de iteraciones se trata como un parámetro libre que intercambia velocidad por precisión de factibilidad sin necesidad de reentrenar.

La función de pérdida del artículo combina el criterio de desempeño con un término de regularización

espectral:

$$\mathcal{L}(\theta) = \frac{1}{N_{train}} \sum_{i=1}^{N_{train}} \left[\log \det(Q^{(i)}) - \beta_{soft} \lambda_{min}(F(y^{*(i)})) \right], \quad \beta_{soft} = 100, \quad (3.11)$$

evaluada sobre la salida proyectada y^* . El primer término minimiza el volumen del elipsoide invariante que corresponde al conjunto de la Ec. (2.33) del marco teórico expresado en la variable $Q = P^{-1}$: dado que su volumen es proporcional a $\sqrt{\det(Q)}$, minimizar $\log \det(Q)$ confina los estados en la región de atracción más compacta posible, como ilustra la Figura A.12. El segundo término cumple una doble función según el signo del autovalor mínimo de F : cuando es negativo, penaliza la violación residual de la restricción que subsiste tras un número finito de iteraciones del solucionador; cuando es positivo, recompensa que la solución mantenga un margen hacia el interior del cono, alejándola de la frontera de factibilidad.

Con esta configuración, el artículo reporta que la arquitectura alcanza cero violaciones de la restricción con 3000–4000 iteraciones de inferencia, igualando la factibilidad del solucionador convexo de referencia (CVXPY/SCS) con tiempos de cómputo entre 3.5 y 35 veces menores.

3.2.8. Limitaciones de la Formulación Original

La formulación original, si bien introduce un mecanismo novedoso con garantías formales de factibilidad, presenta limitaciones inherentes a su diseño y a su protocolo de validación. Identificarlas con precisión es relevante porque varias de ellas motivan directamente el aporte de esta memoria.

Validación Restringida a Sistemas LTI Individuales de Baja Dimensión

Los experimentos del artículo se limitan a sistemas de segundo orden ($n_x = 2$) con un actuador, donde cada instancia es un único sistema LTI. La arquitectura no fue evaluada sobre familias de sistemas que deban compartir un certificado común de estabilidad, escenario estructuralmente más exigente que constituye el núcleo del control robusto politópico. Adicionalmente, la parametrización de entrada $\text{vech}(A)$ y la construcción espectral de los conjuntos de datos restringen los experimentos a matrices de estado simétricas, una clase de dinámicas de espectro real que excluye, entre otros, los modos oscilatorios y los fenómenos de crecimiento transitorio asociados a la no-normalidad.

Rigidez Dimensional del *Backbone*

El *backbone* asume una dimensionalidad de entrada fija, determinada por el tamaño del vector ξ_{net} . Los propios autores señalan como trabajo futuro la necesidad de escalar hacia “*advanced backbone architectures*” para problemas de mayor dimensión. Esta limitación se agudiza en el contexto politópico, donde la descripción del sistema deja de ser un vector de tamaño fijo para convertirse en un conjunto de cardinalidad variable.

3.3. Extensión a la Estabilización Robusta de Sistemas Politópicos

La formulación original de LMI-Net, descrita en la Sección 3.2, fue propuesta y validada para instancias LTI individuales. Esta sección desarrolla el aporte central de esta memoria: la extensión de dicha arquitectura a la estabilización robusta de sistemas LPV politópicos, una clase de problemas estructuralmente más exigente. La extensión se articula en torno a dos ejes de diseño ortogonales entre sí, que en conjunto definen el espacio experimental de esta investigación: el primero concierne a la representación y procesamiento de la entrada, el cómo una red neuronal debe ingerir un polítopo de cardinalidad variable, y se desarrolla en la Sección 3.4; el segundo concierne a la estrategia de retropropagación a través de la capa de proyección, donde esta memoria introduce y estudia una alternativa al esquema implícito original.

3.3.1. Estabilidad Cuadrática con Tasa de Decaimiento

Considérese el sistema politópico de la Ec. (3.1), definido por la envolvente convexa de N vértices $\{(A_i, B_i)\}$ con coeficientes $\eta \in \Delta_N$, donde Δ_N denota el simplex unitario (Sección 2, Ec. (2.13)). Se busca una única ley de realimentación estática $u = Kx$, común a todo el polítopo, que garantice estabilidad exponencial con tasa de decaimiento prescrita $\alpha > 0$ para toda trayectoria admisible del parámetro. Bajo la parametrización $Q = P^{-1}$, $Y = KQ$ introducida en la Ec. (2.31), dicha garantía se obtiene si el par (Q, Y) satisface simultáneamente las $N + 1$ condiciones

$$A_i Q + Q A_i^\top + B_i Y + Y^\top B_i^\top + 2\alpha Q \prec 0 \quad \forall i \in \{1, \dots, N\}, \quad Q \succeq \epsilon_{pos} I, \quad (3.12)$$

que corresponden a la LMI de síntesis del marco teórico (Ec. (2.31)) aumentadas con el término de decaimiento $2\alpha Q$, lo cual es equivalente a exigir la condición de Lyapunov sobre las matrices desplazadas $A_i + \alpha I$, y con el margen de positividad estricta sobre el certificado.

3.3.2. Construcción Bloque-Diagonal

La formulación general del problema parametrizado (Ec. (3.2)) admite, como observan los propios autores, la representación de múltiples LMIs simultáneas mediante una única matriz bloque-diagonal. Sin embargo, el trabajo original no instancia ni evalúa esta posibilidad al tener que sus experimentos involucran una única desigualdad por sistema. Esta investigación consiste en explotar dicha estructura para el caso robusto politópico, apilando las N condiciones de vértice y la condición de positividad de la Ec. (3.12) en un único mapa afín:

$$F(y) = \text{diag} \left(F^{(1)}(y), \dots, F^{(N)}(y), Q - \epsilon_{pos} I \right) \succeq 0, \quad (3.13)$$

donde cada bloque de vértice se define como

$$F^{(i)}(y) = -(A_i Q + Q A_i^\top + B_i Y + Y^\top B_i^\top + 2\alpha Q). \quad (3.14)$$

Dado que una matriz bloque-diagonal es semidefinida positiva si y solo si todos sus bloques lo son, la condición $F(y) \succeq 0$ es exactamente equivalente al sistema de la Ec. (3.12). La consecuencia central de esta construcción es que la proyección descrita en la Sección 3.2 se preserva íntegra de modo que F sigue siendo afín en y , por lo que el subespacio $\mathcal{C}_1$, la matriz precomputada $M^{-1} = (I + L^\top L)^{-1}$ y el Algoritmo 3 operan sin modificación alguna; lo único que cambia es la dimensión del espacio levantado, cuyo número de bloques pasa de 2 a $N + 1$.

La proyección sobre el cono PSD se realiza bloque a bloque, mediante $N + 1$ descomposiciones espectrales independientes de matrices $n_x \times n_x$, con costo $O((N + 1)n_x^3)$; tratar F como una matriz monolítica de dimensión $(N + 1)n_x$ elevaría dicho costo a $O((N + 1)^3 n_x^3)$. Adicionalmente, la matriz M^{-1} de la proyección afín conserva la dimensión del vector de decisión ($\dim y \times \dim y$), independiente de N : el crecimiento del polítopo engrosa el operador L , pero no el sistema lineal que se resuelve en cada iteración. Estas propiedades anticipan un comportamiento de escalamiento favorable frente a solucionadores genéricos, hipótesis que se evalúa empíricamente en el Capítulo 4.

3.3.3. Adaptación del Problema de Referencia

La instancia experimental de esta memoria difiere de la del artículo original en un aspecto impuesto por los datos disponibles: la base de datos utilizada (Sección 3.1) caracteriza cada sistema únicamente por sus vértices $\{(A_i, B_i)\}$, sin incluir el canal de perturbación exógena B_w . En consecuencia, el problema de diseño conjunto bajo perturbación acotada de la Ec. (3.5) no es reproducible sobre esta base, y el criterio de certificación adoptado es la estabilización robusta con tasa de decaimiento prescrita de la Ec. (3.12). Cabe precisar que el elipsoide $\mathcal{E}(Q)$ de la Ec. (2.33) conserva su carácter de conjunto invariante —como conjunto de nivel del certificado de Lyapunov del lazo cerrado—, aunque su interpretación deja de estar ligada al rechazo de una perturbación específica. La Tabla A.5 resume la correspondencia completa entre ambas instancias.

3.4. Arquitecturas de Codificación del Polítopo

Esta sección desarrolla el primer eje de diseño de la extensión politópica: la representación de la entrada. Se estudian tres arquitecturas de codificador que incorporan, de forma progresiva, los sesgos inductivos que la estructura del problema pone a disposición. Las tres comparten íntegramente el resto de la cadena, producen una predicción cruda $\hat{y}_\theta \in \mathbb{R}^{\dim y}$ que la misma capa de proyección de la Sección 3.2 corrige hasta la factibilidad, de modo que cualquier diferencia de desempeño entre ellas es atribuible exclusivamente a la representación, condición necesaria para el estudio comparado del Capítulo 4.

3.4.1. El Polítopo como Conjunto: Asimetría entre Entrada y Salida

La adaptación directa de la arquitectura original consiste en aplanar y concatenar todos los vértices en un único vector de características, de dimensión $N(n_x^2 + n_x n_u)$ —por ejemplo, 24 entradas para la configuración $n_x = 3$, $n_u = 1$, $N = 2$, con salida de $\dim y = \frac{n_x(n_x+1)}{2} + n_u n_x = 9$ parámetros. Esta

representación, empleada como línea base en esta memoria, arrastra dos defectos estructurales. El primero es la rigidez de cardinalidad: la dimensión de entrada depende de N , obligando a entrenar una arquitectura distinta para cada tamaño de polítopo. El segundo deriva de si consideramos que un polítopo es un conjunto de vértices sin orden intrínseco. Permutar los vértices describe exactamente el mismo sistema incierto y admite exactamente el mismo certificado, pero el vector aplanado impone un orden arbitrario, forzando a la red a consumir capacidad y datos en aprender una invarianza que la estructura del problema otorga de antemano.

3.4.2. Codificador Aplanado

La primera arquitectura es la adaptación aplanada ya descrita: el vector de la Ec. (3.15),

$$\xi_{net} = [\text{vec}(A_1), \dots, \text{vec}(A_N), \text{vec}(B_1), \dots, \text{vec}(B_N)] \in \mathbb{R}^{N(n_x^2 + n_x n_u)}, \quad (3.15)$$

alimenta el *backbone* del artículo original: un perceptrón multicapa de dos capas ocultas de 64 neuronas con activación ReLU, sin normalización interna. Esta arquitectura se implementa como reproducción fiel de la original, incluidos sus valores por defecto de entrenamiento, lo que establece qué desempeño es alcanzable sin sesgo inductivo alguno, cargando con los dos defectos estructurales recién identificados. En particular, la rigidez de su capa de entrada tiene una consecuencia que se explotará: una red entrenada sobre una topología (n_x, n_u, N) es incapaz de procesar cualquier otra, de modo que cubrir la malla completa de la base de datos exigiría entrenar y mantener 28 redes independientes.

3.4.3. Invarianza de Conjunto sobre los Vértices

El primer defecto se resuelve reconociendo que toda función invariante a permutación sobre un conjunto admite una descomposición en suma [34]: existe un codificador por elemento ϕ y un decodificador ρ tales que

$$f(\{x_1, \dots, x_N\}) = \rho \left(\text{pool}_{i=1}^N \phi(x_i) \right), \quad (3.16)$$

donde *pool* es una agregación simétrica (el promedio, en esta implementación). El codificador de vértices instancia este esquema *Deep Sets* formando una ficha por vértice, $x_i = [\text{vec}(A_i), \text{vec}(B_i)] \in \mathbb{R}^{n_x^2 + n_x n_u}$, procesada por una red ϕ de pesos compartidos; el promedio sobre vértices produce un resumen del polítopo de dimensión fija que ρ transforma en $\hat{y}_\theta$. Así, tenemos que la salida es exactamente invariante al orden de los vértices y la arquitectura procesa cualquier cardinalidad N sin reentrenar.

3.4.4. Arquitectura Propuesta: Codificador de Actuadores en Dos Ejes

Las Dos Simetrías del Problema

El sistema politópico posee dos grupos de transformaciones que dejan el problema de síntesis esencialmente inalterado, pero que actúan sobre la salida de manera distinta. La primera es la ya

discutida permutación de vértices: reordenar $\{(A_i, B_i)\}$ describe el mismo sistema incierto y admite el mismo certificado, de modo que la salida completa (Q, Y) debe ser **invariante**. La segunda es la permutación de actuadores: reetiquetar las columnas de B mediante una matriz de permutación $\Pi \in \mathbb{R}^{n_u \times n_u}$ describe el mismo sistema físico con sus entradas reenumeradas. El lazo cerrado revela cómo debe transformarse el certificado:

$$A_i + (B_i \Pi)(\Pi^\top K) = A_i + B_i K, \quad (3.17)$$

es decir, el sistema reetiquetado se estabiliza con la ganancia de filas permutadas $K' = \Pi^\top K$ y el *mismo* certificado de Lyapunov. Bajo la parametrización $Y = KQ$, la simetría se reparte entre las dos mitades de la salida: $Q \mapsto Q$ es **invariante** e $Y \mapsto \Pi^\top Y$ es **equivariante** (sus filas se permutan junto con los actuadores).

Factorización en Fichas por Vértice y Actuador

En lugar de una ficha por vértice, el codificador de actuadores forma una ficha por cada par (vértice i , actuador j), emparejando la dinámica completa del vértice con una sola columna de su matriz de entrada:

$$t_{ij} = [\text{vec}(A_i), b_{ij}] \in \mathbb{R}^{n_x^2 + n_x}, \quad i = 1, \dots, N, \quad j = 1, \dots, n_u, \quad (3.18)$$

donde b_{ij} es la j -ésima columna de B_i . La dimensión de la ficha depende únicamente del orden n_x : ni la cardinalidad del polítopo ni el número de actuadores aparecen en ella, de modo que una única red ϕ de pesos compartidos procesa la malla topológica completa. La agregación procede entonces en dos ejes sucesivos, uno por simetría. El promedio sobre el eje de los vértices produce un resumen por actuador,

$$u_j = \frac{1}{N} \sum_{i=1}^N \phi(t_{ij}), \quad (3.19)$$

que condensa cómo el actuador j interactúa con la incertidumbre de todo el polítopo; y el promedio sobre el eje de los actuadores produce el resumen global del sistema,

$$z = \frac{1}{n_u} \sum_{j=1}^{n_u} u_j. \quad (3.20)$$

Salida Dividida

La salida se ensambla respetando la estructura mixta de la simetría. La mitad invariante del certificado se produce desde el resumen global,

$$\text{vech}(Q) = \rho_Q(z), \quad (3.21)$$

mientras que cada fila de Y —la porción de la ganancia asociada al actuador j — se produce desde el resumen de ese actuador, concatenado con el contexto global:

$$Y_{j,:} = \rho_Y([u_j, z]), \quad j = 1, \dots, n_u. \quad (3.22)$$

La equivariancia es consecuencia directa del reparto de pesos: como la misma red ρ_Y evalúa todos los actuadores, permutar las columnas de B permuta los resúmenes u_j y, con ellos, las filas de Y , exactamente la transformación que la Ec. (3.17) exige; el resumen z , y por lo tanto Q , permanecen intactos al ser el promedio insensible al orden. El número de filas producidas se adapta, además, al número de actuadores de cada instancia, completando la independencia dimensional: una sola red cubre cualquier par (N, n_u) , y las 28 redes de la línea base se reducen a 4, una por orden n_x —la única dependencia dimensional residual de la arquitectura, heredada del tamaño de la ficha (Ec. (3.18)). La Figura A.13 del Anexo A ilustra el flujo completo del codificador sobre un ejemplo con $N = 2$ vértices y $n_u = 2$ actuadores.

3.4.5. Elementos Comunes de Implementación

Los dos encoders del conjunto comparten la misma arquitectura. Las redes ϕ , ρ , ρ_Q y ρ_Y son perceptrones de dos capas de 128 neuronas, cada transformación lineal seguida de normalización de capa [3] y activación Mish [23]. Dicha transformación homogeneiza internamente magnitudes que, incluso tras el reescalamiento físico de la ingesta, varían entre sistemas, manteniendo acotadas las entradas al solucionador iterativo; y la suavidad de Mish, frente a la no diferenciabilidad de ReLU en el origen, produce paisajes de gradiente más regulares al retropropagar a través de las iteraciones de la proyección. La línea base conserva deliberadamente la receta original (ReLU, sin normalización), pues su rol es reproducir fielmente el punto de comparación. La Tabla A.6 sintetiza los tres peldaños.

3.5. Desenrollado frente a Diferenciación Implícita

La formulación original calcula los gradientes exclusivamente mediante diferenciación implícita (Sección 3.2.6). Esta memoria implementa adicionalmente una segunda estrategia que denominaremos desenrollado algorítmico (*algorithm unrolling*), y estudia ambas de forma comparada. El principio de esta estrategia consiste en que cada iteración del ciclo de Douglas–Rachford se trata como una capa diferenciable más del grafo computacional; si el solucionador ejecuta K_{it} iteraciones, el motor de diferenciación aplica la regla de la cadena a través de las K_{it} operaciones hasta alcanzar los pesos del *backbone*. La estrategia no requiere derivación adicional alguna, pero su costo de memoria crece linealmente con K_{it} , pues el grafo completo debe almacenarse para el pase hacia atrás. Esto obliga, en la práctica, a truncar el número de iteraciones durante el entrenamiento muy por debajo del utilizado en inferencia, donde el pase hacia adelante no acarrea grafo y puede ejecutarse hasta la convergencia. Ambas estrategias comparten exactamente el mismo pase hacia adelante y son intercambiables con cualquier arquitectura de *backbone*, lo que permite aislar experimentalmente el efecto del gradiente. La Tabla A.7 resume sus diferencias.

A priori, la comparación parece favorecer sin ambigüedad a la diferenciación implícita: gradiente exacto y memoria constante. Sin embargo, esta memoria plantea como hipótesis de diseño (y verifica experimentalmente en el Capítulo 4) que la exactitud del gradiente interactúa de manera no trivial con la función de pérdida. Cuando el criterio de desempeño alcanza su óptimo sobre la frontera del conjunto factible, el gradiente exacto conduce a la red a proponer certificados al borde de la factibilidad, mientras que la imprecisión del desenrollado truncado opera como una regularización implícita hacia soluciones más conservadoras.

3.6. Funciones de Pérdida

Dado que la capa de proyección asume íntegramente la responsabilidad de la factibilidad, la función de pérdida cumple un rol distinto al habitual: no discrimina entre soluciones válidas e inválidas, sino que selecciona *en qué punto de la región factible* se sitúa el certificado. Esta memoria estudia una familia de seis criterios auto-supervisados que difieren precisamente en su tratamiento de la frontera de dicha región. Todos se evalúan sobre la salida proyectada (Q, Y) y todos se minimizan. En lo que sigue, $\lambda_{\min}(F(y^*))$ denota el menor autovalor sobre los $N + 1$ bloques de la construcción bloque-diagonal de la Ec. (3.13): cuando es negativo mide la violación residual de la LMI tras un número finito de iteraciones del solucionador; cuando es positivo mide la holgura o *margen interior* del certificado respecto de la frontera de factibilidad.

3.6.1. Criterio de Referencia: Volumen con Margen Lineal (paper)

La línea base es la pérdida de la formulación original [28], ya presentada en la Ec. (3.11). El primer término minimiza el volumen del elipsoide invariante $\mathcal{E}(Q)$; el segundo recompensa linealmente y sin cota el alejamiento de la frontera de factibilidad. Su traslado al caso politópico es directo: el único cambio es que $\lambda_{\min}$ se calcula ahora sobre los $N + 1$ bloques.

3.6.2. Criterio de Volumen y Esfuerzo Sustituto (control)

La segunda pérdida reemplaza el criterio de volumen logarítmico por su sustituto convexo lineal, la traza, y añade una penalización barata del esfuerzo de control:

$$\mathcal{L}_{\text{control}} = \text{tr}(Q) + \mu \|Y\|_F^2, \quad \mu = 0.1. \quad (3.23)$$

La sustitución responde a dos motivos. El primero corresponde a la desigualdad entre medias aritmética y geométrica, $\text{tr}(Q) \geq n_x \det(Q)^{1/n_x}$, de modo que minimizar la traza acota superiormente el volumen del elipsoide; el uso de la traza como criterio convexo de tamaño del elipsoide es estándar en la literatura de optimización LMI [9, 31]. El segundo es que el gradiente de $\log \det(Q)$ diverge cuando Q se aproxima a la singularidad —situación frecuente en épocas tempranas de entrenamiento—, mientras que la traza es lineal en los autovalores y permanece acotada. El término $\|Y\|_F^2$ opera como sustituto de bajo costo del esfuerzo de control, pues $Y = KQ$ crece con la agresividad de la ganancia.

3.6.3. Criterio de Volumen con Piso Espectral (`control_margen`)

Los criterios de volumen —tanto $\log \det(Q)$ como $\text{tr}(Q)$ — comparten un defecto: su óptimo empuja a Q hacia la casi-singularidad, la esquina de la región factible donde la ganancia recuperada $K = YQ^{-1}$ se dispara y el solucionador iterativo se ralentiza. Para contrarrestarlo, esta variante añade a la Ec. (3.23) un piso prescrito sobre el menor autovalor de Q , relajación suave de la restricción de buen condicionamiento $Q \succeq \tau I$ empleada en la síntesis LMI clásica para excluir certificados degenerados [9]:

$$\mathcal{L}_{cm} = \mathcal{L}_{control} + \text{relu}(\tau - \lambda_{\min}(Q)), \quad \tau = 0.05, \quad (3.24)$$

El término de bisagra (*hinge*) penaliza los certificados cuya matriz Q se aproxima a la singularidad y se anula por completo cuando $\lambda_{\min}(Q) \geq \tau$, permitiendo que el criterio de volumen opere sin interferencia una vez asegurado el piso. Nótese que, a diferencia del margen de la Ec. (3.11), aquí la cantidad protegida no es la holgura de la LMI completa sino el espectro del propio certificado Q : la hipótesis de diseño es que el condicionamiento de Q —y no la distancia a la frontera en el espacio levantado— es la variable que gobierna la degradación fuera de distribución, conjetura que el análisis experimental del Capítulo 4 somete a prueba.

3.6.4. Criterio de Esfuerzo de Control Efectivo (`esfuerzo`)

La cuarta pérdida penaliza directamente la magnitud de la ganancia efectiva del controlador, en lugar de su sustituto $\|Y\|_F$:

$$\mathcal{L}_{esf} = \|K\|_F^2 = \|YQ^{-1}\|_F^2. \quad (3.25)$$

Controladores de ganancia acotada son deseables en la práctica porque reducen la saturación de actuadores y la amplificación de ruido de medición, el mismo principio que motiva la penalización cuadrática del esfuerzo en el regulador lineal cuadrático [1]; en la síntesis LMI, la limitación de la norma de la ganancia y de la señal de control se impone mediante restricciones adicionales sobre el par (Q, Y) [9]. En la implementación, $K^\top = Q^{-1}Y^\top$ se obtiene resolviendo el sistema lineal $QK^\top = Y^\top$ en lugar de invertir Q explícitamente, decisión numéricamente más estable dada la simetría de Q .

3.6.5. Criterio de Condicionamiento del Certificado (`condicionamiento`)

La quinta pérdida minimiza el número de condición del certificado de Lyapunov:

$$\mathcal{L}_\kappa = \kappa(Q) = \frac{\lambda_{\max}(Q)}{\lambda_{\min}(Q)}. \quad (3.26)$$

Geométricamente, $\kappa(Q)$ mide la excentricidad del elipsoide invariante: $\kappa = 1$ corresponde a una esfera y valores altos a elipsoides degenerados, alargados en alguna dirección. Este criterio no es una heurística: el propio certificado cuadrático implica la cota transitoria $\|x(t)\| \leq \sqrt{\kappa(Q)} e^{-\alpha t} \|x(0)\|$ [9], de modo que minimizar $\kappa(Q)$ acota directamente el sobreimpulso admisible de las trayectorias; el condicionamiento como objetivo de diseño posee, además, una tradición establecida en la asignación

robusta de polos [17]. Un certificado bien condicionado produce transitorios de decaimiento uniforme en todas las direcciones del espacio de estados, mantiene acotada la ganancia $K = YQ^{-1}$ y mejora la estabilidad numérica de toda la cadena de cómputo. Este criterio depende únicamente de Q .

3.6.6. Criterio de Margen Normalizado (`margen_norm`)

La última pérdida invierte la jerarquía de los criterios anteriores: en lugar de optimizar un desempeño sujeto implícitamente a la factibilidad, maximiza de forma directa el margen interior de la LMI, con la traza como término de normalización. La maximización del autovalor mínimo de una matriz afín es uno de los tres problemas canónicos de la optimización bajo LMIs —el problema de autovalores (EVP)— y requiere, como aquí, una normalización que fije la escala del certificado [9]:

$$\mathcal{L}_{mn} = -\lambda_{\min}(F(y^*)) + \mu \operatorname{tr}(Q), \quad \mu = 0.1. \quad (3.27)$$

El término de normalización corresponde a una condición de buena definición del problema, los bloques de vértice de la Ec. (3.13) son lineales —homogéneos de grado uno— en el par (Q, Y) , de modo que escalar el certificado por un factor $t > 1$ infla el margen $\lambda_{\min}$ en la misma proporción sin alterar la ganancia $K = (tY)(tQ)^{-1} = YQ^{-1}$. Sin el término $\mu \operatorname{tr}(Q)$ que fija la escala, la pérdida degeneraría en una carrera de magnitudes sin contenido de control. Este criterio entrena explícitamente la cantidad que la evaluación mide, la holgura del peor bloque.

3.6.7. Síntesis de la Familia de Criterios

La Tabla A.8 resume los seis criterios. Nótese que las pérdidas se distinguen por la dirección en que empujan al certificado respecto de la frontera de factibilidad. Los criterios de volumen puro (`paper` sin su término de margen, `control`) atraen la solución hacia la frontera; los criterios de margen (`control_margen`, `margen_norm`) la repelen; y los criterios de calidad del certificado (`esfuerzo`, `condicionamiento`) son agnósticos a la frontera pero penalizan las esquinas degeneradas de la región factible.

4. Experimentos y Resultados

Este capítulo evalúa empíricamente la extensión politópica de LMI-Net desarrollada en el Capítulo 3. El propósito de la evaluación no se limita a medir cuántos sistemas estabiliza la red, sino que busca responder cinco preguntas que estructuran todo el capítulo y que anticipan la discusión del capítulo de conclusiones.

1. **Configuración del aprendizaje.** De los ejes de diseño introducidos en la metodología — función de pérdida, presupuesto de *unrolling*, tasa de decaimiento prescrita—, ¿cuáles gobiernan la calidad del certificado aprendido y en qué dirección? (Sección 4.2.)
2. **Escalamiento.** ¿Cómo se comporta el método al crecer el orden del sistema y al variar la cantidad de datos de entrenamiento? (Sección 4.3.)
3. **Arquitectura e invarianza.** ¿Qué aporta la invarianza estructural del codificador frente a la línea base aplanada del trabajo original, tanto dentro de la distribución de entrenamiento como en topologías jamás vistas? (Sección 4.4.)
4. **El solver como componente.** Separando el codificador de la capa de proyección, ¿qué gana y qué pierde Douglas–Rachford frente a un solver convexo exacto, y cuánto mejora el solver cuando parte de la propuesta de la red? (Sección 4.6.)
5. **Robustez *out-of-distribution* (OOD).** Cuando la planta se aleja paramétricamente de la distribución de entrenamiento, ¿se degradan los certificados de forma gradual o catastrófica, y mediante qué mecanismo? (Sección 4.7.)

El estudio se organiza en 443 entrenamientos independientes, evaluados sobre escenarios de dificultad creciente que separan el desempeño en distribución de la generalización estructural y de la robustez adversarial. La etapa principal (E1) constituye un factorial completo y balanceado, esto es, cruza todas las combinaciones de niveles de los tres ejes que barre, de modo que el efecto de cada uno puede aislarse promediando sobre los demás. Las etapas restantes son barridos axiales en torno a la configuración base, que desplazan uno o dos ejes manteniendo fijos los demás; sus promedios marginales no son, por lo tanto, comparables entre sí, y las comparaciones correspondientes se realizan siempre sobre subconjuntos controlados (Sección 4.3.1). En total, el análisis procesa 27,7 millones de filas de evaluación cruda, una por cada combinación de sistema, escenario, época de entrenamiento y presupuesto de iteraciones de inferencia.

4.1. Diseño Experimental

4.1.1. Protocolo General y Configuración Base

Las seis funciones de pérdida de la Sección 3.6 atraviesan todas las etapas del barrido, sin selección adaptativa de finalistas. Esta decisión encarece el estudio, pero permite afirmar que el efecto de cada eje es (o no es) consistente a través de los demás con respaldo del diseño, y no de una elección posterior a los resultados.

Todos los experimentos comparten una configuración base de la cual cada etapa desvía uno o pocos ejes. Dicha base emplea el codificador de actuadores, sistemas de tercer orden ($n_x = 3$) con un actuador, unrolling truncado a 30 iteraciones de Douglas–Rachford en entrenamiento, tasa de decaimiento prescrita $\alpha = 0.01$, 150 sistemas de entrenamiento y 400 épocas con Adam. Dos mecanismos abaratan radicalmente el barrido sin sacrificar resolución. El primero son los *checkpoints de época*, mediante los cuales una corrida de 400 épocas se evalúa también en sus estados intermedios, entregando la curva de aprendizaje completa al precio de un solo entrenamiento. El segundo es el *sondeo del presupuesto de inferencia*, que en cada evaluación recorre presupuestos de Douglas–Rachford desde 100 hasta 8000 iteraciones en una sola pasada, de modo que el compromiso entre tiempo de inferencia y tasa de éxito queda medido sin corridas adicionales.

4.1.2. Etapas del Barrido y Preguntas Asociadas

El barrido se estructura en cuatro etapas de entrenamiento y dos estudios de evaluación sobre los modelos ya entrenados. La Tabla A.9 resume el diseño; los párrafos siguientes explican qué compara cada etapa y por qué esa comparación es informativa.

- **Barrido principal (E1).** Barrido conjunto de los tres ejes cuya interacción la evidencia preliminar señaló como relevante; esto es, la función de pérdida (6 niveles), la tasa de decaimiento prescrita ($\alpha \in \{0.001, 0.01, 0.05, 0.1\}$) y el presupuesto de *unrolling* en entrenamiento ($K_{tr} \in \{5, 30, 120, 500\}$), más la rama de diferenciación implícita, que al iterar hasta convergencia no admite presupuesto de *unrolling*. La motivación de barrer estos ejes en conjunto, y no uno a la vez, es que la hipótesis geométrica del Capítulo 3 predice una interacción entre ellos, pues tanto la pérdida como el gradiente del solver determinan hacia qué región del conjunto factible se dirige el certificado. Es la etapa de mayor volumen (240 entrenamientos) y la fuente principal de la Sección 4.2.
- **Barrido de orden (E2).** Efecto del orden del sistema $n_x \in \{2, 3, 4, 5\}$ sobre las seis pérdidas, con arquitectura fija. Su propósito es verificar que las conclusiones del barrido principal, obtenidas en $n_x = 3$, no son un artefacto de esa dimensión particular.
- **Curva de eficiencia de datos (E3).** Efecto del tamaño del conjunto de entrenamiento ($\{50, 150, 400\}$ sistemas) sobre las seis pérdidas. Un método auto-supervisado que requiera pocos ejemplos resulta especialmente valioso en control, donde generar sistemas certificados

es costoso.

- **Backpropagation y contraste de arquitecturas (E4).** Comparación directa entre unrolling truncado y diferenciación implícita bajo configuración emparejada, junto con la evaluación de los tres peldaños arquitectónicos de la Sección 3.4 (línea base aplanada, codificador de vértices, codificador de actuadores) sobre la malla completa de órdenes $n_x \in \{2, 3, 4, 5\}$, lo que permite además descartar que la ventaja de un codificador dependa del tamaño del sistema.
- **Evaluación adversarial (E5).** Los modelos entrenados en E1 se evalúan, sin reentrenar, sobre dos bancos de deriva paramétrica descritos en la Sección 4.7. Aquí no se compara ningún eje de entrenamiento nuevo, sino la resistencia de lo ya aprendido cuando la planta abandona la distribución de entrenamiento.
- **Comparación de solvers.** Con independencia de toda red, se compara Douglas–Rachford contra un solver convexo de punto interior (CVXPY [12]) en velocidad y tasa de éxito, y se mide cuánto mejora Douglas–Rachford cuando su punto de partida es la propuesta de la red en lugar de una inicialización aleatoria. Esta comparación aísla la contribución de cada componente del sistema propuesto.

4.1.3. Escenarios de Evaluación

Todo modelo entrenado se evalúa sobre escenarios concéntricos de dificultad creciente, siempre con las mismas métricas y el mismo sondeo de presupuesto de inferencia. La Figura A.14 esquematiza la organización.

- **Escenario en distribución (S1).** Partición de prueba (20 %, semilla fija) de las mismas celdas topológicas vistas en entrenamiento. Mide el desempeño convencional de generalización estadística a sistemas nuevos de familias conocidas.
- **Escenario estructural (S2).** Celdas topológicas *retenidas por completo* del entrenamiento, es decir, polítopos de $N = 5$ vértices y sistemas con $n_u = 2$ actuadores, combinaciones que ningún modelo observó jamás. Este escenario mide la generalización de las invarianzas arquitectónicas, puesto que un modelo solo puede rendir aquí si su codificador captura la estructura de conjunto del polítopo y no una memorización de topologías particulares. La línea base aplanada queda estructuralmente excluida de este escenario, ya que su entrada de dimensión fija es incapaz siquiera de procesar una cardinalidad o un número de actuadores distintos de los de entrenamiento.
- **Escenario adversarial (S3).** Barrido paramétrico de perturbaciones sobre sistemas nominales, contrastado contra el solver convexo de referencia (techo de factibilidad) y contra Douglas–Rachford puro desde una inicialización aleatoria (control que aísla el codificador del solver). Sus resultados se presentan en la Sección 4.7.

Se privilegia S2 por sobre S1 porque es la más informativa respecto del objetivo de la memoria, que consiste en sintetizar controladores para familias de sistemas no vistas. Dos precisiones acotan

el alcance de esa elección. La primera es que el diseño no reservó un conjunto de validación independiente: S2 operó simultáneamente como criterio de comparación entre configuraciones y como escenario reportado, de modo que la cifra de la mejor configuración debe leerse como el máximo observado sobre el barrido y no como una estimación insesgada del desempeño esperado. Ningún sistema de S2 interviene en el entrenamiento (las celdas están retenidas por completo), por lo que no existe fuga de datos sino selección sobre el escenario reportado. La segunda es que S2 mide una forma específica de generalización, la estructural hacia topologías retenidas, que no equivale a robustez frente a cambios en la distribución de los sistemas: la Sección 4.7 muestra que el criterio que encabeza S2 es precisamente el que colapsa bajo deriva paramétrica, de manera que S3, y no S2, constituye el escenario más exigente del capítulo.

4.1.4. Métricas

Para cada sistema evaluado se registran cuatro cantidades. Todas ellas se calculan a posteriori sobre el controlador que la arquitectura entrega, esto es, sobre la ganancia recuperada a partir de la salida proyectada $y^* = (\text{vech}(Q^*), \text{vec}(Y^*))$ mediante $K = Y^*(Q^*)^{-1}$ (Ec. (2.32)), y no sobre el valor de la función de pérdida.

Porcentaje estabilizado. Fracción de sistemas del escenario cuyo lazo cerrado es Hurwitz en todos los vértices:

$$\text{PE} = \frac{100}{|\mathcal{D}|} \sum_{s \in \mathcal{D}} \mathbf{1}[a(K_s; s) < 0] \quad [\%], \quad (4.1)$$

donde $\mathbf{1}[\cdot]$ es la función indicadora y K_s la ganancia predicha para el sistema s . Es la métrica primaria porque corresponde exactamente a la garantía que el certificado promete.

Porcentaje que cumple el decaimiento. Endurece el criterio anterior exigiendo que el polo dominante quede a la izquierda de $-\alpha$, es decir, que la tasa prescrita dentro de la LMI (Ec. (3.12)) se materialice efectivamente en el espectro:

$$\text{PD} = \frac{100}{|\mathcal{D}|} \sum_{s \in \mathcal{D}} \mathbf{1}[a(K_s; s) \leq -\alpha] \quad [\%]. \quad (4.2)$$

Por construcción $\text{PD} \leq \text{PE}$, y la brecha entre ambas mide cuánta estabilización es meramente marginal.

Presupuesto mínimo de inferencia. Sea $\mathcal{G} = \{100, 250, 500, 1000, 2000, 4000, 8000\}$ la grilla de presupuestos sondeados y $K_s^{(k)}$ la ganancia obtenida al detener la capa de proyección tras k iteraciones de Douglas–Rachford. Entonces

$$\text{iters}_{\min}(s) = \min \left\{ k \in \mathcal{G} : a(K_s^{(k)}; s) < 0 \right\}, \quad \text{iters}_{\min}(s) \triangleq \infty \text{ si el conjunto es vacío,} \quad (4.3)$$

y se reporta la mediana $\text{med}\{\text{iters}_{\min}(s) : s \in \mathcal{D}, \text{iters}_{\min}(s) < \infty\}$, que mide el costo computacional real de la etapa online. Dado que la trayectoria del solver no es monótona, ya que un sistema puede cruzar transitoriamente al lado estable y volver a salir, la implementación registra siempre esta métrica junto al indicador de estabilidad al presupuesto máximo de la Ec. (4.1); sus medianas son, por lo tanto, condicionales al éxito eventual.

Condicionamiento del certificado. Razón entre los autovalores extremos de la matriz de Lyapunov proyectada,

$$\kappa(Q^*) = \frac{\lambda_{\max}(Q^*)}{\lambda_{\min}(Q^*)} \geq 1, \quad (4.4)$$

reportada como mediana sobre el escenario. Diagnostica la calidad geométrica de la solución: $\kappa(Q^*)$ es la excentricidad del elipsoide invariante $\mathcal{E}(Q^*)$, de modo que valores próximos a 1 indican certificados bien condicionados, mientras que valores grandes señalan un elipsoide casi degenerado, propio de las esquinas de la región factible donde $\lambda_{\min}(Q^*) \rightarrow 0$ y la ganancia recuperada $K = Y^*(Q^*)^{-1}$ se dispara.

Como se verá en la Sección 4.7, esta última métrica, secundaria dentro de la distribución de entrenamiento, se convierte en la variable explicativa central del comportamiento *out-of-distribution*.

4.2. Resultados del Barrido Principal

Esta sección reporta los efectos de los tres ejes del barrido principal (E1), es decir, la función de pérdida, el presupuesto de unrolling y la tasa de decaimiento prescrita, y culmina con la mejor configuración global. Los tres efectos, aparentemente independientes, admiten una lectura geométrica unificada que se desarrolla al cierre de la sección con apoyo de la Figura A.17.

4.2.1. Efecto de la Función de Pérdida

La Tabla A.10 presenta el efecto marginal de la función de pérdida sobre el escenario estructural, promediando sobre los restantes ejes del diseño balanceado, y la Figura A.15 muestra las curvas completas de estabilización en función del presupuesto de inferencia. El resultado central es que **la receta del trabajo original no es la mejor**, pues cuatro de las cinco alternativas propuestas en esta memoria superan a la pérdida **paper**, encabezadas por **condicionamiento** (+7.0 puntos porcentuales) y **margen_norm** (+5.2 puntos).

El ordenamiento no es arbitrario, ya que reproduce la clasificación por tratamiento de la frontera anticipada en la Tabla A.8. Los dos extremos son ilustrativos. La peor pérdida es **control**, el único criterio que atrae la solución hacia la frontera de factibilidad sin contrapeso alguno; y basta añadirle el piso espectral de **control_margen** para ganar 7.7 puntos, cuantificando de forma aislada el costo de optimizar sobre la frontera. En el otro extremo, los criterios que repelen la frontera o penalizan sus esquinas degeneradas (**condicionamiento**, **margen_norm**) dominan el ordenamiento. La pérdida **paper** queda en penúltimo lugar pese a incluir un término de margen, porque su recompensa lineal

y sin cota compite permanentemente contra el criterio de volumen, en lugar de anularse una vez asegurada una holgura suficiente.

4.2.2. Truncamiento como Regularización

La Tabla A.11 presenta el efecto del presupuesto de iteraciones de Douglas–Rachford durante el entrenamiento, para la rama de unrolling. El resultado contradice la intuición de que un gradiente más fiel al punto de convergencia produce un mejor modelo, dado que el unrolling truncado a $K_{tr} = 30$ iteraciones supera al régimen profundo de $K_{tr} = 500$ (el empleado por la formulación original) por 14.1 puntos porcentuales, y la degradación es monótona a partir del óptimo.

La explicación mecanística es la interacción entre gradiente y frontera descrita en la Sección 3.5 y esquematizada en la Figura A.16. Como el óptimo de los criterios de desempeño se sitúa sobre o cerca de la frontera del conjunto factible, un gradiente que refleja fielmente que el punto de convergencia profunda arrastra al codificador hacia certificados de margen nulo. El truncamiento introduce una imprecisión que opera como *regularización implícita*, en el sentido de que la red aprende a proponer puntos cuya proyección superficial ya es buena, lo que la mantiene alejada de las esquinas degeneradas. La expresión posee un contenido técnico preciso. Truncar el unrolling a K_{tr} iteraciones equivale a truncar la serie de Neumann de $(I - J_s)^{-1}$, donde J_s denota la jacobiana del operador de Douglas–Rachford respecto de su estado, lo que induce sobre cada modo propio λ de dicha jacobiana el factor de filtrado $\varphi_{K_{tr}}(\lambda) = 1 - \lambda^{K_{tr}}$. Los modos rápidos atraviesan el filtro sin alteración y los modos lentos quedan atenuados, de modo que el truncamiento no escala el gradiente sino que lo filtra modo por modo. Esta es la misma familia de filtros espectrales de la iteración de Landweber, para la cual la detención temprana constituye un esquema de regularización con caracterización formal [13]. El alcance de esta caracterización se examina en la Sección 4.5.1. La fila de la diferenciación implícita, que calcula el gradiente exacto en el punto fijo, es el caso límite de este fenómeno y se analiza en detalle en la Sección 4.5. Nótese además la consecuencia sobre el costo de inferencia, puesto que los regímenes truncados no solo estabilizan más sistemas, sino que lo hacen con presupuestos mínimos cinco veces menores (mediana de 100 frente a 500 iteraciones).

Este hallazgo ofrece, adicionalmente, una explicación de una decisión de diseño que el trabajo original emplea sin justificar, a saber, la inclusión del término de margen espectral en su función de pérdida. Bajo entrenamiento profundo ($K_{tr} = 500$), dicho término es el único mecanismo que evita el colapso hacia la frontera; bajo truncamiento, la regularización implícita cumple ese rol de forma gratuita.

4.2.3. Efecto de la Tasa de Decaimiento Prescrita

La tasa α no es un hiperparámetro de optimización sino una especificación de diseño, ya que define cuán rápido se exige que el lazo cerrado disipe energía y, con ello, el tamaño de la región factible. La Tabla A.12 muestra el compromiso resultante.

Los extremos fallan por razones opuestas. Con $\alpha = 0.1$ la exigencia estrangula geométricamente la

región factible, y solo un tercio de los sistemas alcanza el decaimiento prescrito. Con $\alpha = 0.001$ la meta es tan laxa que se cumple trivialmente, pero la garantía certificada pierde contenido práctico. El valor $\alpha = 0.01$ equilibra ambos efectos y se adopta como configuración base. Este resultado adquiere relieve al contrastarlo con la caracterización de la base de datos (Sección 3.1), donde las ganancias de referencia almacenadas logran una tasa mediana de $\alpha \approx 6.3 \times 10^{-4}$, de modo que los controladores sintetizados por la red certifican decaimientos un orden de magnitud mayores que la solución clásica de la propia base.

4.2.4. Mejor Configuración Global

La Tabla A.13 presenta la mejor configuración del barrido completo según la métrica de referencia, junto a la receta del trabajo original evaluada bajo el mismo protocolo.

La descomposición de la brecha es más informativa que su magnitud. De los 46.0 puntos que separan a la receta original de la mejor configuración, 43.4 los aporta el cambio de estrategia de *backpropagation* con la *misma* pérdida original ($51.4 \rightarrow 94.8$), y solo 2.6 el cambio conjunto de criterio y tamaño de datos ($94.8 \rightarrow 97.4$).

Dos observaciones merecen destacarse. La primera es el nivel absoluto, un 97.4 % de estabilización sobre topologías jamás vistas ($N = 5$, $n_u = 2$), con una mediana de solo 100 iteraciones de inferencia y certificados casi esféricos ($\kappa(Q) = 1.67$). La segunda es más sutil: esta misma configuración rinde 94.0 % en el escenario en distribución (S1), es decir, generaliza aparentemente mejor a las topologías retenidas que a su propia distribución de entrenamiento. La Tabla A.14 muestra que se trata de un efecto de composición gobernado por el número de actuadores y no por la cardinalidad del polítopo. Todas las celdas de dos actuadores —que disponen de mayor autoridad de control y son intrínsecamente más fáciles de estabilizar— rinden entre 97.3 % y 99.1 %, y todas las de un actuador entre 92.5 % y 95.0 %, con independencia de N ; como S2 concentra cuatro de sus cinco celdas en dos actuadores mientras que S1 consta exclusivamente de un actuador, la aparente ventaja de S2 desaparece al estratificar. Nótese además que dentro de las celdas de dos actuadores el desempeño decrece levemente al aumentar N ($99.1 \rightarrow 97.3$), lo que descarta que un mayor número de vértices aporte más información al mecanismo de agregación invariante.

4.2.5. Hiperparámetros de la Capa de Proyección

El peso de anclaje σ_{anc} y el margen de positividad ϵ_{pos} se heredaron de la formulación original y permanecieron fijos en el barrido principal. Su barrido cruzado ($\sigma_{anc} \in \{0.005, 0.01, 0.1, 1.0\}$ contra $\epsilon_{pos} \in \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}\}$, seis pérdidas y dos semillas, Tabla A.26) revela 23.8 puntos porcentuales entre sus extremos, por encima del presupuesto de *unrolling* (14.1) y de la función de pérdida (11.2).

La expresión $y_{avg} = (2\sigma_{anc}\hat{y} + y_k)/(2\sigma_{anc} + 1)$ retiene la propuesta del codificador en *cada* iteración con peso $2\sigma_{anc}/(2\sigma_{anc} + 1)$, de modo que σ_{anc} no gobierna el punto de partida (que es siempre $\hat{y}$) sino cuánto de ese sesgo sobrevive a la proyección. Anclaje fuerte conserva el sesgo del criterio hasta

el certificado final y hace decisiva la elección de pérdida; anclaje débil deja que Douglas–Rachford lo diluya. Ello explica que la dispersión entre criterios colapse de 33.0 a 2.2 puntos al bajar σ_{anc} de 1.0 a 0.005, y que `margen_norm` deba su liderazgo menos a su desempeño absoluto que a ser el criterio menos sensible a este eje.

El efecto de ϵ_{pos} es monótono y de signo único: 18.2 puntos entre 10^{-5} y 10^{-2} , con $\kappa(Q^*)$ mediano cayendo de 1.83 a 1.05. Alejar por construcción el certificado de la singularidad mejora a la vez la tasa de estabilización y el condicionamiento, sin que se observe el estrechamiento del conjunto factible que cabría anticipar. La mejor celda de la malla, $(\sigma_{anc}, \epsilon_{pos}) = (0.005, 10^{-2})$, alcanza 98.11 % en S2, frente al 95.16 % de la configuración heredada, de modo que las cifras del resto del capítulo constituyen una cota inferior del método.

4.2.6. La Geometría de la Frontera como Hilo Conductor

Los tres efectos del barrido principal admiten una lectura unificada, esquematizada en la Figura A.17. El óptimo de los criterios de desempeño clásicos vive sobre la frontera del conjunto factible, y la frontera es precisamente la región donde el certificado degenera, pues allí Q se aproxima a la singularidad, la ganancia $K = YQ^{-1}$ se dispara y el solver iterativo se ralentiza. Todo mecanismo que empuja la solución hacia esa frontera degrada el desempeño (el gradiente exacto de la diferenciación implícita, el unrolling profundo y los criterios de volumen sin contrapeso), y todo mecanismo que la repele lo mejora (el truncamiento del unrolling, los términos de margen y los criterios de condicionamiento).

La Figura A.18 sustenta esta lectura sobre una instancia concreta en lugar de un esquema. Sobre el polítopo de vértice marginal nominal, el corte del conjunto factible por el plano que contiene la trayectoria del solucionador muestra la cuña de factibilidad con el certificado alojado exactamente en su vértice, y confirma que los gradientes de los distintos criterios de desempeño tiran del certificado en direcciones netamente distintas, con `control` y `condicionamiento` apuntando hacia el exterior de $\mathcal{C}$.

4.3. Escalamiento en Orden y Eficiencia de Datos

4.3.1. Efecto del Orden del Sistema (E2)

El barrido de orden repite la comparación de pérdidas en $n_x \in \{2, 3, 4, 5\}$ manteniendo el resto de la configuración base. Dos conclusiones se desprenden de él. En primer lugar, el desempeño no se degrada con el orden dentro del rango estudiado, ya que bajo la configuración base controlada el codificador de actuadores estabiliza en S2 el 91.4 %, 95.2 %, 94.1 % y 91.1 % de los sistemas para $n_x = 2, 3, 4, 5$ respectivamente (promedio sobre las seis pérdidas y dos semillas, Tabla A.16). La ausencia de una tendencia monótona decreciente sugiere que, al menos hasta quinto orden, la dificultad dominante no es la dimensión del certificado sino la geometría del polítopo. En segundo lugar, el ordenamiento de pérdidas observado en $n_x = 3$ se mantiene en los demás órdenes, lo que

descarta que las conclusiones del barrido principal sean un artefacto de la dimensión en que se ejecutó.

Una advertencia metodológica aplica a esta y a las restantes comparaciones del capítulo. Los promedios marginales del reporte de barrido mezclan celdas con cobertura desigual: la celda $n_x = 3$ y el codificador de actuadores absorben la totalidad del barrido principal E1 —incluidas sus configuraciones deliberadamente malas, como el unrolling profundo, la diferenciación implícita y los valores extremos de α —, mientras que las demás celdas solo se evaluaron bajo la configuración base. Por ello, toda comparación de orden, tamaño o arquitectura de este capítulo se realiza sobre el subconjunto controlado y no sobre los marginales crudos, que en ambos casos inducirían la conclusión opuesta a la correcta.

4.3.2. Curva de Eficiencia de Datos (E3)

La Tabla A.15 presenta el efecto del tamaño del conjunto de entrenamiento bajo la configuración base, promediando sobre las seis pérdidas y las dos semillas. La ganancia es monótona pero notablemente plana, pues cuadruplicar los datos desde 150 hasta 400 sistemas aporta menos de medio punto porcentual, y con apenas 50 sistemas el método ya supera el 93 % de estabilización estructural.

Esta economía de datos es coherente con la naturaleza auto-supervisada del entrenamiento. La señal de aprendizaje no proviene de etiquetas escasas sino de la propia LMI evaluada sobre cada propuesta, de manera que cada sistema de entrenamiento aporta un paisaje de pérdida completo y no un único par entrada-salida. Para la mejor configuración individual la tendencia se mantiene, dado que `margen_norm` pasa de 96.8 % con 150 sistemas a 97.4 % con 400. En términos prácticos, el costo de generar datos no es la barrera de entrada del método.

4.4. Arquitecturas e Invarianza Estructural

La etapa E4 completa la malla arquitectura $\times$ orden bajo la configuración base controlada, cuya única diferencia entre celdas es el codificador y el orden del sistema. Las Tablas A.16 y A.17 presentan el contraste en ambos escenarios. Lo que se compara aquí es la hipótesis central de la extensión propuesta, esto es, que dotar al codificador de las invarianzas del problema (permutación e inserción de vértices, permutación de actuadores) compra generalización estructural, y que esa compra tiene un precio medible dentro de la distribución.

Tres lecturas se desprenden de las comparaciones. La primera es que, dentro de la distribución, la línea base aplanada domina en todos los órdenes por aproximadamente cuatro puntos porcentuales. Este resultado no debe sorprender, pues una red especializada en una única topología puede dedicar toda su capacidad a esa familia, mientras que los codificadores invariantes reparten la suya entre todas las cardinalidades vistas. Ese margen, sin embargo, estaba confundido con el margen de positividad, pues la línea base heredaba $\epsilon_{pos} = 10^{-3}$ del trabajo original mientras los codificadores invariantes empleaban 10^{-5} . Reentrenadas las tres arquitecturas a ϵ_{pos} igualado en $n_x = 3$, la ventaja de la línea base desaparece: la diferencia residual queda por debajo de la dispersión entre semillas

(Tabla A.27), en ese orden, sin que el experimento se haya replicado en los órdenes restantes, de modo que el precio de la invarianza es considerablemente menor que el estimado inicial. La segunda es que esa ventaja es estéril fuera de la topología de entrenamiento, dado que la línea base ni siquiera puede evaluar el escenario S2, no por bajo desempeño sino por imposibilidad estructural, ya que requeriría reentrenar una red por cada combinación (N, n_u) del universo de plantas. La tercera es que la equivariancia sobre los actuadores amplía el dominio de aplicabilidad antes que el desempeño sobre el problema compartido. El codificador de vértices es invariante a N pero no a n_u , de modo que de las cinco celdas que componen S2 solo admite como entrada la de un actuador y $N = 5$ mientras que el de actuadores evalúa las cinco. El contraste directo de la Tabla A.16 promedia por lo tanto conjuntos distintos, y la ventaja que exhibe refleja la composición de celdas antes que la arquitectura: restringida la comparación a la celda común, ambos codificadores rinden de forma equivalente dentro de la dispersión entre semillas, con diferencias de a lo sumo 0.5 puntos en los cuatro órdenes. Lo que la equivariancia adicional aporta no es, en consecuencia, una mayor tasa de éxito sobre las topologías que ambos pueden procesar, sino la capacidad de procesar las cuatro celdas de dos actuadores que el codificador de vértices no admite siquiera como entrada. Ambos contrastes de esta sección se realizan bajo hiperparámetros idénticos; los marginales crudos del reporte inducirían además la conclusión opuesta por el artefacto de cobertura ya descrito en la Sección 4.3.1.

4.5. Unrolling frente a Diferenciación Implícita

La diferenciación implícita calcula el gradiente exacto en el punto fijo del solver mediante el teorema de la función implícita y evita almacenar iteraciones intermedias. Cabía esperar que dominara al *unrolling* truncado, un gradiente sesgado de un proceso interrumpido. Ocurrió lo contrario en ambos frentes, calidad y costo, como resume la Tabla A.18.

La rama implícita no solo generaliza 30 puntos peor en el marginal, sino que consumió cerca de dos tercios del cómputo total del barrido pese a representar una fracción minoritaria de las corridas. La explicación conecta directamente con la Sección 4.2.2 y con la Figura A.16. La diferenciación implícita es el límite del *unrolling* cuando el número de iteraciones tiende a infinito, y la degradación observada en la Tabla A.11 es monótona en esa dirección, de modo que el gradiente exacto en el punto fijo hereda, en su forma más pura, el defecto de arrastrar al codificador hacia la frontera. Existe además un efecto de acoplamiento entre entrenamiento e inferencia que favorece al truncamiento, dado que la red truncada aprende a proponer puntos útiles *para el régimen de pocas iteraciones*, que es exactamente el régimen en que la inferencia es barata. El resultado práctico es que la opción más simple y económica resulta simultáneamente la de mejor generalización.

4.5.1. Puesta a Prueba del Mecanismo Propuesto

La hipótesis examinada fue que el gradiente de la rama implícita diverge en las direcciones asociadas a la no unicidad del punto fijo de Douglas–Rachford, de manera que el truncamiento no aportaría una regularización sino simplemente una cota sobre una cantidad mal definida. Bajo esa hipótesis

la comparación de la Tabla A.18 no contrastaría dos gradientes válidos sino uno acotado frente a uno degenerado.

La hipótesis fue descartada. El estado apilado del solver es $s = [y_k \mid x_k]$, con $y_k \in \mathbb{R}^{\dim y}$ y $x_k \in \mathbb{R}^{(N+1)n_x^2}$, de modo que en la configuración base ($n_x = 3$, $m = 1$, $N = 2$) resulta $\dim s = 36$. Se evaluó la jacobiana $J_s = \partial T / \partial s$ en el punto fijo mediante diferencias finitas centradas en doble precisión. La medición confirma la existencia de las direcciones problemáticas, ya que 18 de los 36 modos se acumulan en el círculo unitario, lo que vuelve singular a $(I - J_s)$ por construcción. Sin embargo, el entrenamiento no las recorre. La señal de aprendizaje proyectada sobre ese subespacio tiene magnitud del orden de 10^{-12} , frente a 10^3 sobre el complemento, doce órdenes de magnitud de diferencia. El motivo es estructural, puesto que esas direcciones son precisamente las que desplazan el estado a lo largo de la variedad de puntos fijos sin alterar la salida y^* , y las funciones de pérdida empleadas dependen únicamente de dicha salida. El adjunto de la rama implícita converge de forma satisfactoria sobre el lado derecho que el entrenamiento efectivamente le entrega, de modo que la caracterización de la Sección 4.5 como gradiente exacto en el punto fijo se mantiene.

La medición sí permite localizar la discrepancia. De las 36 direcciones del estado, únicamente 6 concentran la diferencia entre el gradiente truncado y el completo, y sobre ellas el gradiente truncado excede al exacto en un 35 %. Esto acota el fenómeno a una banda específica del espectro y lo distingue de una atenuación uniforme, pero no constituye por sí solo un mecanismo. El anclaje espectral introducido en la Sección 4.2.2 explica *cómo* el truncamiento filtra el gradiente, no *por qué* ese filtrado mejora la generalización en 34.3 puntos; en particular, en la iteración de Landweber los modos atenuados son los asociados al ruido de medición, y no se dispone aquí de una identificación análoga para los seis modos involucrados. La explicación completa del hallazgo permanece abierta y se recoge como línea de trabajo futuro en el Capítulo 5. Los procedimientos de medición y sus resultados numéricos se detallan en la Tabla A.25.

4.6. Douglas–Rachford frente al Solver Convexo

Antes de evaluar la robustez del sistema completo conviene descomponerlo. El método propuesto encadena dos piezas, un codificador que propone $\hat{y}$ y un solver de proyección que lo vuelve factible. Esta sección compara la segunda pieza contra un solver convexo de punto interior (CVXPY [12], que resuelve la LMI de forma exacta y actúa como *ground truth* de factibilidad) y cuantifica el valor de la primera midiendo cuánto mejora Douglas–Rachford cuando parte de la propuesta entrenada en lugar de una inicialización aleatoria.

4.6.1. Velocidad y Escalamiento

La Tabla A.19 y la Figura A.19 resumen la comparación sobre bancos de 200 sistemas por cardinalidad. CVXPY certifica el 100 % de los sistemas, lo que confirma que todos son robustamente estabilizables, a un costo por sistema que crece rápidamente con el número de vértices, desde 189 ms en $N = 2$ hasta 1130 ms en $N = 5$. Douglas–Rachford por lotes, en cambio, escala suavemente

con N , de manera que su ventaja crece con el tamaño del problema, desde 5.1 veces en $N = 2$ hasta 16.2 veces en $N = 5$ con el presupuesto máximo evaluado, y supera dos órdenes de magnitud si se acepta el presupuesto mínimo. El precio de esa velocidad es una brecha de completitud, pues con 4000 iteraciones y partida aleatoria el solver de proyección estabiliza entre el 85.5 % y el 91.0 % de los sistemas según la cardinalidad.

Dos matices delimitan la lectura de esta tabla. El primero es que en problemas diminutos la ventaja se invierte, como se verá en la instancia única de la Sección 4.7, donde CVXPY resuelve en unos 10 ms; la superioridad de Douglas–Rachford emerge del procesamiento por lotes y del escalamiento con N , que es el régimen de interés para sintetizar controladores masivamente. El segundo es que CVXPY entrega, junto a la solución, un certificado numérico de factibilidad, mientras que Douglas–Rachford entrega un punto cuya factibilidad debe verificarse a posteriori.

4.6.2. El Valor del Codificador

La misma infraestructura permite aislar la contribución de la red. Partiendo de $\hat{y}$ aleatorio, Douglas–Rachford estabiliza entre el 85 % y el 91 % de los sistemas según se vio; partiendo de la propuesta del codificador entrenado, las configuraciones superiores del barrido alcanzan entre el 95 % y el 97.4 % en el escenario estructural con presupuestos medianos de solo 100 iteraciones (Tabla A.13). El codificador aporta entonces dos cosas distintas, por una parte entre cuatro y diez puntos de tasa de éxito y, por otra, una reducción de más de un orden de magnitud en el presupuesto necesario, al situar el punto de partida en la cuenca de proyección correcta. La Sección 4.7 mostrará que este mismo mecanismo, un punto de partida fuertemente sesgado por lo aprendido, es también la vía por la cual el sistema puede fallar.

4.6.3. Caracterización de los Fallos del solver

Los 91 sistemas (de 800) que Douglas–Rachford no logra estabilizar desde partida aleatoria no se distribuyen al azar. La Figura A.20 contrasta sus descriptores con los de los sistemas estabilizados; los fallos concentran matrices de estado peor condicionadas (mediana de $\kappa(A) \approx 64$ sobre los sistemas normalizados), polítopos más dispersos (mediana de la dispersión ≈ 1.02) y mayor inestabilidad de lazo abierto (mediana de la abscisa espectral ≈ 0.31). Estos son precisamente los sistemas cuya región factible es pequeña o está mal condicionada, donde la convergencia asintótica de los métodos de división es más lenta. El patrón es coherente con la lectura geométrica de la Sección 4.2.6 y anticipa el tipo de instancia donde el punto de partida del codificador más importa.

4.7. Evaluación *Out-of-Distribution*

Los escenarios S1 y S2 miden generalización a sistemas y a topologías nuevas, pero en ambos casos las plantas provienen del mismo proceso generador que los datos de entrenamiento. El escenario adversarial responde una pregunta distinta y más cercana a la operación real, a saber, qué ocurre cuando la planta se *aleja continuamente* de esa distribución, por ejemplo por desgaste, cambio de

punto de operación o error de modelado. La respuesta corta es que la degradación puede ser gradual o catastrófica según el criterio con que se entrenó la red, y que la pérdida campeona del escenario estructural es precisamente la que colapsa.

4.7.1. Protocolo

Los modelos del barrido principal se evalúan, sin reentrenamiento alguno, sobre dos bancos de deriva paramétrica. El primero, de *desplazamiento de polos*, es un sistema nominal de un vértice y tercer orden, $A(s) = A^0 + sI$ con $A^0 = [[0, 1, 0], [0, 0, 1], [2, -3, 1]]$ y $B = [0, 0, 1]^\top$, recorrido en 31 valores de $s \in [-1, 2]$. Como $\lambda(A^0 + sI) = \lambda(A^0) + s$, el parámetro traslada en bloque todo el espectro de lazo abierto, de modo que los valores negativos producen plantas más estables que la nominal y los positivos plantas progresivamente más inestables. El solver convexo halla certificado en *los 31 puntos* de la rampa, como corresponde a un par controlable de un solo vértice; lo que la deriva degrada no es la factibilidad sino la geometría del certificado, cuyo condicionamiento de referencia crece de $\kappa(Q) = 1$ en $s = -1$ hasta $\kappa(Q) = 358$ en $s = 2$ (Tabla A.20). El segundo banco, denominado aquí *polítopo de vértice marginal*, es una familia uniparamétrica $A_i(\delta) = A_i^0 + \delta D_i$ construida de manera que en $\delta = 1$ uno de los vértices posee un polo exactamente sobre el eje imaginario —de ahí su nombre— y para $\delta > 1$ dicho vértice cruza al semiplano inestable. Este banco es especialmente informativo porque la estabilizabilidad robusta se conserva aunque un vértice sea inestable en lazo abierto, dado que el par se mantiene controlable. En ambos bancos, el solver convexo halla certificado en la *totalidad* de la rampa, de modo que todo fallo de la red es atribuible al método y no al problema.

El protocolo instrumenta además el *mecanismo* de cada fallo, registrando el peor autovalor de lazo cerrado y el residual del solver en función de la iteración, tanto para la propuesta $\hat{y}$ de la red como para una propuesta aleatoria de control. Esta comparación permite atribuir cada fallo al codificador o al solver.

4.7.2. Resultados Agregados

La Tabla A.21 resume ambos bancos y la Figura A.21 muestra el presupuesto mínimo de estabilización a lo largo de la rampa del polítopo de vértice marginal. Sobre este banco, cuatro de las seis pérdidas (**condicionamiento**, **control**, **control_margen** y **paper**) igualan el techo de factibilidad del solver convexo en toda la rampa, estabilizando el 100 % de las instancias incluso cuando un vértice es inestable en lazo abierto. La pérdida **esfuerzo** lo consigue solo en el 76 % de los casos, con fallos que aparecen desde $\delta \geq 0.9$, y **margen_norm**, la mejor configuración del escenario estructural, se desploma al 39 %.

El banco de desplazamiento de polos aporta un matiz esencial antes de interpretar ese colapso. Sobre ese banco, **margen_norm** es la pérdida *más* robusta en la zona de deriva moderada, sosteniendo entre el 75 % y el 86 % de estabilización para $s \in [0.1, 1.1]$ mientras **control** y **paper** caen bajo el 65 %, y todas las pérdidas se derrumban conjuntamente más allá de $s \approx 1.3$, donde ninguna supera el 16 % pese a que el certificado sigue existiendo. La fragilidad de **margen_norm** no es, por lo tanto,

una debilidad genérica ante cualquier perturbación, sino una interacción específica entre su sesgo aprendido y la dirección de deriva del polítopo de vértice marginal, lo que motiva el análisis de mecanismo que sigue.

4.7.3. Anatomía de un Colapso: `margen_norm` sobre el Polítopo de Vértice Marginal

La Tabla A.22 sigue la degradación instancia a instancia y la Figura A.22 la traza sobre la rampa completa. En el nominal ($\delta = 0$) las cuatro réplicas de `margen_norm` estabilizan. Basta sin embargo la mínima deriva ($\delta = 0.1$) para que la mitad de las réplicas quede del lado inestable por poco, con el peor autovalor de lazo cerrado apenas positivo. Al llegar al punto crítico $\delta = 1$, el certificado de las réplicas fallidas degenera por completo, con $\kappa(Q)$ superando 10^7 , la matriz Q prácticamente singular, la ganancia $K = YQ^{-1}$ disparada y el peor autovalor del orden de 10^4 . En $\delta = 2$ ninguna réplica estabiliza. Durante toda la rampa el solver convexo sigue encontrando certificado, de modo que cada uno de estos fallos es atribuible al método.

El contraste con `control_margen` en la misma tabla ilustra el papel del piso espectral. Su condicionamiento crece de forma suave y acotada a lo largo de la rampa, desde 1.6 hasta 68, y todas sus réplicas estabilizan en todos los niveles de deriva. El menor autovalor de sus certificados finales queda fijado exactamente en la tolerancia $\lambda_{\min}(Q) = 10^{-5}$ que la capa de proyección impone, lo que indica que los certificados descansan contra esa restricción sin degenerar, pues su autovalor máximo permanece acotado. La pérdida `esfuerzo` ocupa una posición intermedia; estabiliza rápido cuando lo logra (presupuesto mínimo de 100 iteraciones en toda la rampa), pero su condicionamiento se degrada hasta el orden de 10^6 y la mitad de sus réplicas falla para $\delta \geq 1.3$, un modo de degradación coherente con su indiferencia declarada hacia la geometría del certificado.

4.7.4. Firma del Encoder

La Figura A.23 entrega la evidencia decisiva mediante el control de propuesta aleatoria. Partiendo del $\hat{y}$ de la red, el residual del solver desciende rápido al comienzo y luego se *estanca* en una meseta de la cual no escapa dentro del presupuesto, mientras el peor autovalor de lazo cerrado queda detenido apenas del lado inestable. Partiendo de un $\hat{y}$ aleatorio sobre la misma instancia, el residual atraviesa una fase inicial errática pero termina convergiendo y estabilizando. El estancamiento aparece *únicamente* con la propuesta de la red, de modo que el fallo no es imputable al solver, cuya convergencia sobre la instancia queda demostrada por el control, sino al codificador, que dirige la proyección hacia una región degenerada del conjunto factible.

La Figura A.24 esquematiza la interpretación geométrica de este comportamiento. La pérdida `margen_norm` entrena al codificador para apuntar directamente al punto de margen máximo del conjunto factible nominal, sin ninguna penalización sobre el condicionamiento del certificado que allí se obtiene. Mientras la planta permanece cerca de la distribución de entrenamiento, ese sesgo es una virtud, y explica que la pérdida encabece el escenario estructural. Cuando la deriva δ deforma el polítopo, el conjunto factible se estrecha en la dirección hacia la cual el codificador aprendió a

apuntar, y la propuesta $\hat{y}$ cae junto a una región residual delgada y mal condicionada. La proyección desde ese punto avanza a lo largo de la región angosta con pasos cada vez menores, lo que se manifiesta como la meseta del residual, y el punto que finalmente entrega es un certificado con Q casi singular cuya ganancia asociada explota. Una propuesta aleatoria, libre de ese sesgo direccional, aterriza con alta probabilidad frente a la parte ancha de la región y se proyecta sin dificultad. El fenómeno admite entonces una lectura precisa en términos de aprendizaje, dado que el mismo sesgo inductivo que produce la mejor generalización estructural constituye la vulnerabilidad *out-of-distribution*; generalizar a estructuras nuevas y resistir la deriva paramétrica no son la misma propiedad, y los datos muestran que pueden entrar en conflicto.

4.7.5. Costo Temporal en la Instancia Adversarial

La Figura A.25 compara el tiempo hasta estabilizar de la red contra el solver convexo sobre la instancia del vértice marginal. En este problema pequeño y único, CVXPY resuelve en torno a los 10 ms de forma casi constante, mientras que la red requiere desde 23 ms en el nominal hasta cerca de un segundo en los niveles altos de deriva, conforme el presupuesto necesario crece. El resultado es honesto respecto del alcance de la propuesta, puesto que la ventaja de velocidad del método no reside en instancias individuales pequeñas sino en el procesamiento por lotes y en el escalamiento con la cardinalidad documentados en la Sección 4.6, y además la deriva encarece la inferencia de la red mucho antes de hacerla fallar, lo que sugiere el presupuesto consumido como señal práctica de alerta temprana de salida de distribución.

4.8. Costos Computacionales

El costo del método se reparte entre un entrenamiento *offline* y una inferencia *online* cuyo presupuesto es ajustable. En inferencia, el tiempo por sistema crece de forma esencialmente lineal con el presupuesto de Douglas–Rachford (Figura A.26), desde ~ 1.5 ms con 100 iteraciones hasta ~ 190 ms con 8000. Combinado con las medianas de presupuesto mínimo de las secciones anteriores, esto sitúa el costo típico de sintetizar un controlador para un sistema en distribución en el orden de los pocos milisegundos, reservando los presupuestos altos para las instancias difíciles o derivadas.

En entrenamiento, el costo lo gobierna la estrategia de gradiente y no el criterio de desempeño (Figura A.27). Dentro de la rama de *unrolling*, las seis pérdidas se separan por menos de un 5 % en tiempo, entre 3 965 s (`margen_norm`) y 4 405 s (`esfuerzo`) por corrida, promediando sobre presupuestos, y la memoria pico permanece entre 533 y 698 MB. La rama implícita multiplica el tiempo por un factor cercano a once, entre 38 421 s (`margen_norm`) y 49 337 s (`control_margen`), sin reducción alguna de memoria pese a que su motivación declarada es no almacenar las iteraciones intermedias. La elección del criterio puede tomarse, por lo tanto, por sus propiedades de generalización sin consideraciones de presupuesto; la de la estrategia de gradiente, no. Cabe registrar, por último, que las curvas de pérdida son estables para cinco de los seis criterios; `esfuerzo` exhibe picos de hasta 2×10^{14} en la fase final del entrenamiento, manifestación temprana de la misma patología de certificados casi singulares analizada en la Sección 4.7.

4.9. Limitaciones y consideraciones

Los resultados anteriores deben leerse junto a las siguientes limitaciones del diseño y de su ejecución.

- **Número de réplicas.** Cada configuración se entrenó con dos semillas, que controlan la partición de datos y la inicialización de la red. Una tercera réplica del barrido completo habría añadido del orden de 590 horas de procesador sobre las 1 180 del estudio, fuera del presupuesto de cómputo disponible. La dispersión entre semillas, medida sobre las 174 configuraciones que cuentan con ambas réplicas en S2, tiene mediana de 0.60 puntos porcentuales y percentil 75 de 1.28, de modo que las diferencias inferiores a 1.3 puntos no son resolubles con este diseño. Las conclusiones del capítulo descansan sobre brechas que exceden ese umbral en al menos un orden de magnitud como *unrolling* frente a diferenciación implícita (34.3 puntos), presupuesto de *unrolling* (14.1) y colapso *out-of-distribution* de `margen_norm` (60.7), mientras que los ordenamientos internos del grupo de cabeza de la Tabla A.10 y la ventaja del codificador de actuadores en $n_x = 2$ (0.3 puntos) deben leerse como empates.
- **Marginales con cobertura desigual.** El diseño no es un factorial completo sobre todos los ejes simultáneamente, de modo que los promedios marginales del reporte mezclan celdas con cobertura muy distinta; por ello, las comparaciones de orden, tamaño y arquitectura se realizan siempre sobre subconjuntos controlados, según la advertencia de la Sección 4.3.1.
- **Tamaño de los bancos adversariales.** Ambos bancos son familias uniparamétricas de un único sistema por punto de rampa, evaluadas con múltiples réplicas de modelo: cuatro por punto en el polítopo de vértice marginal y cuarenta y cuatro en el de desplazamiento. Los porcentajes reportados son, por lo tanto, fracciones de *modelos* que estabilizan la instancia, no fracciones de sistemas. Bastan para establecer la existencia y el mecanismo del colapso, que es la afirmación que este capítulo sostiene, pero no para estimar su frecuencia sobre la población general de plantas.
- **Cuantización y censura del presupuesto mínimo.** La métrica $\text{iters}_{\min}$ se sondea sobre una grilla discreta de presupuestos, por lo que sus medianas heredan esa cuantización y las comparaciones entre valores adyacentes de la grilla deben tomarse como cotas. Además, los sistemas que nunca estabilizan no contribuyen a la mediana, de modo que esta describe el costo condicional al éxito y debe leerse junto al porcentaje estabilizado, nunca en su lugar.
- **Alcance de la caracterización espectral.** La medición del espectro de J_s reportada en la Sección 4.5.1 se realizó sobre una muestra de sistemas de orden $n_x = 3$ con polítopos de dos vértices, y sus conclusiones no se extrapolan sin más a órdenes superiores, donde la dimensión del estado del solver crece como $\frac{n_x(n_x+1)}{2} + mn_x + (N+1)n_x^2$. Adicionalmente, la identidad que vincula el *unrolling* truncado con la serie de Neumann es exacta únicamente en el punto fijo, mientras que durante el entrenamiento el desenrollado parte de la predicción del codificador y las jacobianas varían a lo largo de la trayectoria, por lo que la caracterización debe entenderse como una aproximación válida en la vecindad de la convergencia.

4.10. Configuración del *Benchmark*

4.10.1. Plataforma de Cómputo

Todos los tiempos reportados en este capítulo corresponden al equipo descrito en la Tabla A.23. El barrido se ejecutó *íntegramente en CPU*, con doce procesos concurrentes y un hilo de cómputo por proceso, y en precisión doble en todo el flujo de datos. La tarjeta gráfica del equipo quedó deliberadamente sin uso, dado que las dimensiones del problema —matrices de a lo sumo 5×5 y lotes de pocos cientos de sistemas— son demasiado pequeñas para amortizar la latencia de lanzamiento de núcleos, de manera que las mediciones preliminares arrojaron un barrido varias veces más lento sobre la unidad gráfica que sobre el procesador. Esta observación es relevante más allá de la logística, pues indica que el método propuesto no requiere aceleración especializada para operar.

4.10.2. Costo Total del Barrido

La Tabla A.24 agrega el costo de las 443 corridas del estudio sobre la plataforma de la Tabla A.23. El total asciende a 1 180 horas de procesador, equivalentes a 49.2 días de cómputo de un solo núcleo, que se completaron en aproximadamente 9.6 días de reloj gracias a los doce procesos concurrentes. La evaluación de los escenarios, que se realiza en cuatro *checkpoints* de época y recorre el sondeo completo de presupuestos de inferencia, representa un 13 % adicional sobre el costo de entrenamiento.

El reparto por rama de *backpropagation* resume en una sola cifra el hallazgo de la Sección 4.5. Las 59 corridas de diferenciación implícita, que constituyen el 13 % del estudio, consumieron el 66 % del cómputo total y son a la vez las de peor generalización. Dicho de otro modo, dos tercios del presupuesto computacional de esta memoria se invirtieron en demostrar que la alternativa más cara es la peor.

5. Conclusiones y Trabajo Futuro

5.1. Conclusiones

Esta memoria abordó el problema de sintetizar controladores robustos para sistemas LPV politópicos combinando la velocidad de inferencia del aprendizaje profundo con las garantías formales de la teoría de control. El punto de partida fue la arquitectura LMI-Net [28], propuesta y validada originalmente sobre sistemas LTI individuales, cuya capa de proyección diferenciable basada en Douglas–Rachford impone las restricciones LMI por construcción. El aporte central consistió en extender dicha arquitectura a la estabilización robusta de familias politópicas, apilando las N condiciones de vértice y la positividad del certificado en una única restricción bloque-diagonal que la misma capa de proyección procesa sin modificación, y en someter la extensión a un estudio empírico de 443 entrenamientos sobre una base de datos estándar de sistemas robustamente estabilizables.

El primer resultado es la viabilidad de la extensión. La mejor configuración identificada, la cual fue criterio `margen_norm`, *unrolling* truncado a $K_{tr} = 30$ iteraciones, tasa prescrita $\alpha = 0.01$, estabiliza el 97.4 % de los sistemas de topologías jamás observadas en entrenamiento ($N = 5$ vértices, $n_u = 2$ actuadores), cumple la tasa de decaimiento prescrita en el 90.9 % de los casos, y lo hace con una mediana de solo 100 iteraciones de proyección y certificados casi esféricos ($\kappa(Q) = 1.67$). Los controladores sintetizados certifican, además, tasas de decaimiento un orden de magnitud mayores que las ganancias de referencia almacenadas en la propia base de datos, cuya construcción está orientada a la factibilidad y no al desempeño. La descomposición *offline–online* cumple su promesa en el régimen para el que fue concebida: la proyección de Douglas–Rachford por lotes escala entre 5.1 y 16.2 veces más rápido que el solver de punto interior al crecer la cardinalidad del politopo, y el codificador entrenado aporta entre cuatro y diez puntos de tasa de éxito junto con una reducción de más de un orden de magnitud en el presupuesto de inferencia respecto de una partida aleatoria.

El hallazgo metodológico de mayor alcance concierne a la estrategia de *backpropagation*. De los 46.0 puntos porcentuales que separan la receta de la formulación original de la mejor configuración, 43.4 provienen exclusivamente de reemplazar la diferenciación implícita por *unrolling* truncado, conservando la misma función de pérdida. El óptimo de los criterios de desempeño clásicos se sitúa sobre la frontera del conjunto factible, de modo que el gradiente exacto en el punto fijo arrastra al codificador hacia certificados degenerados de margen nulo, mientras que la imprecisión del truncamiento opera como regularización implícita hacia soluciones interiores. Las corridas de diferenciación implícita, un 13 % del estudio, consumieron el 66 % del cómputo total para establecer que constituyen la peor alternativa. Esta misma lectura de la frontera ordena el resto de los resultados del barrido: los criterios que repelen la frontera o penalizan sus esquinas degeneradas (`condicionamiento`, `margen_norm`, `control_margen`) superan consistentemente a la pérdida del artículo original, y la

tasa prescrita α regula el tamaño de la región factible con un óptimo intermedio en $\alpha = 0.01$.

En el plano arquitectónico, el estudio cuantificó el precio y el valor de la invarianza estructural. Dentro de la distribución de entrenamiento, la línea base aplanada del trabajo original domina a los codificadores invariantes por unos cuatro puntos porcentuales, el costo de repartir la capacidad de la red entre todas las cardinalidades en lugar de especializarse en una. Ese margen compra, sin embargo, una capacidad que la línea base no posee ni puede poseer: procesar topologías de cardinalidad y número de actuadores nunca vistos, con más del 91 % de éxito en todos los órdenes estudiados, y reducir de 28 a 4 las redes necesarias para cubrir la malla topológica de la base de datos. La equivariancia adicional respecto de los actuadores no resultó redundante, aunque su aporte es de cobertura antes que de desempeño: sobre el subproblema que ambos codificadores pueden abordar el rendimiento es equivalente, y lo que el codificador de actuadores añade es la capacidad de procesar polítopos de dos actuadores, que el de vértices no admite como entrada.

La evaluación *out-of-distribution* aportó la lección más matizada del estudio: la generalización estructural y la robustez ante deriva paramétrica no son la misma propiedad, y pueden entrar en conflicto. El criterio `margen_norm`, el cual era el mejor del escenario estructural, colapsa al 39 % sobre el polítopo de vértice marginal, con certificados cuyo condicionamiento supera 10^7 , mientras el solver convexo certifica factibilidad en toda la rampa; `control_margen`, en cambio, estabiliza la totalidad de la rampa con condicionamiento acotado. El experimento de control con propuesta aleatoria atribuyó el fallo inequívocamente al codificador y no al solver: el mismo sesgo inductivo que apunta al punto de margen máximo del conjunto nominal dirige la proyección, bajo deriva, hacia la región residual delgada y degenerada del conjunto deformado. Dos consecuencias prácticas se desprenden de este análisis. La primera es que el condicionamiento $\kappa(Q)$, una métrica secundaria dentro de la distribución, es la variable explicativa central del comportamiento fuera de ella, y su monitoreo distingue la degradación suave de la catastrófica. La segunda es que el presupuesto de inferencia consumido crece con la deriva mucho antes de que el método falle, lo que lo convierte en una señal de alerta temprana de salida de distribución disponible sin costo adicional.

Considerando lo expuesto y las respectivas restricciones, el balance global respalda la tesis de la memoria: es posible trasladar el costo de la síntesis robusta politópica a una fase *offline* de entrenamiento auto-supervisado, conservando por construcción la garantía de factibilidad de las LMIs, y las decisiones que gobiernan la calidad del resultado, tales como criterio, gradiente y arquitectura, admiten una explicación unificada en términos de la geometría de la frontera del conjunto factible.

5.2. Trabajo Futuro

Las líneas que siguen extienden la propuesta en direcciones que los propios resultados del Capítulo 4 señalan como naturales. Cada una se presenta junto con la literatura que la respalda y, cuando corresponde, con las restricciones que la evidencia de esta memoria impone sobre su diseño.

5.2.1. Meta-Controlador Agnóstico al Orden del Sistema

El codificador de actuadores eliminó la dependencia de la arquitectura respecto de la cardinalidad del polítopo y del número de actuadores, pero conserva una dependencia residual del orden n_x a través del tamaño de la ficha (Ec. (3.18)), lo que exige mantener una red por orden. El siguiente peldaño de la escalera de invarianzas es un único meta-controlador que procese cualquier (n_x, n_u, N) , y la simetría que lo habilita es la permutación de las variables de estado: reetiquetar los estados transforma (A_i, B_i, Q, K) de forma consistente, exactamente el tipo de equivariancia que las redes neuronales de grafos (GNN) imponen por construcción [5]. Bajo esta representación, cada vértice del polítopo se codifica como un grafo atribuido cuyos nodos son las variables de estado, cuyas aristas portan las entradas de A_i y cuyos atributos nodales portan las filas de B_i ; el paso de mensajes produce representaciones por nodo y por par de nodos de dimensión independiente de n_x , desde las cuales cabezas equivariantes pueden decodificar las entradas de Q (por par de nodos) y de Y (por par nodo-actuador). El precedente directo existe: las GNN ya se han empleado como parametrización de controladores entrenados de forma auto-supervisada sobre el costo de control [14], aunque sin garantías duras de factibilidad, que es precisamente lo que la capa de proyección de esta memoria aportaría a esa línea. Como alternativa al paso de mensajes, los mecanismos de atención sobre conjuntos [19] ofrecen una vía para agregar fichas de dimensión variable que generaliza el promedio de Deep Sets empleado aquí. El desafío abierto es empírico antes que conceptual: los resultados de la Sección 4.4 muestran que cada invarianza adicional cobra un precio dentro de la distribución, por lo que la pregunta relevante es si la invarianza al orden paga ese precio con una generalización dimensional que los codificadores actuales no pueden intentar.

5.2.2. Clases de Sistemas Más Amplias

La instancia estudiada (estabilización robusta con tasa de decaimiento prescrita, bajo realimentación de estados) es la más elemental de una familia de problemas que comparten la misma estructura LMI y, por lo tanto, la misma capa de proyección. Tres extensiones destacan, a las que se suma una cuarta de naturaleza distinta.

La primera es la incorporación de **perturbaciones exógenas**. El criterio de desempeño $\mathcal{H}_\infty$, que acota la amplificación de energía desde la perturbación hacia la salida, admite una formulación LMI estándar sobre el par (Q, Y) [9] y quedó excluido de esta memoria únicamente porque la base de datos empleada no incluye el canal B_w (Sección 3.3.3). Extender la base con matrices de perturbación permitiría entrenar la misma arquitectura sobre el bloque aumentado del problema $\mathcal{H}_\infty$, recuperando además la interpretación original del elipsoide invariante como conjunto de confinamiento bajo perturbación acotada.

La segunda son los **sistemas bajo ataque**. Los ciberataques sobre CPS como inyección de datos falsos, secuestro de actuadores o denegación de servicio se modelan como alteraciones abruptas de los parámetros efectivos de la planta [25, 10], es decir, como excursiones paramétricas estructuralmente análogas a las rampas de deriva del escenario S3. Los hallazgos de la Sección 4.7 son, en ese sentido, un primer resultado de seguridad: caracterizan qué criterios de entrenamiento degradan con gracia

y cuáles colapsan cuando un adversario desplaza la planta, e identifican el presupuesto de inferencia como detector de anomalía. La línea natural consiste en cerrar el lazo, esto es, entrenar sobre familias de excursiones adversariales (endurecimiento del codificador en la dirección de peor caso) y evaluar contra modelos de ataque explícitos en lugar de rampas benignas.

La tercera son los sistemas **no cuadráticamente estabilizables**. La estabilidad cuadrática exigida en esta memoria (un único certificado Q común a todo el polítopo) es suficiente pero no necesaria, y existen polítopos estabilizables que ningún certificado común puede cubrir. La literatura de control robusto resuelve este conservadurismo con funciones de Lyapunov *dependientes de parámetros*, $P(\eta) = \sum_i \eta_i P_i$ y sus generalizaciones polinomiales homogéneas, cuya búsqueda se caracteriza mediante relajaciones LMI de precisión creciente [2, 24]. La extensión encaja con naturalidad en la arquitectura propuesta: la salida pasaría de un certificado único a un certificado por vértice $\{Q_i\}$ y las condiciones resultantes siguen siendo LMIs, de modo que la construcción bloque-diagonal y la capa de proyección se preservan, con más bloques y más variables de decisión. El costo esperable es un espacio levantado mayor y regiones factibles de geometría más compleja, terreno donde las lecciones de frontera de esta memoria serían puestas a prueba.

La cuarta extensión es de naturaleza distinta a las anteriores, porque no conserva la convexidad del problema: la **realimentación estática de salida** (SOF, $u = Fy$ con $y = Cx$). Es el caso operativamente relevante en los CPS que motivan esta memoria, donde el estado completo rara vez se mide, y quedó fuera de alcance por dos razones expuestas en la Sección 2.4.3: la base de datos empleada no incluye matriz de salida C , y —sobre todo— la transformación de congruencia que linealiza la síntesis de estado no linealiza la de salida. El término $BFCQ$ que resulta de la congruencia no admite el cambio de variable $Y = KQ$, de modo que la condición permanece como una BMI y su optimización es NP-difícil en general [8, 27].

Esto no invalida el enfoque, pero sí obliga a reformularlo, y la ruta más prometedora es apoyarse en las *relajaciones LMI suficientes* del problema SOF: bajo una restricción de acoplamiento del tipo $PB = BG$ con G invertible, o bajo una estructura impuesta sobre Q compatible con el núcleo de C , la condición vuelve a ser afín en las variables de decisión [11, 27]. Dicha relajación es conservadora —certifica menos sistemas de los estabilizables— pero encaja sin fricción en la arquitectura propuesta: la construcción bloque-diagonal se preserva íntegra, pues cada vértice sigue aportando un bloque afín, y solo cambia el contenido de los bloques y la dimensión del vector de decisión, que pasaría de $(\text{vech}(Q), \text{vec}(Y))$ a incluir la variable de acoplamiento G . La capa de proyección, el precómputo de M^{-1} y el recorte espectral por bloques operarían sin modificación. La pregunta abierta, y el interés real de la línea, es si el sesgo del codificador puede compensar parcialmente el conservadurismo de la relajación, esto es, si aprender a proponer buenos puntos de partida dentro del conjunto factible relajado recupera parte de los sistemas que la relajación descarta. Una alternativa más ambiciosa, y correspondientemente más incierta, consiste en abandonar la convexidad y tratar la BMI directamente mediante una capa de proyección alternada sobre los dos bloques de variables, a costa de perder la garantía de factibilidad por construcción que constituye el atractivo central de esta arquitectura.

5.2.3. Anclaje Adaptativo y Frontera del Óptimo

El barrido de σ_{anc} y ϵ_{pos} (Sección 4.2.5) identificó el anclaje como un eje con un efecto relevante del estudio y dejó dos frentes abiertos. El primero es que el óptimo de ambos ejes cayó en el extremo de la grilla, por lo que resta determinar si la mejora continúa al reducir σ_{anc} por debajo de 0.005 o si la curva se aplana; la pregunta no es solo de calibración, pues $\sigma_{anc} \rightarrow 0$ describe un régimen en que la propuesta del codificador opera como inicialización pero no como ancla, lectura compatible con que el valor del codificador resida en la cuenca de convergencia que selecciona antes que en la posición exacta que propone. El segundo es que el anclaje adaptativo por dispersión del polítopo, ensayado aquí en su forma más simple, admite formulaciones aprendidas: hacer de σ_{anc} una salida más del codificador convertiría un hiperparámetro global en una decisión por instancia, sin alterar la capa de proyección.

5.2.4. Visualización de la Geometría del Polítopo y del Conjunto Factible

Las explicaciones centrales de esta memoria se apoyan en esquemas conceptuales declaradamente no a escala (Figuras A.17, A.16 y A.24). Una línea de trabajo instrumental, pero de alto rendimiento, consiste en reemplazar esos esquemas por visualizaciones computadas de instancias reales: secciones bidimensionales del conjunto factible $\mathcal{C}$ a lo largo de direcciones informativas, por ejemplo, el plano generado por la propuesta del codificador, el certificado proyectado y el certificado del solver exacto, trayectorias de los iterados de Douglas–Rachford sobre esas secciones, y mapas espectrales de los vértices a lo largo de las rampas de deriva. El análogo metodológico existe en el propio aprendizaje profundo, donde la visualización por cortes de paisajes de pérdida de alta dimensión [20] convirtió intuiciones geométricas en evidencia inspeccionable. Aplicada aquí, la técnica permitiría verificar directamente el adelgazamiento direccional del conjunto factible que el análisis de mecanismo de la Sección 4.7.4 infiere de las trazas del residual, además de producir una herramienta de diagnóstico y de docencia para la incertidumbre politópica, cuyos objetos (polítopos de matrices) son intrínsecamente difíciles de comunicar sin proyecciones adecuadas.

Bibliografía

- [1] Brian D. O. Anderson and John B. Moore. *Optimal Control: Linear Quadratic Methods*. Dover Publications, 2007. Reimpresión de la edición de Prentice-Hall, 1990.
- [2] Pierre Apkarian and Hoang Duong Tuan. Parameterized LMIs in control theory. *SIAM Journal on Control and Optimization*, 38(4):1241–1264, 2000.
- [3] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
- [4] Shaojie Bai, J. Zico Kolter, and Vladlen Koltun. Deep equilibrium models. *Advances in Neural Information Processing Systems (NeurIPS)*, 32, 2019.
- [5] Peter W. Battaglia, Jessica B. Hamrick, Victor Bapst, et al. Relational inductive biases, deep learning, and graph networks. *arXiv preprint arXiv:1806.01261*, 2018.
- [6] H. H. Bauschke and P. L. Combettes. *Convex analysis and monotone operator theory in Hilbert spaces*. Springer, 2011.
- [7] Alberto Bemporad, Manfred Morari, Vivek Dua, and Efstratios N Pistikopoulos. The explicit linear quadratic regulator for constrained systems. *Automatica*, 38(1):3–20, 2002.
- [8] Vincent Blondel and John N. Tsitsiklis. NP-hardness of some linear control design problems. *SIAM Journal on Control and Optimization*, 35(6):2118–2127, 1997.
- [9] Stephen Boyd, Laurent El Ghaoui, Eric Feron, and Venkataramanan Balakrishnan. *Linear Matrix Inequalities in System and Control Theory*, volume 15 of *SIAM Studies in Applied Mathematics*. Society for Industrial and Applied Mathematics (SIAM), Philadelphia, PA, 1994.
- [10] Alvaro A Cárdenas, Saurabh Amin, and Shankar Sastry. Secure control: Towards survivable cyber-physical systems. In *2008 The 28th International Conference on Distributed Computing Systems Workshops*, pages 495–500. IEEE, 2008.
- [11] Carlos A. R. Crusius and Alexandre Trofino. Sufficient LMI conditions for output feedback control problems. *IEEE Transactions on Automatic Control*, 44(5):1053–1057, 1999.
- [12] S. Diamond and S. Boyd. CVXPY: A Python-embedded modeling language for convex optimization. *Journal of Machine Learning Research*, 17(83):1–5, 2016.
- [13] Heinz W. Engl, Martin Hanke, and Andreas Neubauer. *Regularization of Inverse Problems*, volume 375 of *Mathematics and Its Applications*. Kluwer Academic Publishers, Dordrecht, 1996.

- [14] Fernando Gama and Somayeh Sojoudi. Graph neural networks for distributed linear-quadratic control. In *Proceedings of the 3rd Conference on Learning for Dynamics and Control (L4DC)*, volume 144 of *Proceedings of Machine Learning Research*, pages 111–124. PMLR, 2021.
- [15] Stephen Gould, Richard Hartley, and Dylan Campbell. Deep declarative networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(8):3988–4004, 2021.
- [16] P. D. Grontas, A. Terpin, E. C. Balta, R. D’Andrea, and J. Lygeros. Pinet: Optimizing hard-constrained neural networks with orthogonal projection layers. In *International Conference on Learning Representations (ICLR)*, 2026.
- [17] J. Kautsky, N. K. Nichols, and P. Van Dooren. Robust pole assignment in linear state feedback. *International Journal of Control*, 41(5):1129–1155, 1985.
- [18] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015. arXiv preprint arXiv:1412.6980, 2014.
- [19] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam R. Kosiorek, Seungjin Choi, and Yee Whye Teh. Set Transformer: A framework for attention-based permutation-invariant neural networks. In *International Conference on Machine Learning (ICML)*. PMLR, 2019.
- [20] Hao Li, Zheng Xu, Gavin Taylor, Christoph Studer, and Tom Goldstein. Visualizing the loss landscape of neural nets. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 31, 2018.
- [21] P.-L. Lions and B. Mercier. Splitting algorithms for the sum of two nonlinear operators. *SIAM Journal on Numerical Analysis*, 16(6):964–979, 1979.
- [22] Y. Min and N. Azizan. HardNet: Hard-constrained neural networks with universal approximation guarantees. *arXiv preprint arXiv:2410.10807*, 2024.
- [23] Diganta Misra. Mish: A self regularized non-monotonic activation function. In *British Machine Vision Conference (BMVC)*, 2020. arXiv preprint arXiv:1908.08681, 2019.
- [24] Ricardo C. L. F. Oliveira and Pedro L. D. Peres. Parameter-dependent LMIs in robust analysis: Characterization of homogeneous polynomially parameter-dependent solutions via LMI relaxations. *IEEE Transactions on Automatic Control*, 52(7):1334–1340, 2007.
- [25] Fabio Pasqualetti, Florian Dörfler, and Francesco Bullo. Attack detection and identification in cyber-physical systems. *IEEE Transactions on Automatic Control*, 58(11):2715–2729, 2013.
- [26] R. Sambharya, G. Hall, B. Amos, and B. Stellato. End-to-end learning to warm-start for real-time quadratic optimization. In *Learning for Dynamics and Control Conference*, pages 220–234. PMLR, 2023.
- [27] Vassilis L. Syrmos, Chaouki T. Abdallah, Peter Dorato, and Karolos Grigoriadis. Static output feedback: A survey. *Automatica*, 33(2):125–137, 1997.

- [28] Sunbochen Tang, Andrea Goertzen, and Navid Azizan. LMI-Net: Linear matrix inequality–constrained neural networks via differentiable projection layers. *arXiv preprint arXiv:2604.05374*, 2026. Massachusetts Institute of Technology (MIT), Laboratory for Information and Decision Systems (LIDS).
- [29] J. Tordesillas, J. P. How, and M. Hutter. RAYEN: Imposition of hard convex constraints on neural networks. *arXiv preprint arXiv:2307.08336*, 2023.
- [30] U.S.-Canada Power System Outage Task Force. Final report on the august 14, 2003 blackout in the united states and canada: Causes and recommendations. Technical report, U.S. Department of Energy and Natural Resources Canada, 2004.
- [31] Jeremy G. VanAntwerp and Richard D. Braatz. A tutorial on linear and bilinear matrix inequalities. *Journal of Process Control*, 10(4):363–385, 2000.
- [32] V. A. Yakubovich. The S-procedure in nonlinear control theory. *Vestnik Leningrad University Mathematics*, 4:73–93, 1977.
- [33] H. Yin et al. Enforcing robust control guarantees within neural network policies. In *International Conference on Learning Representations (ICLR)*, 2021.
- [34] Manzil Zaheer, Satwik Kottur, Siamak Ravanbakhsh, Barnabás Póczos, Ruslan Salakhutdinov, and Alexander J. Smola. Deep sets. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.

A. Figuras, Tablas y Algoritmos

Este anexo reúne el material gráfico, tabular y algorítmico referido a lo largo del documento. Los elementos se presentan en el mismo orden en que se les hace referencia en el cuerpo, agrupados por capítulo de origen.

A.1. Capítulo 2: Marco Teórico




Figura A.1: Representación espectral de la estabilidad en el plano complejo $\mathbb{C}$. El semiplano izquierdo representa el espacio geométrico donde los autovalores de una matriz de Hurwitz inducen trayectorias dinámicas asintóticamente convergentes a cero.

Parámetro ξ_2 (ej. Fricción)





Figura A.2: Representación geométrica de un polígono paramétrico en 2D. Las líneas punteadas representan los límites físicos o restricciones operativas del sistema. La intersección de estos límites define los vértices (A_i), correspondientes a las condiciones operativas extremas. Cualquier variación en el tiempo del sistema físico ($\xi(t)$) queda contenida de forma segura dentro de la región azul, expresable como combinación convexa de sus vértices.



(a) $P \succ 0$ (Autovalores $\lambda_1, \lambda_2 > 0$): La energía forma un elipsoide cerrado, confinando los estados.

(b) $P \not\succ 0$ (Ej: $\lambda_1 > 0, \lambda_2 < 0$): La superficie se abre en un hiperboloide. Existen trayectorias no acotadas.

Figura A.3: Interpretación geométrica de la matriz de Lyapunov P mediante sus vectores propios (v_1, v_2) y la influencia de los signos de sus autovalores en el confinamiento del espacio de estados $\mathbb{R}^2$.




Figura A.4: Esquema de realimentación de estados aplicado al sistema politópico. El controlador estático K mide el vector de estado $x(t)$ y genera la señal de control $u(t) = Kx(t)$, que se reinyecta a la planta para conformar la dinámica en lazo cerrado $\dot{x} = (A(\xi) + B(\xi)K)x$. Nótese que la misma ganancia K debe estabilizar la planta para toda variación admisible de $\xi(t)$.

Data: Matrices del sistema paramétrico, función de costo J_{obj} , tolerancia de convergencia

ϵ_{tol}

Result: Matriz P^* que minimiza J_{obj} y satisface las LMIs

Inicialización: Encontrar un punto interior inicial estrictamente factible $P_0 \succ 0$ y variables duales $Z_0 \succ 0$;

Fijar parámetro de barrera inicial $\mu_{bar} > 0$;

while Brecha de dualidad $> \epsilon_{tol}$ **do**

 Construir el sistema perturbado de Karush-Kuhn-Tucker (KKT);

 Calcular el gradiente y la matriz Hessiana (derivadas de la función barrera);

Paso de Newton: Resolver el sistema lineal de ecuaciones para encontrar la dirección de búsqueda $(\Delta P, \Delta Z)$;

Búsqueda de línea: Determinar el tamaño de paso máximo $\alpha_{ipm} > 0$ que garantice mantener la factibilidad estricta $(P + \alpha_{ipm}\Delta P \succ 0)$;

Actualización de variables: $P \leftarrow P + \alpha_{ipm}\Delta P$, $Z \leftarrow Z + \alpha_{ipm}\Delta Z$;

Actualización de barrera: Reducir el parámetro $\mu_{bar} \leftarrow \sigma_{bar} \mu_{bar}$ (donde $\sigma_{bar} \in (0, 1)$);

end

return $P^* = P$;

Algorithm 1: Estructura Computacional de un Método de Punto Interior para LMIs

Data: Predicción cruda de la red $\hat{y}_\theta$, Ecuaciones del sistema (que definen los conjuntos afín y cónico), Tolerancia ϵ_{tol}

Result: Salida proyectada factible y^* y cálculo de gradientes para backpropagation

// Fase 1: Pase hacia Adelante mediante Splitting (Ej. Douglas-Rachford)

Inicializar variables auxiliares z_0, x_0 en base al esquema de descomposición;

while *error iterativo* $> \epsilon_{tol}$ **do**

- $w_{k+1} \leftarrow$ Proyectar sobre el subconjunto de igualdades afines;
- $v_{k+1} \leftarrow$ Proyectar sobre el cono semidefinido positivo (recorte de autovalores);
- $z_{k+1} \leftarrow$ Actualizar variables combinando ambas proyecciones;

end

Asignar la salida definitiva de la red: $y^* \leftarrow z_{final}$;

// Fase 2: Pase hacia Atrás (Entrenamiento)

if *modo* $==$ *entrenamiento* **then**

- Recibir el gradiente de la función de pérdida con respecto a la salida: $\frac{\partial \mathcal{L}}{\partial y^*}$;
- Calcular la Jacobiana de la proyección $\mathcal{J} = \frac{\partial y^*}{\partial \hat{y}_\theta}$ mediante diferenciación implícita en el punto óptimo y^* ;
- Retropropagar el error hacia las capas densas anteriores: $\frac{\partial \mathcal{L}}{\partial \hat{y}_\theta} = \frac{\partial \mathcal{L}}{\partial y^*} \cdot \mathcal{J}$;

end

return $y^*, \frac{\partial \mathcal{L}}{\partial \hat{y}_\theta}$;

Algorithm 2: Operación Computacional de una Capa de Proyección basada en Splitting

A.2. Capítulo 3: Desarrollo Metodológico

Tabla A.1: Glosario de indicadores usados en el análisis.

Indicador	En palabras simples	Un valor alto significa. . .
Abscisa espectral (lazo abierto) $\max_i \max \operatorname{Re} \lambda(A_i)$	Rapidez del modo más inestable del peor vértice	Planta muy inestable: sin control, se dispara muy rápido.
Tasa de decaimiento $\alpha = -\max_i \max \operatorname{Re} \lambda(A_i + B_i K)$	Qué tan rápido se calma el sistema ya controlado	Más margen de estabilidad; $\alpha \approx 0$ = estable al borde.
Norma $\max_i \ A_i\ _2$	Fuerza de la dinámica propia	Acoplamientos internos intensos.
Norma $\max_i \ B_i\ _2$	Cuánto influye el control en el estado	Actuadores con mucha autoridad.
Dispersión del politopo $\max_i \ A_i - \bar{A}\ _2$	Qué tan distintos son los vértices	Más incertidumbre que cubrir con una sola K .
Condición $\kappa(A_i)$	Sensibilidad numérica de la matriz	Riesgo de imprecisión numérica.
Esfuerzo $\ K\ _2$	Qué tan “fuerte” es el controlador	Acción de control más agresiva.

Tabla A.2: Esquema de la base de datos. Cada sistema es un politopo de N vértices con una ganancia robusta K .

Campo	Símbolo	Forma	Descripción
A	$\{A_i\}_{i=1}^N$	$N \times (n_x \times n_x)$	Matrices de estado de los vértices
B	$\{B_i\}_{i=1}^N$	$N \times (n_x \times n_u)$	Matrices de entrada de los vértices
K	K	$n_u \times n_x$	Ganancia de realimentación común
$n_x \in \{2, 3, 4, 5\}$ $n_u \in \{1, 2\}$ $N \in \{2, 3, 4, 5\}$ 500 casos/celda			




Figura A.5: Abscisa espectral del peor vértice. La planta es inestable (rojo, $\operatorname{Re} \lambda > 0$) en el 98.8 % de los casos; bajo la ganancia K el lazo cerrado es estable en el 100 % (inset azul, todos < 0).

Magnitudes por orden del sistema




Figura A.6: Distribución de $\|K\|_2$, $\max_i \|A_i\|_2$ y $\max_i \|B_i\|_2$ por orden n_x . El esfuerzo de control y la norma de la planta crecen con el orden.




Figura A.7: Tamaño del politopo $\max_i \|A_i - \bar{A}\|_2$ frente al número de vértices N . La incertidumbre crece con N .




Figura A.8: Tasa de decaimiento lograda α (escala log). El 84.9 % de los sistemas queda casi marginal ($\alpha < 10^{-2}$); una minoría exhibe márgenes grandes. La distribución es bimodal.




Figura A.9: Autovalores de los vértices en el plano complejo (escala symlog en el eje real). La planta en lazo abierto (rojo) se extiende al semiplano derecho; el lazo cerrado (azul) queda íntegramente a la izquierda, con el polo dominante junto al eje.




Figura A.10: Correlaciones de Spearman entre descriptores. $\|K\|$ sigue a $\|A\|$ y a la dispersión del politopo; la tasa de decaimiento α no correlaciona con ningún descriptor.

Tabla A.3: Resumen de descriptores sobre los 14 000 sistemas (datos crudos, sin normalizar).

Descriptor	Mín.	Mediana	Máx.
Abscisa espectral peor vértice (lazo abierto)	-17.9	30.9	832
Tasa de decaimiento lograda α	1.0×10^{-4}	6.3×10^{-4}	10.6
$\max_i \ A_i\ _2$	12.2	131	1012
$\max_i \ B_i\ _2$	0.74	7.90	16.8
Dispersión del politopo dispA	3.12	97.5	850
Condicionamiento $\max_i \kappa(A_i)$	1.44	52.8	5.7×10^5
Esfuerzo de control $\ K\ _2$	0.077	17.4	98.1

Data: Predicción cruda $\hat{y}_\theta$; vértices $\{(A_i, B_i)\}_{i=1}^N$; tasa de decaimiento α ; margen ϵ_{pos} ; peso de fidelidad σ_{anc} ; iteraciones K_{it}

Result: Parámetros factibles y^*

// Precómputo (una vez por sistema, fuera del bucle)

Construir L, c tales que $\text{vec}(F(y)) = Ly + c$, con F según la Ec. (3.7);

$M^{-1} \leftarrow (I + L^\top L)^{-1}$;

// Inicialización desde la predicción de la red

$y_0 \leftarrow \hat{y}_\theta$; $x_0 \leftarrow L\hat{y}_\theta + c$;

for $k \leftarrow 0$ **to** $K_{it} - 1$ **do**

$\bar{y} \leftarrow \frac{2\sigma_{anc}\hat{y}_\theta + y_k}{2\sigma_{anc} + 1}$; // anclaje a la predicción

$y_{k+1} \leftarrow M^{-1}(\bar{y} - L^\top(c - x_k))$; // proyección sobre $\mathcal{C}_1$ (mínimos cuadrados)

$\tilde{x} \leftarrow L y_{k+1} + c$;

$\hat{x} \leftarrow \Pi_{\mathcal{C}_2}(2\tilde{x} - x_k)$; // reflexión + recorte espectral por bloques

$x_{k+1} \leftarrow x_k + (\hat{x} - \tilde{x})$;

end

$y^* \leftarrow$ proyección final sobre $\mathcal{C}_1$ desde $(y_{K_{it}}, x_{K_{it}})$;

return y^* ;

Algorithm 3: Douglas–Rachford para la Proyección de la LMI (según implementación)




Figura A.11: Ilustración esquemática (no a escala) de la convergencia del algoritmo de Douglas–Rachford: partiendo de una predicción $\hat{y}_\theta$ fuera de la región factible, las proyecciones alternadas sobre el subespacio afín $\mathcal{C}_1$ y el cono $\mathcal{C}_2$ generan una trayectoria en zigzag de amplitud decreciente que converge al punto factible $y^* \in \mathcal{C}_1 \cap \mathcal{C}_2$.

Tabla A.4: Configuración de entrenamiento de la formulación original de LMI-Net [28].

Componente	Valor	Símbolo
<i>Backbone</i>	MLP, 2 capas ocultas $\times$ 64 neuronas, ReLU	—
Optimizador	Adam	—
Iteraciones DR (entrenamiento)	500	K_{it}
Iteraciones DR (inferencia)	Libre (3000–4000 típico)	—
Peso de anclaje	0.01	σ_{anc}
Margen de positividad	10^{-3}	ϵ_{pos}
Multiplicador del procedimiento S	0.1	α_s
Peso del término de margen	100	β_{soft}
Retropropagación	Diferenciación implícita	—




Figura A.12: Interpretación geométrica (esquema no a escala) del criterio de volumen $\log \det(Q)$. El elipsoide invariante $\mathcal{E}(Q)$ es la región que el certificado garantiza que las trayectorias no abandonan. Con un certificado holgado (a), la garantía admite excursiones amplias del estado; al minimizar el volumen (b), la misma garantía confina las trayectorias en la vecindad más compacta posible del equilibrio, lo que se traduce en un rechazo más estricto de las perturbaciones.

Tabla A.5: Correspondencia entre la instancia original de LMI-Net y la extensión politópica de esta memoria

	Original	Esta Investigación
Clase de sistema	LTI individual con perturbación	LPV politópico, N vértices
Parámetro de entrada ξ_{net}	(A, B, B_w) , dimensión fija	$\{(A_i, B_i)\}_{i=1}^N$, cardinalidad variable
Escalar en la LMI	α_s : multiplicador del procedimiento S	α : tasa de decaimiento prescrita
Bloques de $F(y)$	2 (desigualdad conjunta; positividad)	$N + 1$ (N vértices; positividad)
Garantía certificada	Invarianza de $\mathcal{E}(Q)$ bajo $w^\top w \leq 1$	Decaimiento exponencial robusto a tasa α
Capa de proyección	Idéntica (Algoritmo 3)	




Figura A.13: Flujo del codificador de actuadores para un ejemplo con $N = 2$ vértices y $n_u = 2$ actuadores. Cada ficha t_{ij} empareja la dinámica de un vértice con una columna de su matriz de entrada; la red compartida ϕ y los dos promedios sucesivos producen un resumen por actuador (u_j) y uno global (z); la cabeza partida genera la mitad invariante del certificado desde z y cada fila de Y desde su actuador correspondiente.

Tabla A.6: Síntesis de la escalera arquitectónica. La columna final indica cuántas redes independientes exige cubrir las 28 celdas topológicas (n_x, n_u, N) de la base de datos.

Arquitectura	Unidad de entrada	Simetrías por construcción	Redes
Línea aplanada	base Vector de $N(n_x^2 + n_x n_u)$	único Ninguna	28
Codificador de vértices	Ficha por $\mathbb{R}^{n_x^2 + n_x n_u}$ vértice,	Invariancia a permutación y cardinalidad de vértices	7
Codificador de actuadores	Ficha por (vértice, actuador), $\mathbb{R}^{n_x^2 + n_x}$	Invariancia en vértices; equivariancia en actuadores (cabeza partida)	4

Tabla A.7: Comparación entre las dos estrategias de retropropagación

Criterio	Diferenciación implícita	Desenrollado
Costo de memoria	$O(1)$, independiente de K_{it}	$O(K_{it})$, crece con las iteraciones
Gradiente	Exacto en el punto fijo	Aproximado si se trunca antes de converger
Profundidad en entrenamiento	Permite converger profundamente ($K_{it} = 500$)	Obliga a truncar ($K_{it} \approx 30$)
Implementación	Sistema lineal adjunto por muestra	Diferenciación automática nativa sobre el bucle

Tabla A.8: Registro de las seis funciones de pérdida estudiadas. Todas se evalúan sobre el certificado proyectado (Q, Y) y se minimizan.

Nombre	Expresión	Optimiza	Frontera
paper	$\log \det(Q) - 100 \lambda_{\min}(F)$	Volumen + margen	Repele)
control	$\text{tr}(Q) + 0.1 \ Y\ _F^2$	Volumen + esfuerzo	Atrae
control_margen	$\mathcal{L}_{\text{control}} + \text{relu}(0.05 - \lambda_{\min}(Q))$	Volumen + piso en Q	Repele
esfuerzo	$\ YQ^{-1}\ _F^2$	Ganancia acotada	Agnóstica
condicionamiento	$\lambda_{\max}(Q)/\lambda_{\min}(Q)$	Elipsoide esférico	Agnóstica
margen_norm	$-\lambda_{\min}(F) + 0.1 \text{tr}(Q)$	Margen normalizado	Repele

A.3. Capítulo 4: Estudio Experimental

Tabla A.9: Estructura del barrido experimental. Las etapas E1–E4 son entrenamientos; E5 y la comparación de solvers evalúan modelos ya entrenados. Todas las celdas no mencionadas permanecen en la configuración base (codificador de actuadores, $n_x = 3$, *unrolling* con $K_{tr} = 30$, $\alpha = 0.01$, 150 sistemas, 2 semillas).

Etapa	Ejes variados	Corridas	Pregunta que responde
E1	pérdida $\times \alpha \times K_{tr}$ / implícita	240	configuración del aprendizaje
E2	pérdida $\times$ orden $n_x \in \{2, \dots, 5\}$	48	escalamiento en el orden
E3	pérdida $\times$ tamaño $\in \{50, 150, 400\}$	36	eficiencia de datos
E4	arquitectura $\times$ pérdida $\times$ orden; <i>backpropagation</i>	119	invarianza, escalamiento y grad
E5	deriva paramétrica (δ, s) sobre modelos de E1	—	robustez <i>out-of-distribution</i>
DR/CVXPY	solver aislado, $N \in \{2, \dots, 5\}$	—	valor del solver y del codificador






Figura A.14: Escenarios de evaluación. El escenario S1 mide generalización estadística sobre topologías vistas; el escenario S2 mide generalización estructural a topologías jamás observadas, para lo cual el codificador debe capturar la estructura de conjunto del polítopo y no memorizar topologías particulares; el escenario S3 somete los modelos ya entrenados a deriva paramétrica *out-of-distribution*, con el solver convexo como *ground truth* de factibilidad y con Douglas–Rachford desde una inicialización aleatoria como control que aísla al codificador.

Tabla A.10: Efecto marginal de la función de pérdida sobre el escenario estructural (S2), promediando sobre los restantes ejes del barrido principal. Época 400, presupuesto de inferencia 8000.

Pérdida	% estabilizado	% decaimiento	iters _{min} (med.)
condicionamiento	89.2	71.8	250
margen_norm	87.4	69.4	100
control_margen	85.7	67.1	250
esfuerzo	83.2	70.9	100
paper	82.2	63.7	250
control	78.0	59.6	250



(a) Escenario S1 (topologías vistas).



(b) Escenario S2 (generalización estructural).

Figura A.15: Porcentaje de sistemas estabilizados en función del presupuesto de inferencia de Douglas–Rachford, por función de pérdida (época 400, promedio sobre configuraciones de E1). El ordenamiento entre pérdidas es estable en todo el rango de presupuestos y consistente entre ambos escenarios, lo que indica que la ventaja de los criterios sensibles a la frontera no depende del punto de operación elegido.

Tabla A.11: Efecto del presupuesto de *unrolling* en entrenamiento sobre el escenario estructural (S2). La última fila corresponde a la rama de diferenciación implícita, que itera hasta convergencia y constituye el caso límite del *unrolling* profundo.

K_{tr}	% estabilizado	% decaimiento	iters _{min} (med.)
30	93.3	80.7	100
5	92.0	71.0	100
120	85.5	63.1	250
500	79.4	56.0	500
Implícita (convergencia)	59.0	42.9	250




Figura A.16: Esquema conceptual (no a escala) del truncamiento como regularización implícita: con *unrolling* truncado (a), el gradiente refleja un punto interior y la red es recompensada por proponer $\hat{y}$ cuya proyección superficial ya es un certificado interior; con *unrolling* profundo o diferenciación implícita (b), el gradiente refleja el punto de convergencia sobre la frontera y el codificador deriva hacia certificados de margen nulo.

Tabla A.12: Efecto de la tasa de decaimiento prescrita α sobre el escenario estructural (S2).

α	% estabilizado	% decaimiento
0.01	87.4	79.6
0.001	81.8	80.6
0.05	81.8	52.7
0.1	80.5	33.1

Tabla A.13: Mejor configuración global frente a la receta de la formulación original, ambas con codificador de actuadores. La columna intermedia aísla el efecto del gradiente, pues conserva la pérdida original y solo cambia la estrategia de *backpropagation*. Métrica de referencia correspondiente al % estabilizado en el escenario estructural (S2), época 400, presupuesto 8000, promedio sobre semillas.

	Mejor configuración	Receta original	Receta original + <i>unrolling</i>
Pérdida	margen_norm	paper	paper
<i>Backpropagation</i>	<i>Unrolling, $K_{tr} = 30$</i>	<i>Unrolling, $K_{tr} = 30$</i>	Implícita
α	0.01	0.01	0.01
Sistemas de entrenamiento	400	150	150
% estabilizado (S2)	97.4	94.8	51.4
% decaimiento (S2)	90.9	87.6	43.7
iters _{min} mediano	100	250	500
$\kappa(Q)$ mediano	1.67	3.07	2.31
% estabilizado (S1)	94.0	90.7	49.8

Tabla A.14: Descomposición por celda topológica (n_u, N) del desempeño de la mejor configuración, época 400, presupuesto 8000, promedio sobre semillas. El factor que ordena las celdas es el número de actuadores, no la cardinalidad del polítopo ni la pertenencia al escenario.

Escenario	(n_u, N)	% estab.	% decaim.	$\kappa(Q)$ med.	sistemas
S1	(1, 2)	92.5	86.5	1.62	200
S1	(1, 3)	94.5	87.0	1.86	200
S1	(1, 4)	95.0	80.5	1.75	200
S2	(1, 5)	93.8	81.5	1.67	1000
S2	(2, 2)	99.1	95.5	1.73	1000
S2	(2, 3)	98.8	95.0	1.72	1000
S2	(2, 4)	98.1	91.7	1.65	1000
S2	(2, 5)	97.3	90.7	1.59	1000




Figura A.17: Esquema conceptual (no a escala) de la geometría del conjunto factible $\mathcal{C}$ de la LMI politópica y de las fuerzas que cada familia de criterios ejerce sobre el certificado. Los criterios de volumen puro atraen la solución hacia la frontera, cuyo extremo degenerado corresponde a Q casi singular con $\kappa(Q)$ y $\|K\|$ divergentes; los términos de margen la repelen hacia el interior; y los criterios de calidad del certificado penalizan las esquinas sin fijar la distancia a la frontera. La posición del óptimo de cada pérdida dentro de esta geometría explica los ordenamientos de las Tablas A.10 y A.11.




Figura A.18: Contraparte *computada* de la Figura A.17, sobre una instancia real del polítopo de vértice marginal en su valor nominal ($\delta = 0$), con el codificador de actuadores entrenado con `margen_norm`. Para $n_x = 2$ el espacio de decisión tiene dimensión cinco, de modo que se representa el corte de C por el plano de las dos componentes principales de la nube formada por $\hat{y}$, la trayectoria completa del solucionador, y^* y y_{cvx} ; dicho plano recoge el 98.2% de la varianza de esa nube. La región coloreada es $\{y : \lambda_{\min}(F(y)) \geq 0\}$ evaluada exactamente sobre una malla de 460×460 puntos, y su color indica el condicionamiento $\kappa(Q)$ del certificado en cada punto. Tres hechos cuantitativos sustituyen aquí a la intuición del esquema. Primero, y^* se sitúa exactamente en el vértice de la cuña factible, que es la esquina que el argumento geométrico postula. Segundo, la salida del solucionador y el certificado convexo de referencia distan 2.1×10^{-5} , por lo que ambos marcadores se superponen y Douglas–Rachford alcanza en la práctica el mismo punto que el solucionador exacto. Tercero, los criterios de desempeño ejercen fuerzas de direcciones distintas sobre el certificado, con `control` y `condicionamiento` apuntando fuera del conjunto factible. Los gradientes se dibujan normalizados, de modo que la figura informa su dirección y no su magnitud, y tanto ellos como la trayectoria son proyecciones sobre el plano de corte; la componente de $\hat{y}$ fuera de dicho plano es 1.5×10^{-2} . La trayectoria mostrada corresponde a la proyección final Π_{C_1} en cada iteración, que es la salida que el codificador efectivamente recibe.

Tabla A.15: Curva de eficiencia de datos sobre el escenario estructural (S2), bajo configuración base (codificador de actuadores, $n_x = 3$, $K_{tr} = 30$, $\alpha = 0.01$), promedio sobre las seis pérdidas y dos semillas. La celda de 150 sistemas proviene de la misma configuración controlada del contraste de arquitecturas (E4).

Sistemas de entrenamiento	% estabilizado (S2)	iters _{min} (med.)
50	93.4	100
150	95.2	100
400	95.6	100

Tabla A.16: Contraste de arquitecturas sobre el escenario estructural S2, % estabilizado promedio sobre las seis pérdidas y dos semillas, configuración base controlada. Los dos codificadores no evalúan el mismo conjunto: el de actuadores cubre las cinco celdas de S2 (2500 sistemas), mientras que el de vértices, invariante a N pero no a n_u , solo admite como entrada la celda ($n_u=1$, $N=5$) (500 sistemas), que es además la más difícil del escenario. Las dos últimas columnas restringen la comparación a esa celda común. En $n_x = 2$ ambas lecturas coinciden porque la base no contiene celdas de dos actuadores en ese orden. La línea base aplanada no aparece porque su entrada de dimensión fija no puede procesar ninguna topología retenida.

n_x	S2 completo		Celda común ($n_u=1$, $N=5$)		
	actuadores	vértices	actuadores	vértices	dif.
2	91.4	91.1	91.4	91.1	+0.3
3	95.2	90.7	90.5	90.7	-0.2
4	94.1	91.0	91.0	91.0	0.0
5	91.1	86.7	86.2	86.7	-0.5

Tabla A.17: Contraste de arquitecturas sobre el escenario en distribución S1 (topologías vistas), % estabilizado promedio sobre las seis pérdidas y dos semillas, configuración base controlada. Cada arquitectura se evalúa sobre la partición de prueba de las celdas en que fue entrenada, de modo que los codificadores invariantes cubren tres celdas (300 sistemas) y la línea base aplanada una sola, ($n_u=1$, $N=2$) (100 sistemas); la comparación mide por tanto el desempeño de cada arquitectura en su propio régimen y no un contraste sobre sistemas idénticos.


n_x	actuadores	vértices	aplanada (<i>vanilla</i>)
2	91.2	91.5	95.8
3	91.2	91.3	95.0
4	88.4	88.4	92.5
5	87.4	87.5	91.8

Tabla A.18: Comparación entre estrategias de *backpropagation* sobre el escenario estructural (S2), marginando sobre el resto del barrido principal, junto a su costo de entrenamiento. El *unrolling* reporta su mejor presupuesto ($K_{tr} = 30$) y su marginal completo.


<i>Backpropagation</i>	% estab. (S2)	% decaim.	Costo de entrenamiento
<i>Unrolling</i> ($K_{tr} = 30$)	93.3	80.7	~ 3 h por corrida
<i>Unrolling</i> (marginal)	89.5	72.0	—
Implícita (convergencia)	59.0	42.9	~ 13 h por corrida

Tabla A.19: Douglas–Rachford por lotes frente a CVXPY, por cardinalidad del polítopo ($n_x = 3$, 200 sistemas por celda, partida aleatoria para DR). Tiempos por sistema; la aceleración se calcula respecto del presupuesto de 4000 iteraciones.

N	CVXPY		DR (4000 it.)		Acel.	DR 500 it. (ms / %)
	ms	% estab.	ms	% estab.		
2	189	100	37.0	89.5	$5.1\times$	4.7 / 82.0
3	607	100	48.1	85.5	$12.6\times$	6.0 / 75.5
4	959	100	59.1	91.0	$16.2\times$	7.2 / 81.5
5	1130	100	70.0	88.5	$16.2\times$	8.7 / 81.0



(a) Tiempo por sistema.



(b) Tasa de estabilización.

Figura A.19: Comparación de solvers. A la izquierda, el costo por sistema de Douglas–Rachford por lotes crece suavemente con el presupuesto y con N , mientras que el solver de punto interior (líneas punteadas) parte más de un orden de magnitud por encima y escala peor con la cardinalidad. A la derecha, CVXPY certifica el 100 % de los sistemas y define el techo de factibilidad que Douglas–Rachford aproxima al aumentar el presupuesto.




Figura A.20: Descriptores de los sistemas que Douglas–Rachford no estabiliza desde partida aleatoria, contrastados con los estabilizados. Los fallos se concentran en sistemas con matrices peor condicionadas, polítopos más dispersos y mayor abscisa espectral de lazo abierto.

Tabla A.20: Techo de factibilidad del banco de desplazamiento de polos según el solver convexo ($\alpha = 0.01$). La LMI admite certificado en toda la rampa; lo que se degrada es el condicionamiento de ese certificado, y el peor autovalor de lazo cerrado se ancla en la tasa prescrita.

s	abscisa lazo abierto	factible	peor $\text{Re } \lambda$	$\kappa(Q)$
−1.0	−0.095	sí	−0.147	1.0
−0.7	+0.005	sí	−0.064	1.0
0.0	+0.238	sí	−0.010	3.4
0.5	+0.405	sí	−0.010	10.6
1.0	+0.572	sí	−0.010	42.8
1.3	+0.672	sí	−0.010	89.2
1.5	+0.738	sí	−0.010	138
2.0	+0.905	sí	−0.010	358

Tabla A.21: Evaluación *out-of-distribution* de los modelos de la rama de *unrolling*, con presupuesto de inferencia de 8000 iteraciones. Para cada banco se reporta el promedio del % estabilizado a lo largo de la rampa completa y la fracción de puntos de la rampa resueltos al 100 %. En ambos bancos el solver convexo certifica factibilidad en toda la rampa, de modo que el techo alcanzable es 100 en las cuatro columnas y toda diferencia es atribuible al método. El banco del vértice marginal promedia 4 réplicas de modelo por punto y el de desplazamiento, 44.

Pérdida	Vértice marginal		Desplazamiento de polos	
	media %	puntos al 100 %	media %	puntos al 100 %
condicionamiento	100.0	100.0	65.5	32.3
control	100.0	100.0	53.2	32.3
control_margen	100.0	100.0	60.6	32.3
paper	100.0	100.0	54.0	25.8
esfuerzo	76.2	42.9	56.2	25.8
margen_norm	39.3	4.8	68.7	19.4




Figura A.21: Presupuesto mínimo de estabilización en función de la deriva δ sobre el polítopo de vértice marginal, por función de pérdida, junto al control de Douglas–Rachford desde propuesta aleatoria. El costo crece con δ para todas las pérdidas conforme la región factible se estrecha, con la excepción del colapso intermitente de `margen_norm`, cuyos puntos faltantes o extremos corresponden a instancias no estabilizadas dentro del presupuesto máximo.

Tabla A.22: Anatomía del colapso sobre el polítopo de vértice marginal. Para cada nivel de deriva se reporta la fracción de réplicas (modelos $\times$ semillas) que estabiliza, el peor condicionamiento del certificado final y el peor autovalor de lazo cerrado entre las réplicas, junto al comportamiento de `control_margen` bajo el mismo protocolo. La factibilidad según el solver convexo se mantiene en toda la rampa.

δ	margen_norm			control_margen	
	estab.	máx $\kappa(Q)$	peor $\text{Re } \lambda$	estab.	$\kappa(Q)$ med.
0.0	4/4	7.0×10^3	-0.007	4/4	1.6
0.5	2/4	8.2×10^3	+0.19	4/4	6.2
1.0	2/4	1.1×10^7	$+1.6 \times 10^4$	4/4	18.4
1.5	1/4	1.4×10^8	+234	4/4	38.8
2.0	0/4	1.7×10^9	+406	4/4	67.7




Figura A.22: Evolución del certificado final sobre la rampa del polítopo de vértice marginal. El condicionamiento $\kappa(Q^*)$ de `margen_norm` salta órdenes de magnitud a partir de $\delta \approx 1$ y su peor autovalor de lazo cerrado cruza al semiplano derecho, mientras que las pérdidas restantes degradan su condicionamiento de forma suave y mantienen el espectro estable. La pérdida `esfuerzo` exhibe una degeneración intermedia, con $\kappa(Q^*)$ creciendo silenciosamente hasta el orden de 10^5 sin fallo inmediato.

P2 · peor autovalor y residual vs k ($\hat{y}$ red vs aleatorio): el aplanamiento del residual solo aparece con $\hat{y}$ de la red




Figura A.23: Firma del mecanismo de fallo. Para tres niveles de deriva se muestra el peor autovalor de lazo cerrado (arriba) y el residual del solver (abajo) en función de la iteración, partiendo de la propuesta de la red y de una propuesta aleatoria. La meseta del residual aparece solo con la propuesta de la red, lo que atribuye el fallo al codificador y no al solver.




Figura A.24: Esquema conceptual (no a escala) del mecanismo de colapso de `margen_norm`. En el nominal (a), el codificador apunta al punto de margen máximo y la proyección converge en pocas iteraciones; bajo deriva (b), el conjunto factible se adelgaza precisamente en la dirección del sesgo aprendido, la proyección se arrastra por la zona angosta —la meseta del residual de la Figura A.23— y el certificado degenera, mientras que una propuesta aleatoria, sin sesgo direccional, proyecta sobre la parte ancha y estabiliza.




Figura A.25: Tiempo hasta estabilizar la instancia del vértice marginal en función de la deriva, para la red (mejor réplica que estabiliza) y para el solver convexo. En instancias individuales pequeñas el solver exacto es más rápido; la ventaja del método propuesto aparece en el régimen por lotes de la Figura A.19.




Figura A.26: Tiempo de inferencia por sistema en función del presupuesto de Douglas–Rachford. El crecimiento esencialmente lineal permite tratar el presupuesto como una perilla de compromiso entre latencia y tasa de éxito, calibrable con las curvas de la Figura A.15.




Figura A.27: Costo de entrenamiento por función de pérdida, promediado sobre las configuraciones (E1: cuatro tasas α y dos semillas por celda). El eje logarítmico del panel izquierdo hace visibles los dos regímenes a la vez: el presupuesto de *unrolling* hace variar el tiempo por corrida en un factor de cincuenta, y la diferenciación implícita lo multiplica otras cuatro veces sobre el *unrolling* más profundo, mientras que la elección del criterio apenas mueve el costo dentro de cada régimen, un 4.1% de dispersión en tiempo y un 12% en memoria. La memoria pico es indiferente tanto al criterio como a la estrategia de gradiente, y se mantiene por debajo de los 700 MB en todos los casos.

Tabla A.23: Plataforma de cómputo empleada en la totalidad de los experimentos.

Componente	Especificación
Procesador	AMD Ryzen 7 5700G, 8 núcleos / 16 hilos, 3.8 GHz
Memoria	32 GB DDR4-2133 (4×8 GB)
Tarjeta gráfica	NVIDIA GeForce RTX 3050, 6 GB GDDR6 (sin uso)
Placa base	Gigabyte B550M GAMING X WIFI6
Sistema operativo	Windows 10 Home 22H2 (<i>build</i> 19045)
Entorno	Python 3.12.10, PyTorch 2.6.0, NumPy 2.5.1, CVXPY 1.9.2
Configuración	<code>device=cpu, float64</code> , 12 procesos $\times$ 1 hilo

Tabla A.24: Costo computacional agregado del barrido, en horas de procesador. Las corridas de diferenciación implícita concentran dos tercios del cómputo pese a representar el 13 % del total.

Etapas	Corridas	Entrenamiento (h)	Evaluación (h)
E1 (barrido principal)	240	846.3	105.4
E2 (orden)	48	11.7	22.6
E3 (eficiencia de datos)	36	10.2	12.8
E4 (<i>backpropagation</i> y arquitecturas)	119	153.9	17.1
Total	443	1 022.1	158.0
<i>Reparto por rama de backpropagation (entrenamiento y evaluación)</i>			
Diferenciación implícita	59	778.7 h (66.0 %)	
<i>Unrolling</i>	384	401.4 h (34.0 %)	

Tabla A.25: Distribución del espectro de J_s en el punto fijo y proyección de la señal de entrenamiento por banda, promediada sobre los sistemas evaluados. El operador de Douglas–Rachford es firmemente no expansivo, de modo que $\rho(J_s) \leq 1$ por construcción.

Banda espectral	Modos	Magnitud de la señal
$ \lambda > 1 - 10^{-8}$ (variedad de puntos fijos)	18	$\sim 10^{-12}$
$ \lambda \leq 1 - 10^{-8}$ (complemento)	18	$\sim 10^3$
<i>Discrepancia entre gradiente truncado y exacto</i>		
Modos que concentran la diferencia	6	exceso del 35 %

Tabla A.26: Barrido cruzado del peso de anclaje y el margen de positividad sobre el escenario estructural (S2), época 400, presupuesto 8000, promedio sobre las seis pérdidas y dos semillas. La celda sombreada es la configuración heredada de la formulación original para los codificadores invariantes.

σ_{anc}	% estabilizado (ϵ_{pos})			
	10^{-5}	10^{-4}	10^{-3}	10^{-2}
0.005	96.53	97.52	97.79	98.11
0.01	95.16	96.58	96.99	97.47
0.1	74.23	82.13	89.69	93.28
1.0	55.31	70.16	80.64	88.66
σ_{anc}	$\kappa(Q^*)$ mediano			
	10^{-5}	10^{-4}	10^{-3}	10^{-2}
0.005	7.12	2.00	2.18	2.18
0.01	3.26	1.41	1.32	1.34
0.1	1.35	1.12	1.07	1.01
1.0	1.66	1.09	1.05	1.02

Tabla A.27: Contraste de arquitecturas a margen de positividad igualado ($\sigma_{anc} = 0.01$, resto en configuración base), % estabilizado promedio sobre las seis pérdidas y dos semillas. La formulación original fija $\epsilon_{pos} = 10^{-3}$ para la línea base aplanada y 10^{-5} para los codificadores invariantes, de modo que el contraste heredado enfrenta las celdas en *diagonal*: 95.00 contra 91.25, esto es, los 3.75 puntos que la Sección 4.4 atribuía a la arquitectura. Leída por columnas, a ϵ_{pos} igualado, la ventaja de la línea base se reduce a 0.67 y 0.83 puntos. La línea base no admite evaluación en S2 por imposibilidad estructural.

Arquitectura	S1 (visto)		S2 (estructural)	
	$\epsilon_{pos} = 10^{-5}$	$\epsilon_{pos} = 10^{-3}$	$\epsilon_{pos} = 10^{-5}$	$\epsilon_{pos} = 10^{-3}$
Aplanada (<i>vanilla</i>)	91.92	95.00	—	—
Codificador de vértices	91.33	94.03	90.68	93.90
Codificador de actuadores	91.25	94.17	95.16	96.99